



Universidade de Brasília

Instituto de Ciências Exatas
Departamento de Ciência da Computação

TransferKAN: Classificação de Ferimentos Balísticos via Aprendizado por Transferência e Redes de Kolmogorov-Arnold

Arthur Silva Carneiro

Monografia apresentada como requisito parcial
para conclusão do Bacharelado em Ciência da Computação

Orientador
Prof. Dr. Pedro Garcia Freitas

Brasília
2025



Universidade de Brasília

Instituto de Ciências Exatas
Departamento de Ciência da Computação

TransferKAN: Classificação de Ferimentos Balísticos via Aprendizado por Transferência e Redes de Kolmogorov-Arnold

Arthur Silva Carneiro

Monografia apresentada como requisito parcial
para conclusão do Bacharelado em Ciência da Computação

Prof. Dr. Pedro Garcia Freitas (Orientador)
CIC/UnB

Prof. Dr. Membro 1 Prof. Dr. Membro 2
ENE/UnB ENE/UnB

Prof. Dr. Marcelo Grandi Mandelli
Coordenadora do Bacharelado em Ciência da Computação

Brasília, 01 de Dezembro de 2025

Dedicatória

Este trabalho é dedicado às pessoas cuja presença, sacrifício e apoio incondicional tornaram possível a minha jornada acadêmica. Dedico este trabalho a todos vocês, com sincero apreço e respeito.

Agradecimentos

Gostaria de expressar minha sincera gratidão à Universidade de Brasília por me conceder a oportunidade de cursar a graduação dos meus sonhos em Engenharia de Computação. Foi um privilégio estudar e me desenvolver academicamente em uma instituição tão distinta.

Estendo também meus agradecimentos à FAPDF (Fundação de Apoio à Pesquisa do Distrito Federal) pela bolsa de pesquisa concedida durante a primeira metade deste projeto. Esse apoio foi essencial para o desenvolvimento inicial do meu trabalho.

Meu reconhecimento ao GPDS (Grupo de Processamento Digital de Sinais) por fornecer os recursos computacionais que me permitiram realizar partes significativas desta pesquisa. Sou igualmente grato ao LISA (Laboratório de Imagens, Sinais e Acústica) por conceder acesso adicional à infraestrutura computacional, que foi fundamental para a conclusão deste estudo.

Por fim, gostaria de reconhecer a inestimável orientação do meu orientador, Pedro Garcia Freitas. Além de me ensinar e supervisionar minha pesquisa, ele atuou como um mentor que ofereceu conselhos valiosos sobre o meu caminho acadêmico e profissional. Seu apoio foi instrumental para o desenvolvimento bem-sucedido deste trabalho.

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES), por meio do Acesso ao Portal de Periódicos.

Resumo

A análise de ferimentos por arma de fogo (Entrada e Saída) e a estimativa da distância do disparo (MLSD - Medical-Legal Shooting Distance) são tarefas periciais desafiadoras, geralmente demandando especialistas e dependendo de condições sub-ideais de captura de imagens em cenas de crime. O advento do Aprendizado Profundo (Deep Learning) trouxe novas oportunidades para automatizar e auxiliar essas tarefas, mas ainda enfrenta dificuldades com bases de dados limitadas e desbalanceadas. Este trabalho investiga o uso de uma arquitetura híbrida denominada TransferKAN para a classificação de ferimentos balísticos em imagens reais de cenas de crime da base de dados FDCPUnBGunshotDB. A arquitetura proposta utiliza uma rede convolucional pré-treinada (ResNet152) para extração de características espaciais robustas, substituindo o classificador denso tradicional por uma Kolmogorov-Arnold Network (KAN), capaz de modelar relações não-lineares complexas de forma mais eficiente.

A abordagem foi avaliada sob um esquema de validação cruzada k-fold rigoroso, prevenindo o vazamento de dados, e acompanhada de técnicas de Data Augmentation avançadas para mitigar o desbalanceamento inerente às amostras forenses. O desempenho do modelo TransferKAN foi comparado com resultados da literatura (artigo de 2024), demonstrando superioridade técnica.

Para a tarefa de classificação do tipo de ferimento (Entrada vs. Saída), a TransferKAN com validação k-fold obteve 86,0% de Acurácia e uma AUC ponderada de 0,908, com F1-Score ponderado de 0,862. Na classificação da distância do disparo (MLSD), a TransferKAN apresentou uma melhoria em precisão ponderada, recall ponderado e F1-score balanceado, obtendo 87,3% de Acurácia. Esses resultados evidenciam que a TransferKAN obteve a melhor performance e os melhores resultados gerais em métricas integradas, destacando o potencial da utilização das redes KAN como classificadores no auxílio de patologia forense em cenários reais.

Palavras-chave: Ferimentos Balísticos, Aprendizado por Transferência, Redes de Kolmogorov-Arnold (KAN), Visão Computacional

Abstract

The analysis of gunshot wounds (Entry and Exit) and the estimation of the firing distance (MLSD - Medical-Legal Shooting Distance) are challenging forensic tasks. They typically demand highly specialized experts and depend on sub-optimal image capture conditions at crime scenes. The advent of Deep Learning has brought new opportunities to automate and assist in these tasks, yet it still faces difficulties with limited and imbalanced forensic datasets. This work investigates the use of a hybrid architecture called TransferKAN for the classification of ballistic wounds on real crime scene images from the FDCPU-BGunshotDB dataset. The proposed architecture employs a pre-trained convolutional neural network (ResNet152) to extract robust spatial features, replacing the traditional dense classifier with a Kolmogorov-Arnold Network (KAN), which is capable of modeling complex non-linear relationships more efficiently.

The approach was evaluated under a rigorous k-fold cross-validation scheme to prevent data leakage, coupled with advanced Data Augmentation techniques to mitigate the inherent class imbalance of forensic samples. The performance of the TransferKAN model was compared with results from literature (a 2024 paper baseline), demonstrating technical superiority.

For the wound type classification task (Entry vs. Exit), the TransferKAN model with k-fold validation achieved an Accuracy of 86.0% and a weighted AUC of 0.908, with a weighted F1-Score of 0.862. In the firing distance classification (MLSD), the TransferKAN showed improvements in weighted precision, weighted recall, and balanced F1-score, reaching 87.3% Accuracy. These findings demonstrate that our TransferKAN approach with k-fold validation achieved the best performance and overall results, highlighting the potential of using KAN networks as classifiers to assist forensic pathology in real-world scenarios.

Keywords: Ballistic Wounds, Transfer Learning, Kolmogorov-Arnold Networks (KAN), Computer Vision

Sumário

1	Introdução	1
1.1	Definição do Problema	1
1.2	Objetivos da Pesquisa	2
1.2.1	Hipótese de Pesquisa	3
1.3	Contribuições	3
1.4	Organização deste Documento	4
2	Fundamentação Teórica	5
2.1	Patologia Forense de Ferimentos por Arma de Fogo	5
2.1.1	Ferimentos de Entrada versus Saída	5
2.1.2	Distância Médico-Legal do Disparo (MLSD)	6
2.2	Aprendizado Profundo para Visão Computacional	6
2.2.1	Redes Neurais Convolucionais (CNNs) e ResNet	6
2.3	Redes de Kolmogorov-Arnold (KAN)	7
2.3.1	Fundamento Teórico	7
2.3.2	B-Splines e Eficiência de Parâmetros	7
3	Trabalhos Relacionados	9
3.1	IA em Patologia Forense	9
3.2	O Estudo de Referência de 2024	9
3.2.1	Metodologias e Resultados de Referência	10
3.3	Identificação da Lacuna de Pesquisa	10
4	Solução Proposta	11
4.1	A Arquitetura TransferKAN	11
4.1.1	Componentes da Arquitetura	11
4.2	Justificativa da Inovação	12
5	Metodologia	14
5.1	Descrição da Base de Dados	14

5.2	Detalhes de Implementação da TransferKAN	15
5.2.1	Backbone e Regularização	15
5.2.2	Configuração do Classificador KAN	15
5.3	Configuração Experimental	15
5.3.1	Ampliação de Dados	17
5.3.2	Divisão dos Dados: Prevenção do Vazamento Semântico de Dados .	18
5.3.3	Procedimento de Treinamento em Duas Fases	19
6	Resultados	20
6.1	Classificação do Tipo de Ferimento	20
6.2	Classificação da Distância Médico-Legal do Disparo	23
6.3	Resumo dos Achados	24
7	Conclusões	26
	Referências	28

Lista de Figuras

4.1	A arquitetura TransferKAN proposta. Um <i>backbone</i> ResNet152 pré-treinado na ImageNet extrai um vetor de características de 2048 dimensões, que é regularizado por uma camada de <i>dropout</i> ($p = 0,5$) e mapeado para as classes de saída por um classificador de Rede de Kolmogorov-Arnold com estrutura $[2048, 128, N]$ ($N = 2$ para Entrada/Saída, $N = 3$ para MLSD). .	12
5.1	Frequência da idade no momento da morte na base FDCPUnBGunshotDB, reportada por casos selecionados (a) e por imagens selecionadas (b).	16
5.2	Arcabouço geral de classificação adotado para a base FDCPUnBGunshotDB, abrangendo preparação dos dados, ampliação, treinamento do modelo e avaliação.	17
5.3	Exemplos de imagens de ferimentos por arma de fogo e algumas de suas versões ampliadas. De cima para baixo: uma entrada de curta distância, uma entrada de disparo à distância, uma entrada de disparo encostado e um ferimento de saída. Da esquerda para a direita: imagem original (pré-processada), rotação segura, espelhamento horizontal, desfoque, CLAHE, transformação elástica, ruído gaussiano, saturação de matiz, ruído ISO, brilho/contraste aleatório, RGBShift, escala de cinza, nitidez e máscara de nitidez (<i>unsharp</i>).	18
6.1	Análise de estabilidade da ResNet152 de referência ao longo das dobras, para a classificação do tipo de ferimento (a) e para a classificação da Distância Médico-Legal do Disparo (b). A primeira caixa (cinza) de cada painel corresponde à acurácia.	22
6.2	Comparação das AUC Macro, micro e Ponderada entre a ResNet152 de referência [2] e o modelo TransferKAN proposto, para a classificação do Tipo de Ferimento (Entrada/Saída, E/S) e da Distância Médico-Legal do Disparo (MLSD).	25

Lista de Tabelas

6.1	Métricas comparativas de desempenho para a Classificação do Tipo de Ferimento (Entrada vs. Saída). Valores em negrito indicam o melhor desempenho geral nas principais métricas robustas.	21
6.2	Métricas comparativas de desempenho para a Classificação da Distância Médico-Legal do Disparo (MLSD).	23

Capítulo 1

Introdução

1.1 Definição do Problema

As armas de fogo correspondem a um dos instrumentos mais frequentemente utilizados em todo o mundo para o cometimento de homicídios [1]. No trabalho pericial forense, é comum encontrar ferimentos por arma de fogo durante exames externos de corpos, seja em cenas de crime ou durante necropsias. Nesses exames, os peritos forenses precisam determinar com precisão a natureza do ferimento. Os principais desafios envolvem distinguir entre ferimentos de entrada e de saída e classificar os ferimentos de entrada de acordo com a distância a partir da qual o disparo foi efetuado, uma avaliação comumente chamada de Distância Médico-Legal do Disparo (MLSD).

Sob condições ideais, certas características morfológicas—como forma, tamanho, presença de orla de escoriação e bordas—permitem uma diferenciação relativamente fácil entre ferimentos de entrada e de saída. No entanto, na realidade, essas características nem sempre estão claramente visíveis; podem estar parcialmente ausentes, sobrepostas ou drasticamente alteradas pela putrefação. Outros fatores de confusão, incluindo o calibre da arma, o tipo de munição, o ângulo do disparo, alvos intermediários e a região do corpo atingida, complicam ainda mais a classificação precisa, mesmo para patologistas forenses experientes.

A aplicação de Inteligência Artificial (IA) e Aprendizado Profundo (Deep Learning, DL) em tarefas de visão computacional revolucionou recentemente o diagnóstico médico, oferecendo ferramentas robustas e automatizadas para a classificação de imagens complexas. Apesar desses avanços notáveis em ambientes clínicos, a transposição dessas tecnologias para o domínio forense permanece extremamente limitada. Um dos principais desafios reside na aquisição de bases de dados abrangentes, com dados de alta qualidade e cientificamente sólidos. As imagens forenses são geralmente capturadas sob diversas condições ambientais, com uma variedade de equipamentos fotográficos e dentro das circunstâncias

caóticas e rotineiras das cenas de crime, tornando a padronização praticamente impossível e gerando bases de dados altamente desbalanceadas.

A literatura existente no domínio forense, como modelos recentes de classificação treinados em bases de dados de necropsias humanas [2, 3], depende fortemente de Redes Neurais Convolucionais (CNNs) tradicionais. Essas arquiteturas empregam universalmente Perceptrons de Múltiplas Camadas (MLPs) convencionais, compostos por camadas lineares densas em seus estágios finais de classificação. Embora essas arquiteturas tenham desempenho adequado em circunstâncias generalizadas, elas têm dificuldade inerente em mapear de forma eficiente as fronteiras de características altamente não-lineares e complexas presentes em imagens forenses de ferimentos ruidosas, desbalanceadas e não padronizadas. Existe uma lacuna crítica e uma necessidade premente de um classificador mais avançado e eficiente, capaz de extrair e separar padrões não-lineares abstratos sem exigir bases de dados exponencialmente maiores ou contagens massivas de parâmetros.

1.2 Objetivos da Pesquisa

O objetivo principal deste estudo é desenvolver, implementar e avaliar uma nova arquitetura híbrida de aprendizado profundo, denominada **TransferKAN**, para a classificação automatizada de ferimentos humanos por arma de fogo a partir de imagens reais de cenas de crime. Este trabalho concentra-se meticulosamente em duas tarefas forenses específicas: classificar o tipo de ferimento (Entrada vs. Saída) e determinar a Distância Médico-Legal do Disparo (MLSD) como Encostado, Curta distância ou À distância.

Para alcançar esse objetivo geral, os seguintes objetivos específicos foram estabelecidos:

- Implementar um arcabouço de Aprendizado por Transferência utilizando uma rede ResNet152 pré-treinada como *backbone*, aproveitando sua comprovada capacidade de extração de características espaciais de alto nível a partir de imagens complexas.
- Projetar e integrar uma Rede de Kolmogorov-Arnold (KAN) como classificador de decisão principal, substituindo as camadas densas tradicionais de MLP, a fim de capturar e parametrizar melhor relações não-lineares complexas por meio de *splines* aprendíveis.
- Implementar um esquema rigoroso de validação cruzada k-fold baseado em casos para avaliar o desempenho do modelo de forma confiável, eliminando qualquer possibilidade de vazamento semântico de dados que tipicamente infla as métricas na pesquisa de IA forense.
- Comparar rigorosamente as métricas de desempenho (Acurácia, Precisão, Revocação, F1-Score, AUC e Especificidade) da arquitetura TransferKAN proposta com o

desempenho de referência das CNNs do estado da arte, especificamente o modelo ResNet152 reportado no estudo de referência de Lira et al. [2].

1.2.1 Hipótese de Pesquisa

Hipotetizamos que substituir a cabeça de classificação padrão de Perceptron de Múltiplas Camadas (MLP) de uma rede convolucional profunda do estado da arte (ResNet152) por uma Rede de Kolmogorov-Arnold (KAN) resultará em uma arquitetura híbrida superior e altamente robusta (TransferKAN). Ao aprender funções de ativação nas arestas da rede, em vez de depender de ativações fixas nos nós, a arquitetura TransferKAN modelará melhor as fronteiras não-lineares das classes desbalanceadas de imagens forenses. Consequentemente, essa abordagem produzirá maior desempenho discriminativo e confiabilidade—particularmente evidenciada pela Área sob a Curva (AUC)—tanto na classificação do tipo de ferimento quanto na de MLSD, em comparação com a ResNet152 de referência.

1.3 Contribuições

As principais contribuições deste trabalho podem ser resumidas da seguinte forma:

- A introdução pioneira da **arquitetura TransferKAN** no domínio da patologia forense. Esse modelo híbrido combina com sucesso a capacidade de extração profunda de características da ResNet152 com a classificação não-linear dinâmica e eficiente em parâmetros das Redes de Kolmogorov-Arnold.
- A demonstração empírica de que a abordagem TransferKAN, aliada a uma robusta ampliação de dados (*data augmentation*) e a uma validação cruzada k-fold estrita, supera decisivamente as CNNs tradicionais utilizadas na literatura forense anterior, mostrando especialmente grandes melhorias em robustez e na detecção de classes minoritárias para as classificações de Entrada/Saída e MLSD em uma base de dados real de cenas de crime.
- A disponibilização de um *pipeline* metodológico rigoroso que mitiga ativamente problemas de vazamento de dados por meio da divisão dos dados baseada em casos, oferecendo uma avaliação muito mais realista das verdadeiras capacidades de generalização do modelo em cenários investigativos forenses autênticos.

1.4 Organização deste Documento

O restante desta monografia está organizado da seguinte forma. O Capítulo 2 fornece a fundamentação essencial sobre a patologia forense de ferimentos por arma de fogo e introduz os fundamentos teóricos do Aprendizado Profundo e das Redes de Kolmogorov-Arnold (KAN). O Capítulo 3 revisa criticamente a literatura relacionada à IA aplicada à classificação forense de ferimentos, identificando lacunas atuais. O Capítulo 4 apresenta a solução proposta, detalhando a arquitetura TransferKAN. O Capítulo 5 descreve a metodologia, incluindo a base de dados, a ampliação de dados e os procedimentos de validação cruzada. O Capítulo 6 apresenta uma análise comparativa abrangente dos resultados entre a TransferKAN e os modelos de referência. Por fim, o Capítulo 7 conclui o trabalho, resumindo os achados e sugerindo possíveis direções para pesquisas futuras.

Capítulo 2

Fundamentação Teórica

Este capítulo fornece a fundamentação teórica essencial para compreender a natureza interdisciplinar deste trabalho, conectando a patologia forense e a inteligência artificial avançada. Ele detalha os conceitos fundamentais da classificação de ferimentos por arma de fogo, os mecanismos de aprendizado profundo para visão computacional e a teoria matemática que fundamenta as Redes de Kolmogorov-Arnold (KAN).

2.1 Patologia Forense de Ferimentos por Arma de Fogo

Na medicina forense, a análise precisa de ferimentos por arma de fogo é crucial para reconstruir os eventos de uma cena de crime. Quando um projétil atinge um corpo humano, ele produz um conjunto previsível de alterações morfológicas que variam significativamente dependendo da arma, da munição e da distância a partir da qual o disparo foi efetuado [4, 5].

2.1.1 Ferimentos de Entrada versus Saída

As tarefas de classificação mais fundamentais envolvem distinguir um ferimento de entrada de um ferimento de saída. Um ferimento de entrada é tipicamente caracterizado por uma *orla de escoriação* (uma borda marginal de pele raspada), inversão do tecido e uma forma geralmente regular, circular ou oval, dependendo do ângulo de incidência. As propriedades físicas da pele sendo empurrada para dentro pelo projétil causam esses sinais específicos. Por outro lado, um ferimento de saída geralmente apresenta tecido evertido (voltado para fora), formas irregulares ou estreladas e ausência de orla de escoriação ou resíduos de disparo, à medida que o projétil empurra o tecido de dentro para fora.

No entanto, alvos intermediários, deflexões ósseas e alterações post-mortem como a putrefação podem obscurecer essas características, tornando a classificação visual uma tarefa altamente complexa e fortemente dependente da experiência pericial.

2.1.2 Distância Médico-Legal do Disparo (MLSD)

Além de distinguir entrada de saída, classificar a distância do disparo—a Distância Médico-Legal do Disparo (MLSD)—é vital para as investigações legais. A MLSD é categorizada com base nos vestígios macroscópicos deixados pela combustão da pólvora e dos componentes do espoleta sobre a pele [4]:

- **Encostado:** A boca do cano da arma é pressionada contra a pele. Esses ferimentos frequentemente exibem uma "marca do cano" e graves lacerações teciduais devido à entrada dos gases em expansão nas camadas subcutâneas.
- **Curta distância:** Disparado a curta distância (tipicamente menos de 60 cm), esses ferimentos exibem *tatuagem* ou *esfumaçamento* (grãos de pólvora não queimados incrustados na pele) e deposição de fuligem ao redor do orifício de entrada.
- **À distância:** Disparado de uma distância na qual os resíduos de pólvora não alcançam mais a pele. O ferimento apresenta principalmente a orla de escoriação, sem fuligem ou esfumaçamento ao redor.

2.2 Aprendizado Profundo para Visão Computacional

O Aprendizado Profundo (DL), um subconjunto do aprendizado de máquina, revolucionou o campo da Visão Computacional ao permitir que modelos computacionais descubram e extraiam automaticamente as representações necessárias para a detecção de características a partir de dados brutos.

2.2.1 Redes Neurais Convolucionais (CNNs) e ResNet

As Redes Neurais Convolucionais (CNNs) são a arquitetura padrão para classificação de imagens. Elas utilizam camadas convolucionais para extrair características espaciais hierárquicas—de bordas simples nas camadas inferiores a formas semânticas complexas nas camadas mais profundas.

Um problema persistente no treinamento de CNNs profundas é o problema do desaparecimento do gradiente (*vanishing gradient*), em que os gradientes se tornam pequenos

demais para atualizar os pesos de forma eficaz nas camadas iniciais. A arquitetura de Rede Residual (ResNet) [6] resolveu isso introduzindo "conexões de atalho"(ou blocos residuais), que permitem que o gradiente contorne certas camadas. A ResNet152, uma variante com 152 camadas, representa o ápice da extração profunda de características, amplamente utilizada como *backbone* robusto em aplicações de aprendizado por transferência para imagens médicas e forenses, tipicamente inicializada com pesos pré-treinados na base de dados de larga escala ImageNet [7].

Tradicionalmente, as características espaciais profundas extraídas por arquiteturas como a ResNet são achatadas e passadas por um Perceptron de Múltiplas Camadas (MLP)—composto por camadas lineares densas e totalmente conectadas, seguidas de funções de ativação não-lineares fixas (por exemplo, ReLU)—para produzir as probabilidades finais de classe.

2.3 Redes de Kolmogorov-Arnold (KAN)

Embora os MLPs tenham sido o padrão onipresente para a cabeça de classificação no aprendizado profundo, eles são fundamentalmente baseados no Teorema da Aproximação Universal. Recentemente, uma nova arquitetura de rede neural conhecida como Redes de Kolmogorov-Arnold (KAN) foi proposta [8], inspirada no teorema de representação de Kolmogorov-Arnold.

2.3.1 Fundamento Teórico

O teorema de representação de Kolmogorov-Arnold afirma que qualquer função contínua multivariada pode ser representada como uma composição finita de funções contínuas de uma única variável e da operação de adição.

Em um MLP tradicional, a rede aprende pesos fixos (transformações lineares) nas arestas e aplica uma função de ativação não-linear fixa e predefinida (como ReLU ou Sigmoide) nos nós. Em forte contraste, uma KAN inverte esse paradigma: ela coloca funções de ativação não-lineares *aprendíveis* nas *arestas* (conexões) e simplesmente as soma nos nós.

2.3.2 B-Splines e Eficiência de Parâmetros

Para tornar as funções das arestas aprendíveis, as KANs tipicamente as parametrizam usando B-splines (splines de base) [8]. Uma B-spline é uma função polinomial por partes que pode adaptar sua forma de maneira flexível para modelar relações não-lineares altamente complexas.

Como cada parâmetro de peso em um MLP é substituído por uma função spline altamente flexível em uma KAN, as KANs geralmente requerem muito menos parâmetros para alcançar o mesmo mapeamento, ou melhor, de fronteiras de decisão complexas. Isso as torna altamente eficientes em parâmetros e menos propensas ao sobreajuste em bases de dados desbalanceadas ou relativamente pequenas—uma vantagem crítica para a visão computacional forense, na qual obter milhares de imagens de ferimentos por arma de fogo perfeitamente padronizadas é praticamente impossível.

Capítulo 3

Trabalhos Relacionados

Este capítulo revisa a literatura atual sobre a aplicação de inteligência artificial à patologia forense, com foco específico na classificação de ferimentos por arma de fogo. Ele analisa criticamente o *benchmark* do estado da arte estabelecido por estudos recentes e identifica as lacunas arquiteturais que o modelo TransferKAN proposto busca preencher.

3.1 IA em Patologia Forense

A integração da inteligência artificial às ciências forenses tem sido historicamente mais lenta em comparação com a medicina clínica. Estudos iniciais no domínio utilizaram predominantemente carcaças de animais, como suínos, para simular as propriedades da pele humana ao analisar ferimentos por arma de fogo [9]. Embora esses ambientes laboratoriais controlados permitissem altas acurácias de classificação, eles careciam da variabilidade extrema, da contaminação e das alterações morfológicas complexas encontradas em cenas de crime humanas reais. Trabalhos posteriores avançaram em direção a amostras humanas: Cheng et al. [3] treinaram classificadores em fotografias de necropsia de ferimentos humanos por arma de fogo, mas essas imagens foram obtidas sob as condições relativamente controladas de exames de necropsia e não abordaram a tarefa de MLSD.

3.2 O Estudo de Referência de 2024

Um avanço significativo na área foi alcançado recentemente por Lira et al. em seu artigo *Deep learning-based human gunshot wounds classification* [2]. Esse estudo foi pioneiro por utilizar uma base de dados forense substancial e do mundo real—a FDCPUnB GunshotDB—composta por 2.551 fotografias digitais capturadas diretamente em cenas de crime e necropsias pela Polícia Civil do Distrito Federal, no Brasil.

Os autores avaliaram sistematicamente 59 arquiteturas diferentes de aprendizado profundo (incluindo diversas variantes de EfficientNet, MobileNet, ViT e ResNet) para realizar duas tarefas principais: distinguir entre ferimentos de entrada e de saída e classificar a Distância Médico-Legal do Disparo (MLSD).

3.2.1 Metodologias e Resultados de Referência

Em sua metodologia, Lira et al. empregaram extensa ampliação de dados para combater o desbalanceamento inerente da base de dados (por exemplo, 1.883 ferimentos de entrada contra apenas 668 de saída). Eles utilizaram uma abordagem de validação *hold-out* e constataram que a arquitetura **ResNet152** demonstrou o melhor desempenho geral em ambas as tarefas.

- Para a classificação binária **Entrada vs. Saída**, a ResNet152 alcançou uma acurácia de 86,90% e uma Área sob a Curva (AUC) de 82,09%.
- Para a categorização multiclasse de **MLSD**, a mesma arquitetura alcançou uma acurácia expressiva de 92,48% e uma AUC de até 94,36%.

3.3 Identificação da Lacuna de Pesquisa

Embora o estudo de 2024 tenha estabelecido um *benchmark* robusto e comprovado a viabilidade da visão computacional em investigações forenses do mundo real, uma limitação arquitetural crítica persiste.

O modelo ResNet152 do estado da arte, como todas as CNNs tradicionais avaliadas no *benchmark*, depende de um Perceptron de Múltiplas Camadas (MLP) padrão para sua cabeça de classificação final. Os MLPs consistem em camadas lineares densas seguidas de nós de ativação não-linear fixos. Em cenários que envolvem bases de dados forenses altamente desbalanceadas, nas quais as características visuais são obscurecidas por ruído, sangue e putrefação, as ativações rígidas baseadas em nós dos MLPs requerem quantidades massivas de parâmetros para mapear com sucesso fronteiras de decisão altamente complexas e não-lineares.

Os autores do estudo de 2024 observaram que o desbalanceamento das amostras ainda afetava negativamente métricas como precisão e revocação para as classes minoritárias. Portanto, há uma necessidade clara e premente de uma cabeça de classificação leve, porém altamente expressiva, capaz de discriminar melhor, de forma probabilística, essas fronteiras não-lineares complexas sem aumentar exponencialmente o tamanho da base de dados. Essa lacuna constitui a motivação direta para a introdução das Redes de Kolmogorov-Arnold (KAN) como cabeça de classificação neste trabalho.

Capítulo 4

Solução Proposta

Para abordar as limitações das arquiteturas CNN tradicionais na classificação de bases de dados forenses de ferimentos por arma de fogo altamente desbalanceadas e não-lineares, este trabalho introduz uma nova arquitetura híbrida: a **TransferKAN**.

4.1 A Arquitetura TransferKAN

A filosofia central por trás da TransferKAN é combinar a comprovada capacidade de extração de características espaciais das Redes Neurais Convolucionais do estado da arte com o potencial de classificação altamente expressivo e eficiente em parâmetros das Redes de Kolmogorov-Arnold (KAN).

Arquiteturas tradicionais, como a ResNet152 [6] utilizada no *benchmark* de 2024 [2], processam uma imagem por meio de uma série de blocos convolucionais para gerar um vetor de características de alta dimensão. Esse vetor é então tipicamente alimentado em uma cabeça de classificação de Perceptron de Múltiplas Camadas (MLP). Embora o *backbone* ResNet seja excepcionalmente hábil em reconhecer padrões visuais (bordas, texturas, formas), a cabeça MLP frequentemente tem dificuldade em mapear essas características em classes discretas quando as fronteiras de decisão são altamente complexas, ruidosas e não-lineares—como é inerentemente o caso das imagens forenses de ferimentos por arma de fogo.

4.1.1 Componentes da Arquitetura

A arquitetura TransferKAN é composta por três estágios sequenciais distintos:

1. **Extrator de Características Espaciais (Backbone ResNet152):** Utilizamos um modelo ResNet152 [6] pré-treinado na ImageNet [7]. A camada densa totalmente

conectada final (o classificador MLP original) é removida programaticamente. Consequentemente, para uma imagem de entrada padrão, o *backbone* produz um vetor de características achatado de tamanho 2048. Isso aproveita o paradigma do Aprendizado por Transferência, evitando a necessidade de treinar um extrator profundo de características do zero em uma base de dados forense limitada.

2. **Regularização (Dropout):** Para conectar o *backbone* ao novo classificador e, ao mesmo tempo, prevenir agressivamente o sobreajuste, uma camada de *Dropout* com probabilidade $p = 0,5$ é introduzida. Isso força a rede a aprender representações redundantes e robustas, em vez de memorizar as amostras de treinamento.
3. **Classificador de Rede de Kolmogorov-Arnold (KAN):** A inovação central reside em acoplar um módulo KAN [8] diretamente ao vetor de características. Em vez de uma multiplicação matricial de camada densa com ativações fixas nos nós, a KAN mapeia o vetor de 2048 dimensões para o número desejado de classes de saída (por exemplo, 2 para Entrada/Saída ou 3 para MLSD) por meio de uma camada oculta intermediária de 128 dimensões. As conexões entre essas camadas são modeladas como B-splines aprendíveis.

O fluxo completo de dados da arquitetura proposta é resumido na Figura 4.1.




Figura 4.1: A arquitetura TransferKAN proposta. Um *backbone* ResNet152 pré-treinado na ImageNet extrai um vetor de características de 2048 dimensões, que é regularizado por uma camada de *dropout* ($p = 0,5$) e mapeado para as classes de saída por um classificador de Rede de Kolmogorov-Arnold com estrutura $[2048, 128, N]$ ($N = 2$ para Entrada/Saída, $N = 3$ para MLSD).

4.2 Justificativa da Inovação

A transição de uma cabeça de classificação MLP para um classificador KAN não é uma mera substituição estrutural; ela representa uma mudança fundamental na forma como a rede modela a fronteira de decisão final.

Ao colocar as funções de ativação não-lineares nas arestas (splines), a KAN molda dinamicamente suas formas de ativação para melhor se ajustar aos dados durante o treinamento. Isso oferece duas vantagens significativas no contexto forense:

- **Discriminação Superior em Dados Desbalanceados:** As splines permitem que a KAN crie fronteiras não-lineares altamente intrincadas ao redor dos agrupamentos das classes minoritárias (como ferimentos de Saída ou disparos Encostados) sem colapsar na classe majoritária, um ponto comum de falha dos MLPs rígidos.
- **Eficiência de Parâmetros:** A KAN requer significativamente menos parâmetros para alcançar um mapeamento matemático altamente complexo em comparação com um MLP, reduzindo o risco de superparametrização e de sobreajuste à base de dados FDCPUnBGunshotDB, que é limitada.

Por meio desse projeto arquitetural estratégico, a TransferKAN busca atuar como um discriminador probabilístico otimizado, adaptado especificamente às nuances da patologia forense.

Capítulo 5

Metodologia

Este capítulo detalha a aquisição dos dados, a implementação arquitetural do modelo TransferKAN e a configuração experimental rigorosa utilizada para treinar e validar a arquitetura proposta. A metodologia foi meticulosamente projetada para garantir a separação estrita dos dados, prevenindo completamente o vazamento semântico de dados que frequentemente compromete as tarefas de classificação de imagens médicas.

5.1 Descrição da Base de Dados

A base de dados utilizada neste estudo é a FDCPUnBGunshotDB [2], uma coleção curada de fotografias reais de cenas de crime e necropsias obtidas pela Polícia Civil do Distrito Federal (PCDF), no Brasil. Diferentemente de bases compostas por ambientes laboratoriais encenados ou modelos animais, esta base reflete autenticamente os severos desbalanceamentos de classe, as variações de iluminação e as distorções morfológicas que ocorrem naturalmente no trabalho pericial forense.

Para a tarefa principal de **Classificação do Tipo de Ferimento** (Entrada vs. Saída), a base contém um total de 2.551 imagens. Ela é severamente desbalanceada, compreendendo:

- **Ferimentos de Entrada (Rótulo 0):** 1.883 imagens
- **Ferimentos de Saída (Rótulo 1):** 668 imagens

Para a tarefa secundária de **Classificação da Distância Médico-Legal do Disparo (MLSD)**, apenas as 1.883 imagens de ferimentos de entrada são consideradas, já que ferimentos de saída não exibem características de distância. Estas são categorizadas em três classes distintas e altamente assimétricas:

- **À distância (Rótulo 2):** 1.609 imagens (85,45%)

- **Curta distância (Rótulo 1):** 232 imagens (12,32%)
- **Encostado (Rótulo 0):** 42 imagens (2,23%)

Além do desbalanceamento de classes, a base reflete o perfil demográfico típico de fatalidades relacionadas a armas de fogo: as vítimas são predominantemente homens adultos jovens, com idade média de aproximadamente 27 anos e uma forte assimetria à direita em direção a indivíduos na casa dos vinte anos, como mostra a Figura 5.1.

5.2 Detalhes de Implementação da TransferKAN

O núcleo da nossa solução proposta é a arquitetura **TransferKAN**, implementada utilizando PyTorch [10].

5.2.1 Backbone e Regularização


Empregamos uma ResNet152 [6] pré-treinada da TorchVision como *backbone* para a extração de características espaciais, aproveitando seus pesos pré-existentes para identificar padrões visuais de baixo nível complexos sem exigir uma base de dados massiva. A camada final totalmente conectada padrão foi removida, deixando a rede produzir um vetor de características achatado de alta dimensão, de tamanho 2048. Para combater o sobreajuste na base de dados limitada, uma camada pesada de *Dropout* ($p = 0,5$) foi inserida imediatamente após o extrator de características.

5.2.2 Configuração do Classificador KAN


Em vez de camadas densas convencionais, acoplamos um módulo KAN dinâmico [8] (utilizando a implementação *efficient-kan*) como classificador final. Para a classificação Entrada/Saída, a KAN foi configurada com uma estrutura de [2048, 128, 2]. Para garantir que as splines pudessem mapear as fronteiras de decisão complexas dos dados desbalanceados, utilizamos uma ordem de spline cúbica igual a 3 e um tamanho de grade ampliado igual a 10. Para a classificação de MLSD, a estrutura foi levemente adaptada para [2048, 128, 3], a fim de acomodar as três classes de distância.

5.3 Configuração Experimental

Para garantir uma avaliação confiável, reproduzível e robusta, o *pipeline* experimental foi rigorosamente controlado. O arcabouço geral de classificação—abrangendo pré-processamento, ampliação de dados, a divisão treino/teste, o treinamento do modelo e a



(a) Selected cases.



(b) Selected images.

t time of death

Figura 5.1: Frequência da idade no momento da morte na base FDCPUnBGunshotDB, reportada por casos selecionados (a) e por imagens selecionadas (b) (Fonte: [2]).

avaliação—segue o *pipeline* estabelecido para esta base de dados por Lira et al., ilustrado na Figura 5.2.




Figura 5.2: Arcabouço geral de classificação adotado para a base FDCPUnBGunshotDB, abrangendo preparação dos dados, ampliação, treinamento do modelo e avaliação (Fonte: [2]).

5.3.1 Ampliação de Dados

Devido à escassez e ao desbalanceamento extremo dos dados forenses, uma Ampliação de Dados avançada foi aplicada exclusivamente ao conjunto de treino utilizando a biblioteca *Albumentations* [11]. O *pipeline* de ampliação incluiu transformações especificamente adaptadas para imitar as realidades forenses:

- **Transformações Geométricas:** Espelhamentos horizontal e vertical e combinações de deslocamento-escala-rotação para simular diferentes ângulos fotográficos.
- **Simulação de Tecido:** Transformações elásticas para simular a elasticidade e a distorção naturais da pele humana.
- **Iluminação e Detalhe:** Equalização de Histograma Adaptativa Limitada por Contraste (CLAHE) para realçar detalhes do tecido e ruído gaussiano para simular as

condições de iluminação variadas e, muitas vezes, ruins encontradas em cenas de crime.

A Figura 5.3 mostra exemplos representativos dessas transformações aplicadas a imagens de ferimentos de cada tipo. O conjunto de teste passou por transformações estritamente determinísticas, restritas ao redimensionamento essencial (224×224) e à normalização.




Figura 5.3: Exemplos de imagens de ferimentos por arma de fogo e algumas de suas versões ampliadas. De cima para baixo: uma entrada de curta distância, uma entrada de disparo à distância, uma entrada de disparo encostado e um ferimento de saída. Da esquerda para a direita: imagem original (pré-processada), rotação segura, espelhamento horizontal, desfoque, CLAHE, transformação elástica, ruído gaussiano, saturação de matiz, ruído ISO, brilho/contraste aleatório, RGBShift, escala de cinza, nitidez e máscara de nitidez (*unsharp*) (Fonte: [2]).

5.3.2 Divisão dos Dados: Prevenção do Vazamento Semântico de Dados

Uma falha comum no aprendizado de máquina forense é realizar uma divisão aleatória das imagens. Como uma única vítima (Identificador de Caso) pode ter múltiplas fotografias do mesmo ferimento tiradas de ângulos ligeiramente diferentes, dividir as imagens aleatoriamente pode fazer com que o mesmo ferimento apareça tanto no conjunto de treino quanto no de teste, causando vazamento semântico de dados e inflando artificialmente as métricas de teste.

Para evitar isso completamente, a base de dados foi dividida estritamente com base no *Identificador de Caso* (extraído do nome do arquivo). Implementamos uma estratégia rigorosa de validação cruzada de 5 dobras, mantendo uma divisão de 80%/20% baseada em casos por dobra. Uma verificação programática de sanidade foi utilizada para garantir interseção semântica zero entre os subconjuntos de treino e teste.

5.3.3 Procedimento de Treinamento em Duas Fases

O treinamento foi conduzido ao longo de 60 épocas por dobra, utilizando uma metodologia estrita de aprendizado por transferência em duas fases:

1. **Fase 1 (Épocas 1–15):** Os parâmetros do *backbone* ResNet152 foram congelados. Apenas o classificador KAN foi treinado utilizando o otimizador AdamW com taxa de aprendizado de 1×10^{-3} e decaimento de peso (1×10^{-2}). Isso permitiu que as splines da KAN convergissem para uma linha de base estável utilizando as características brutas.
2. **Fase 2 (Épocas 16–60):** Toda a rede foi descongelada (*fine-tuning*). O treinamento continuou com uma taxa de aprendizado reduzida de 1×10^{-5} para otimizar conjuntamente os filtros convolucionais e as splines da KAN.

Um agendador CosineAnnealingLR foi utilizado ao longo de ambas as fases para decair suavemente a taxa de aprendizado. Além disso, a ponderação por frequência inversa de classe foi aplicada à função de perda de Entropia Cruzada para penalizar matematicamente, de forma mais severa, os erros nas classes minoritárias (por exemplo, disparos Encostados). Durante cada dobra, os pesos do modelo que alcançaram a maior acurácia de teste foram salvos como ponto de verificação, e as previsões fora da dobra (*out-of-fold*) foram agregadas para calcular as métricas finais, verdadeiramente validadas por validação cruzada.

Capítulo 6

Resultados

Este capítulo apresenta os resultados comparativos abrangentes da arquitetura TransferKAN proposta em relação ao modelo ResNet152 de referência estabelecido no estudo de Lira et al. [2]. A análise é dividida em duas seções principais, correspondentes às duas tarefas forenses distintas: Classificação do Tipo de Ferimento (Entrada vs. Saída) e Classificação da Distância Médico-Legal do Disparo (MLSD).

Para fornecer uma avaliação robusta e cientificamente sólida das capacidades dos modelos em dados altamente desbalanceados, reportamos as médias Macro (M), micro (m) e Ponderada (P) para diversas métricas, incluindo Precisão, Revocação, F1-Score, Área sob a Curva (AUC) e Especificidade.

6.1 Classificação do Tipo de Ferimento

A Tabela 6.1 detalha as métricas de classificação para distinguir entre ferimentos de entrada e de saída por arma de fogo. É imperativo notar a diferença nas metodologias de validação: o modelo de referência de 2024 foi avaliado utilizando um método padrão de validação *hold-out*, ao passo que nosso modelo TransferKAN proposto foi submetido a um rigoroso esquema de validação cruzada de 5 dobras (VC), separado estritamente por Identificador de Caso. Esse protocolo estrito garante isolamento semântico absoluto entre os conjuntos de treino e teste, prevenindo o vazamento de dados que tipicamente infla artificialmente as métricas de acurácia em imagens forenses.

Os resultados empíricos demonstram que, embora a ResNet152 de referência exiba uma acurácia bruta marginalmente superior (0,869 contra 0,860 da TransferKAN) na Tabela 6.1, essa comparação é fundamentalmente assimétrica. A acurácia de 0,869 da referência foi obtida por meio de uma simples divisão *hold-out*, altamente suscetível a vazamento semântico de dados (por exemplo, imagens do mesmo paciente aparecendo tanto no treino quanto no teste). De forma crucial, quando os autores do estudo de


Tabela 6.1: Métricas comparativas de desempenho para a Classificação do Tipo de Ferimento (Entrada vs. Saída). Valores em negrito indicam o melhor desempenho geral nas principais métricas robustas.

Arquitetura	Variante	ACC	Precisão			Revocação			F1-Score			AUC			Especificidade		
			M	m	P	M	m	P	M	m	P	M	m	P	M	m	P
ResNet [Referência]	152	0.869	0.827	0.869	0.868	0.821	0.869	0.869	0.824	0.869	0.869	0.821	0.821	0.821	0.821	0.869	0.869
ConvKAN+ResNet	Hold-out	0.822	0.767	0.822	0.820	0.762	0.822	0.822	0.765	0.822	0.821	0.839	0.885	0.839	0.762	0.822	0.703
PureConvKAN	Hold-out	0.707	0.614	0.707	0.704	0.611	0.707	0.707	0.613	0.707	0.706	0.682	0.768	0.682	0.611	0.707	0.516
PureKAN	Hold-out	0.692	0.614	0.692	0.692	0.614	0.692	0.692	0.614	0.692	0.692	0.684	0.733	0.684	0.614	0.692	0.536
TransferKAN [Nossa]	K-Fold	0.860	0.817	0.860	0.865	0.835	0.860	0.860	0.825	0.860	0.862	0.908	0.928	0.908	0.835	0.860	0.810


2024 [2] submeteram sua ResNet152 de referência a uma rigorosa validação cruzada k-fold estratificada e agrupada (reportada em seu *boxplot* de análise de estabilidade, reproduzido aqui na Figura 6.1), sua acurácia mediana caiu para cerca de 0,73, com a maior parte das dobras situada entre aproximadamente 0,70 e 0,78 e uma notável dispersão entre as dobras.

Em forte contraste, o modelo TransferKAN proposto alcançou sua acurácia de 0,860 fora da dobra (*Out-of-Fold*, OOF) sob uma validação cruzada de 5 dobras rigorosamente isolada por caso. Ao comparar os modelos sob o mesmo paradigma rigoroso de avaliação k-fold (0,860 para a TransferKAN vs. uma mediana de $\sim 0,73$ para a ResNet152), torna-se inequivocamente claro que a TransferKAN é amplamente superior e significativamente mais estável do que a referência. Além disso, a acurácia bruta em si é uma métrica falha em bases de dados altamente desbalanceadas, pois um modelo pode inflar sua pontuação simplesmente prevendo constantemente a classe majoritária (ferimentos de Entrada). Em vez disso, o verdadeiro poder discriminativo do modelo TransferKAN é amplamente evidenciado pelas pontuações de Área sob a Curva (AUC). A TransferKAN alcançou uma **AUC micro de 0,928** extraordinária e uma **AUC Macro de 0,908**, superando completamente a AUC uniforme de 0,821 da referência. A AUC avalia a capacidade probabilística do modelo de distinguir entre as classes em todos os limiares de classificação. Além disso, a TransferKAN obteve maior Revocação Macro (0,835 vs. 0,821) e maior F1-Score Macro (0,825 vs. 0,824), além de maior Especificidade Macro (0,835 vs. 0,821). Isso confirma nossa hipótese central: substituir o classificador denso MLP tradicional e rígido por uma KAN dinâmica melhora significativamente a capacidade matemática da rede de identificar corretamente as classes minoritárias (ferimentos de Saída) e de lidar com fronteiras visuais não-lineares sem sobreajuste.


Para avaliar de forma abrangente o paradigma das Redes de Kolmogorov-Arnold, também treinamos e testamos diversas arquiteturas alternativas (PureKAN, PureConvKAN e ConvKAN+ResNet) utilizando uma validação *hold-out* estrita e isolada por caso. Como demonstrado na Tabela 6.1, embora esses modelos alternativos mantivessem a separação semântica (prevenindo, assim, o vazamento de dados), seu desempenho geral caiu significativamente, com a PureKAN alcançando uma acurácia de 0,692 e a PureConvKAN,



(a) Wound type



(b) Medical-legal shooting distance



ation performance for wound type (a) and shooting distance (b) using ResNet 152 over the k-folds

Figura 6.1: Análise de estabilidade da ResNet152 de referência ao longo das dobras, para a classificação do tipo de ferimento (a) e para a classificação da Distância Médico-Legal do Disparo (b). A primeira caixa (cinza) de cada painel corresponde à acurácia (Fonte: [2]).

0,707. A híbrida ConvKAN+ResNet teve desempenho melhor (acurácia de 0,822), mas ainda assim ficou aquém da nossa arquitetura TransferKAN proposta. Essa análise comparativa confirma matematicamente que a combinação específica de extração profunda de características espaciais (via *backbone* ResNet) e mapeamento de decisão dinâmico baseado em B-splines (o classificador KAN), proposta na TransferKAN, é estritamente necessária para alcançar desempenho e robustez ótimos na classificação forense de ferimentos por arma de fogo.

6.2 Classificação da Distância Médico-Legal do Disparo

A Tabela 6.2 apresenta os resultados comparativos para a tarefa multiclasse de classificação de MLSD. Essa tarefa representa um caso extremo de desbalanceamento de classes; a base é fortemente enviesada em direção aos disparos 'À distância' (1.609 imagens), com pouquíssimos exemplos de 'Curta distância' (232) e disparos 'Encostado' (42).

Tabela 6.2: Métricas comparativas de desempenho para a Classificação da Distância Médico-Legal do Disparo (MLSD).

Arquitetura	Variante	ACC	Precisão			Revocação			F1-Score			AUC			Especificidade		
			M	m	P	M	m	P	M	m	P	M	m	P	M	m	P
ResNet [Referência]	152	0.925	0.810	0.925	0.917	0.637	0.925	0.925	0.701	0.925	0.917	0.733	0.944	0.745	0.830	0.962	0.566
PureConvKAN	Hold-out	0.803	0.268	0.803	0.645	0.333	0.803	0.803	0.297	0.803	0.716	0.536	0.888	0.509	0.667	0.902	0.197
PureKAN	Hold-out	0.712	0.355	0.712	0.689	0.324	0.712	0.712	0.328	0.712	0.693	0.463	0.841	0.496	0.679	0.856	0.326
TransferKAN [Nossa]	K-Fold	0.873	0.598	0.873	0.853	0.496	0.873	0.873	0.526	0.873	0.860	0.749	0.944	0.785	0.797	0.936	0.517

Para a tarefa de MLSD, a abordagem TransferKAN reportou uma Acurácia validada por validação cruzada de 0,873, enquanto a ResNet152 de referência reportou uma acurácia bruta superior, de 0,925. No entanto, essa discrepância em acurácia, precisão e revocação deve ser analisada contextualmente sob a ótica dos esquemas de validação. A validação *hold-out* frouxa da referência permite inerentemente o vazamento semântico na classe majoritária, inflando artificialmente métricas que são fortemente influenciadas pelo grande volume de imagens 'À distância'. Ao utilizar uma validação cruzada k-fold estrita baseada em casos, a avaliação da TransferKAN simula um cenário forense do mundo real muito mais severo, porém infinitamente mais realista, no qual o modelo deve classificar pacientes completamente desconhecidos.

Apesar dessa penalidade de avaliação severa e estrita, a TransferKAN alcançou uma **AUC Macro mais alta (0,749 vs. 0,733)** e uma **AUC Ponderada mais alta (0,785 vs. 0,745)** em comparação com a referência, mantendo uma AUC micro igual (0,944). Essas métricas probabilísticas integradas são cruciais porque demonstram que a Rede de Kolmogorov-Arnold atua como um discriminador probabilístico excepcional-

mente refinado. Mesmo quando classifica erroneamente um disparo 'Encostado' como 'Curta distância' devido à ambiguidade visual, suas distribuições de probabilidade subjacentes são significativamente mais precisas e confiáveis do que as produzidas por um MLP tradicional.

Além disso, ao avaliar as arquiteturas KAN alternativas (PureKAN e PureConvKAN) nesta tarefa de MLSD altamente desbalanceada utilizando validação *hold-out* estrita baseada em casos, seu desempenho mostrou-se inadequado. Como exibido na Tabela 6.2, a acurácia da PureKAN caiu para 0,712 e a PureConvKAN alcançou 0,803, com ambos os modelos demonstrando pontuações fracas de AUC Macro (0,463 e 0,536, respectivamente) em comparação com a referência e a TransferKAN. Esse declínio acentuado destaca que as camadas KAN sozinhas, ou camadas KAN combinadas com extratores convolucionais rasos, têm grande dificuldade com o desbalanceamento extremo de classes e com as sutis distinções visuais das distâncias de disparo. Isso reforça a conclusão de que a extração de características espaciais profunda e robusta do *backbone* ResNet é indispensável e de que a TransferKAN une com sucesso essa extração profunda ao mapeamento probabilístico avançado das Redes de Kolmogorov-Arnold.

6.3 Resumo dos Achados

Em conclusão, a implementação da TransferKAN com validação cruzada k-fold estrita e isolada por caso fornece a metodologia mais cientificamente robusta para a classificação de imagens forenses de ferimentos por arma de fogo até o momento. Enquanto os MLPs tradicionais perseguem a acurácia bruta superprevedendo as classes majoritárias, a arquitetura TransferKAN aproveita suas B-splines adaptáveis para mapear fronteiras de decisão complexas, resultando em ganhos massivos de Área sob a Curva (AUC) para ambas as tarefas. Isso comprova que a TransferKAN é altamente eficaz no gerenciamento das complexidades não-lineares intrínsecas e dos severos desbalanceamentos das imagens reais de cenas de crime. A Figura 6.2 resume a comparação de AUC entre o modelo TransferKAN proposto e a ResNet152 de referência em ambas as tarefas forenses.




Figura 6.2: Comparação das AUC Macro, micro e Ponderada entre a ResNet152 de referência [2] e o modelo TransferKAN proposto, para a classificação do Tipo de Ferimento (Entrada/Saída, E/S) e da Distância Médico-Legal do Disparo (MLSD).

Capítulo 7

Conclusões

Este estudo projetou, implementou e avaliou rigorosamente a arquitetura **TransferKAN** para a classificação automatizada de ferimentos humanos por arma de fogo. Ao combinar a poderosa capacidade de extração de características espaciais de um *backbone* ResNet152 pré-treinado com a modelagem não-linear dinâmica e eficiente em parâmetros de uma Rede de Kolmogorov-Arnold (KAN), estabelecemos um novo e altamente robusto *benchmark* para aplicações de aprendizado profundo em patologia forense.

A análise empírica, conduzida em uma base de dados realista e severamente desbalanceada de 2.551 imagens de cenas de crime (FDCPUnBGunshotDB), demonstrou que o modelo TransferKAN melhora significativamente a robustez e a generalização da classificação em relação aos métodos tradicionais. Especificamente, na tarefa binária de distinguir entre ferimentos de Entrada e de Saída, a arquitetura proposta alcançou uma estelar Área sob a Curva (AUC) micro de 0,928 e uma AUC Macro de 0,908 sob um esquema estrito de validação cruzada de 5 dobras baseado em casos. Esse desempenho superou decisivamente o classificador ResNet152 de referência reportado na literatura de 2024 [2] (que alcançou uma AUC uniforme de 0,821), comprovando que as KANs são amplamente superiores no tratamento probabilístico de classes minoritárias e de fronteiras de características não-lineares, sem colapsar.

Para a classificação da Distância Médico-Legal do Disparo (MLSD), apesar das dificuldades inerentes do desbalanceamento extremo de classes e do protocolo estrito de validação cruzada que previne ativamente o vazamento de dados, o modelo TransferKAN produziu uma AUC Macro (0,749) e uma AUC Ponderada (0,785) mais altas em comparação com as CNNs tradicionais de referência. Esses resultados confirmam fortemente nossa hipótese central: substituir o Perceptron de Múltiplas Camadas (MLP) padrão e rígido por uma Rede de Kolmogorov-Arnold flexível melhora significativamente a capacidade do modelo de discriminar padrões visuais complexos em imagens forenses ruidosas.

Em conclusão, nossa abordagem utilizando a TransferKAN com validação k-fold estrita fornece a metodologia mais cientificamente robusta para a classificação forense de ferimentos por arma de fogo até o momento, demonstrando sua imensa viabilidade como ferramenta de apoio confiável para peritos forenses e médicos-legistas.

Trabalhos futuros devem focar na expansão da base de dados por meio de colaborações multi-institucionais, a fim de validar ainda mais o modelo em diferentes demografias e tipos de arma de fogo. Adicionalmente, uma direção empolgante para pesquisas futuras envolve explorar a interpretabilidade matemática das splines da KAN. Como as funções de ativação são polinômios explícitos por partes nas arestas, elas oferecem uma oportunidade única de desenvolver percepções de IA Explicável (XAI), permitindo potencialmente que patologistas forenses interpretem fisicamente quais características visuais a rede prioriza durante seu processo de decisão. Por fim, investigar a integração de dados multimodais, como a incorporação do texto bruto de laudos de necropsia juntamente com as imagens digitais, poderia refinar ainda mais o *pipeline* de classificação.

Referências

- [1] United Nations Office on Drugs and Crime (UNODC): *Global study on homicide 2023*. <https://www.unodc.org/unodc/en/data-and-analysis/global-study-on-homicide.html>, 2023. Accessed: 2024-03-08. 1
- [2] Queiroz Nogueira Lira, Renato, Luana Geovana Motta de Sousa, Maisa Luana Memória Pinho, Renan Cesar Pinto da Silva Andrade de Lima, Pedro Garcia Freitas, Bruno Scholles Soares Dias, Andreia Cristina Breda de Souza e André Ferreira Leite: *Deep learning-based human gunshot wounds classification*. *International Journal of Legal Medicine*, 139(2):651–666, 2025. 2, 3, 9, 11, 14, 16, 17, 18, 20, 21, 22, 25, 26
- [3] Cheng, Jerome, Carl Schmidt, Allecia Wilson, Zhaohui Wang, Wei Hao, Joshua Pantanowitz, Christopher Morris, Robert Tashjian e Liron Pantanowitz: *Artificial intelligence for human gunshot wound classification*. *Journal of Pathology Informatics*, 15:100361, 2024. 2, 9
- [4] Di Maio, Vincent J M: *Gunshot Wounds: Practical Aspects of Firearms, Ballistics, and Forensic Techniques*. CRC Press, Boca Raton, FL, USA, 3ª edição, 2015. 5, 6
- [5] Saukko, Pekka J e Bernard Knight: *Knight’s Forensic Pathology*. CRC Press, Boca Raton, FL, USA, 4ª edição, 2016. 5
- [6] He, Kaiming, Xiangyu Zhang, Shaoqing Ren e Jian Sun: *Deep residual learning for image recognition*. Em *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 770–778, 2016. 7, 11, 15
- [7] Deng, Jia, Wei Dong, Richard Socher, Li Jia Li, Kai Li e Li Fei-Fei: *ImageNet: A large-scale hierarchical image database*. Em *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 248–255, 2009. 7, 11
- [8] Liu, Ziming, Yixuan Wang, Sachin Vaidya, Fabian Ruehle, James Halverson, Marin Soljačić, Thomas Y Hou e Max Tegmark: *KAN: Kolmogorov-Arnold networks*. arXiv preprint arXiv:2404.19756, 2024. 7, 12, 15
- [9] Oura, Petteri, Anneli Junno e Juho Antti Junno: *Deep learning in forensic gunshot wound interpretation—a proof-of-concept study*. *International Journal of Legal Medicine*, 135:2101–2106, 2021. 9
- [10] Paszke, Adam, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga *et al.*: *PyTorch: An imperative style, high-performance deep learning library*. Em *Advances in*

Neural Information Processing Systems (NeurIPS), volume 32, páginas 8024–8035, 2019. 15

- [11] Buslaev, Alexander, Vladimir I Iglovikov, Eugene Khvedchenya, Alex Parinov, Mikhail Druzhinin e Alexandr A Kalinin: *Albumentations: Fast and flexible image augmentations*. Information, 11(2):125, 2020. 17