

Universidade de Brasília
Instituto de Ciências Exatas
Departamento de Ciência da Computação

TransferKAN sob um Protocolo sem Vazamento: Reavaliação das Cabeças de Kolmogorov-Arnold na Classificação de Ferimentos por Arma de Fogo

Arthur Silva Carneiro

Monografia apresentada como requisito parcial
para conclusão do Bacharelado em Ciência da Computação

Orientador
Prof. Dr. Pedro Garcia Freitas

Brasília
2026

Dedicatória

Este trabalho é dedicado às pessoas cuja presença, sacrifício e apoio incondicional tornaram possível a minha jornada acadêmica. Dedico este trabalho a todos vocês, com sincero apreço e respeito.

Agradecimentos

Gostaria de expressar minha sincera gratidão à Universidade de Brasília por me conceder a oportunidade de cursar a graduação dos meus sonhos em Ciência da Computação. Foi um privilégio estudar e me desenvolver academicamente em uma instituição tão distinta.

Estendo também meus agradecimentos à FAPDF (Fundação de Apoio à Pesquisa do Distrito Federal) pela bolsa de pesquisa concedida durante a primeira metade deste projeto. Esse apoio foi essencial para o desenvolvimento inicial do meu trabalho.

Meu reconhecimento ao GPDS (Grupo de Processamento Digital de Sinais) por fornecer os recursos computacionais que me permitiram realizar partes significativas desta pesquisa. Sou igualmente grato ao LISA (Laboratório de Imagens, Sinais e Acústica) por conceder acesso adicional à infraestrutura computacional, que foi fundamental para a conclusão deste estudo.

Por fim, gostaria de reconhecer a inestimável orientação do meu orientador, Pedro Garcia Freitas. Além de me ensinar e supervisionar minha pesquisa, ele atuou como um mentor que ofereceu conselhos valiosos sobre o meu caminho acadêmico e profissional. Seu apoio foi instrumental para o desenvolvimento bem-sucedido deste trabalho.

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES), por meio do Acesso ao Portal de Periódicos.

Resumo

Classificar ferimentos por arma de fogo como de entrada ou de saída e estimar a distância do disparo são tarefas periciais exigentes. Este trabalho avalia a TransferKAN, uma ResNet-152 pré-treinada no ImageNet com uma Rede de Kolmogorov-Arnold (KAN) como cabeça de classificação, em fotografias reais de locais de crime da FDCPUnBGunshotDB. Uma versão anterior deste trabalho relatou que a TransferKAN superava os baselines de Lira et al., mas essa comparação misturava partições, inicializações e definições de AUC diferentes. Por isso, a avaliação foi refeita num protocolo único: cinco dobras agrupadas por caso, a mesma receita de treino para todos os modelos, AUC das probabilidades e regras de decisão fixadas antes dos experimentos.

Há quatro achados. (i) O hold-out do código público do estudo de 2024 estratifica pelo caso em vez de agrupar por caso: 98,7% das imagens de teste de entrada/saída pertencem a casos vistos no treino. Com a mesma rede e a mesma receita, ele infla a AUC em +0,034 em entrada/saída e de +0,155 a +0,158 na distância do disparo. (ii) A cabeça KAN não é a fonte dos ganhos: ela é equivalente às cabeças linear e MLP em entrada/saída (AUC de 0,905 contra 0,906) e fica abaixo de uma MLP do mesmo tamanho na distância do disparo, e uma KAN com wavelets não muda isso. (iii) Entre doze arquiteturas retreinadas, a Swin-B é a melhor (AUC de 0,929 em entrada/saída) e supera a TransferKAN nas duas tarefas. (iv) Uma única rede com uma cabeça por tarefa tem 47–50% menos parâmetros e é duas vezes mais rápida que o par de redes. Ela é não inferior na distância do disparo e cerca de 0,01 de AUC pior em entrada/saída, dentro da margem pré-registrada. Os disparos encostados continuam sendo a principal limitação. As contribuições são uma partição auditada, um protocolo sem vazamento e uma rede multitarefa a metade do custo.

Palavras-chave: Ferimentos por Arma de Fogo, Vazamento de Dados, Validação Cruzada Agrupada, Redes de Kolmogorov-Arnold (KAN), Aprendizado por Transferência, Aprendizado Multitarefa

Abstract

Classifying gunshot wounds as entry or exit and estimating the shooting distance are demanding forensic tasks. This work evaluates TransferKAN, a ResNet-152 pre-trained on ImageNet with a Kolmogorov-Arnold Network (KAN) as its classification head, on real crime-scene photographs of the FDCPUnBGunshotDB. An earlier version of this work reported that TransferKAN outperformed the baselines of Lira et al., but that comparison mixed different splits, initialisations and definitions of the AUC. The evaluation was therefore rebuilt under a single protocol: five folds grouped by case, the same training recipe for every model, AUC from probabilities and decision rules fixed before the experiments.

Four findings follow. (i) The hold-out of the public code of the 2024 study stratifies by case instead of grouping by case: 98.7% of its entry/exit test images belong to cases seen in training. With the same network and recipe, it inflates the AUC by +0.034 in entry/exit and by +0.155 to +0.158 in shooting distance. (ii) The KAN head is not the source of the gains: it is equivalent to linear and MLP heads in entry/exit (AUC 0.905 against 0.906) and below an MLP of the same size in shooting distance, and a wavelet KAN does not change this. (iii) Among twelve retrained architectures, Swin-B is the best (AUC 0.929 in entry/exit) and outperforms TransferKAN in both tasks. (iv) A single network with one head per task has 47–50% fewer parameters and is twice as fast as the pair of networks. It is non-inferior in shooting distance and about 0.01 of AUC worse in entry/exit, within the pre-registered margin. Contact shots remain the main limitation. The contributions are an audited split, a leak-free protocol and a multitask network at half the cost.

Keywords: Gunshot Wounds, Data Leakage, Grouped Cross-Validation, Kolmogorov-Arnold Networks (KAN), Transfer Learning, Multitask Learning

Sumário

1 Introdução **1**
1.1 Definição do Problema 1
1.2 Perguntas de Pesquisa 2
1.2.1 A Hipótese Original 2
1.3 Contribuições 2
1.4 Organização deste Documento 3

2 Fundamentação Teórica **4**
2.1 Patologia Forense dos Ferimentos por Arma de Fogo 4
2.1.1 Ferimentos de Entrada e de Saída 4
2.1.2 Distância Médico-Legal do Disparo (MLSD) 5
2.2 Aprendizado Profundo em Visão Computacional 5
2.2.1 Redes Convolucionais, ResNet e Aprendizado por Transferência . . 5
2.2.2 Transformers de Visão 5
2.3 Redes de Kolmogorov-Arnold 6
2.3.1 Do Teorema da Representação às Camadas KAN 6
2.3.2 Arestas com B-Splines e Contagem de Parâmetros 6
2.3.3 KANs com Wavelets 7
2.4 Avaliação sem Vazamento 7
2.5 AUC das Probabilidades e das Classes 7
2.6 Aprendizado Multitarefa 8
2.7 Comparações Pareadas e Não Inferioridade 8

3 Trabalhos Relacionados **10**
3.1 IA na Patologia Forense 10
3.2 O Estudo de Lira et al. 10
3.2.1 O que o Artigo e o Código Público Dizem sobre a Partição 11
3.3 KANs como Cabeças de Classificação 12
3.4 Lacuna de Pesquisa 12

4 TransferKAN e o Desenho Experimental **13**
4.1 A Arquitetura TransferKAN 13
4.2 Hipóteses em Teste 14
4.3 Desenho Experimental 14

5 Metodologia **16**
5.1 Base de Dados 16
5.2 Dobras Agrupadas por Caso 17
5.3 Receita de Treino 19
5.4 Cabeças Comparadas na ResNet-152 20
5.5 Backbones no Mesmo Protocolo 20
5.6 Distância do Disparo 21
5.7 Reprodução da Partição de Lira et al. 21
5.8 Cabeças Wav-KAN 21
5.9 Uma Rede para as Duas Tarefas 22
5.10 Métricas 23
5.11 Estatística e Regras de Decisão Pré-Registradas 23
5.12 Ameaças à Validade 24

6 Resultados **26**
6.1 O Hold-Out de 2024 Vaza Casos 26
6.2 Entrada/Saída: Cabeças e Backbones 28
6.3 Distância do Disparo: Cabeças e Backbones 31
6.4 Comparação com os Números Publicados de Lira et al. 32
6.5 A TransferKAN e os Transformers 34
6.6 Cabeças Wav-KAN 35
6.7 Uma Rede para as Duas Tarefas 38
6.8 Resumo 40

7 Conclusões **41**
7.1 Respostas às Perguntas de Pesquisa 41
7.2 Limitações 42
7.3 Trabalhos Futuros 43

Referências **45**

Apêndice **48**

A Resultados no Formato de Lira et al. **49**

B Experimentos Exploratórios **51**

Anexo **51**

I Artigos Produzidos **53**

Lista de Figuras

4.1 A TransferKAN. Uma ResNet-152 pré-treinada no ImageNet extrai um vetor de 2.048 características, que passa por Dropout ($p = 0{,}5$) e por uma cabeça KAN de duas camadas $[2048, 128, K]$ com grade de tamanho 10 e splines cúbicas ($K = 2$ em entrada/saída, $K = 3$ na distância do disparo). Na ablação da cabeça, só o bloco laranja muda. 14
4.2 A variante multitarefa: uma ResNet-152 e um Dropout compartilhados por duas cabeças do mesmo tipo (KAN ou MLP-128). A perda é $L = L_{\mathrm{E/S}} + L_{\mathrm{dist}}$, com os ferimentos de saída fora do termo de distância. 15

5.1 Frequência da idade no momento do óbito na base FDCPUnBGunshotDB, por casos selecionados (a) e por imagens selecionadas (b). 18

6.1 AUC da ResNet-152 com a cabeça linear (a) e com a cabeça KAN (d), semente 42, em cada dobra agrupada por caso (círculos) e em cada partição reproduzida de Lira et al. (quadrados). Mesma rede, receita e semente; só a partição muda. 27
6.2 Análise de estabilidade da ResNet-152 de Lira et al. em k-folds agrupados, para o tipo de ferimento (a) e a distância do disparo (b); a caixa mais à esquerda (cinza) de cada painel é a acurácia. 29
6.3 Curvas ROC fora da dobra das quatro cabeças na ResNet-152 (entrada/saída; probabilidades médias das sementes 42–44; saída é a classe positiva). 30
6.4 Curvas ROC um-contra-o-resto fora da dobra das quatro cabeças na ResNet-152 para a distância do disparo (só entradas; probabilidades médias das sementes 42–44). A legenda traz a AUC um-contra-o-resto de cada cabeça. 32

6.5 AUC (média ± dp entre dobras) em função do número de parâmetros da cabeça (escala log) para as cabeças linear e MLP, a KAN spline e as cabeças Wav-KAN. W3 e W4 têm o número de parâmetros da W1 e aparecem deslocadas na horizontal só para não se sobreporem; W3–W5 usam uma única semente. 36

Lista de Tabelas

4.1 Cabeças de classificação comparadas sobre o mesmo backbone ResNet-152 (58.143.808 parâmetros) e a mesma receita. K = número de classes (2 em entrada/saída, 3 na MLSD). Parâmetros só da cabeça; sementes usadas em cada tarefa. 15

5.1 Composição das cinco dobras de teste (`StratifiedGroupKFold`, semente 42, grupos = caso, estratificação pelo rótulo de quatro classes). Encostado: imagens (casos). Nenhum caso aparece em mais de uma dobra. 17

6.1 Efeito da partição com todo o resto fixo (ResNet-152, mesma receita, semente 42). *Lira et al.*: o hold-out por imagem do código público de Lira et al. (estratificação iterativa sobre o número do caso e o rótulo) reproduzido em três partições; média ± dp entre as partições. *Agrupada*: as cinco dobras agrupadas por caso deste trabalho; média ± dp entre dobras. Vaz.: fração das imagens de teste cujo caso também tem imagens no treino. Δ = Lira − agrupada. 27

6.2 Classificação entrada/saída no protocolo único (5 dobras estratificadas e agrupadas por caso, mesma receita de duas fases, última época). Média ± dp entre dobras; cada dobra é a média das sementes de treino (coluna S). F1 é a média macro (precisão e revocação macro estão no Apêndice A); a AUC é calculada das probabilidades previstas. Min: minutos de treino por dobra numa NVIDIA L4. 28

6.3 Distância médico-legal do disparo (encostado, curta, distância; só entradas) no mesmo protocolo da Tabela 6.2. Média ± dp entre dobras; S = sementes de treino (Swin-B e MaxViT-T: só as sementes 42 e 43). AUC = AUC macro um-contra-o-resto, das probabilidades. Rev.: revocação por classe (média entre dobras); encostado tem de 4 a 13 imagens de teste por dobra e é só descritivo. 31

6.4 Entrada/saída: números publicados por Lira et al. [1] (Tabela 4) ao lado dos mesmos backbones no protocolo único deste trabalho. Os dois lados diferem em três pontos ao mesmo tempo: a partição (hold-out por imagem no código público deles × 5 dobras agrupadas por caso), a inicialização (quase tudo treinado do zero no código público deles × pesos do ImageNet) e a AUC (das classes previstas, AUC_c × das probabilidades, AUC_p). Só a AUC_c é calculada do mesmo jeito nos dois lados; a tabela compara pacotes de avaliação, não modelos. M = macro; nossos: média ± dp entre dobras. . 33
6.5 MLSD (só entradas): números publicados por Lira et al. [1] (Tabela 5) ao lado dos mesmos backbones no protocolo único deste trabalho. Os dois lados diferem em três pontos ao mesmo tempo: a partição (hold-out por imagem no código público deles × 5 dobras agrupadas por caso), a inicialização (quase tudo treinado do zero no código público deles × pesos do ImageNet) e a AUC (das classes previstas, AUC_c × das probabilidades, AUC_p). Só a AUC_c é calculada do mesmo jeito nos dois lados; a tabela compara pacotes de avaliação, não modelos. M = macro; nossos: média ± dp entre dobras. Nesta tarefa, prever sempre "distância" já dá acurácia de 0,854. 33
6.6 TransferKAN (ResNet-152 + KAN spline, sementes 42–44) contra os dois backbones transformer com cabeça linear, no protocolo único. ΔAUC nas predições fora da dobra (probabilidades médias das sementes); IC 95% por bootstrap pareado de casos (2.000 reamostragens); vence = dobras em que a TransferKAN tem a AUC maior. 34
6.7 Entrada/saída: cabeças Wav-KAN contra as cabeças (a)–(d), na mesma ResNet-152 e com a mesma receita. Média ± dp entre dobras (cada dobra é a média das S sementes); F1 macro; a AUC_{OOF} junta as predições fora da dobra. Min: minutos de treino por dobra (NVIDIA L4). Cabeça ms: forward + backward só da cabeça, num lote de 32 entradas aleatórias de 2048 dimensões. 35
6.8 MLSD (só entradas; AUC = macro um-contra-o-resto): cabeças Wav-KAN contra as cabeças (a)–(d), na mesma ResNet-152 e com a mesma receita. Média ± dp entre dobras (cada dobra é a média das S sementes); F1 macro; a AUC_{OOF} junta as predições fora da dobra. Min: minutos de treino por dobra (NVIDIA L4). Cabeça ms: forward + backward só da cabeça, num lote de 32 entradas aleatórias de 2048 dimensões. 36

6.9 Contrastes pré-registrados das cabeças Wav-KAN (Δ = W − referência) nas predições fora da dobra (probabilidades médias das sementes em comum); IC 95% por bootstrap pareado de casos (2.000 reamostragens). Margem de não inferioridade: −0,02 no limite inferior do IC do ΔAUC e do ΔF1. Superior: AUC maior em pelo menos 4/5 dobras e IC do ΔAUC acima de zero. Inferior: AUC maior em no máximo 1/5 dobras e IC do ΔAUC abaixo de zero. Inconclusivo: nenhum dos três. Vence: dobras em que W tem a AUC maior. 37

6.10 Uma ResNet-152 multitarefa (backbone compartilhado, uma cabeça por tarefa, $L = L_{\mathrm{E/S}} + L_{\mathrm{dist}}$, com as saídas fora de L_{dist}) contra o par de redes de tarefa única da ablação da cabeça, com as mesmas dobras e a mesma receita e sementes 42–44 nos dois lados. Média ± dp entre dobras; AUC das probabilidades (distância: macro um-contra-o-resto, só entradas); F1 macro; F1 de 4 classes: pipeline saída/encostado/curta/distância (secundário, descritivo). 38

6.11 Contrastes pré-registrados do estudo multitarefa (Δ = primeiro − segundo; MT = multitarefa, ST = par de redes de tarefa única), nas predições fora da dobra (probabilidades médias das sementes 42–44); IC 95% por bootstrap pareado de casos (2.000 reamostragens). Margem de não inferioridade: −0,02 no limite inferior do IC do ΔAUC. Pior: AUC maior em no máximo 1/5 dobras e IC do ΔAUC abaixo de zero; "dentro da margem": esse IC ainda fica acima de −0,02. Vence: dobras em que o primeiro sistema tem a AUC maior (o F1, nas linhas de 4 classes). 39

6.12 Custo para obter as duas saídas numa NVIDIA L4 (AMP fp16). Treino: minutos por dobra (tarefa única = soma das duas redes; média ± dp nas 15 unidades) e pico de memória do treino. Inferência: ms por imagem para obter as duas saídas (um forward na rede multitarefa, dois no par; 20 aquecimentos e 200 medidas por eventos CUDA, média ± dp) e pico de memória da inferência com lote 32. O tempo não depende dos pesos e foi medido em modelos recém-criados. 39

A.1 Entrada/saída no protocolo único, no formato de Lira et al. [1]: M = macro, m = micro, W = ponderada. Média entre dobras (os desvios-padrão estão nos arquivos de resultados do repositório); AUC das probabilidades previstas. Sementes como nas tabelas principais. 49

A.2 MLSD (só entradas) no protocolo único, no formato de Lira et al. [1]: M = macro, m = micro, W = ponderada. Média entre dobras (os desvios-padrão estão nos arquivos de resultados do repositório); AUC das probabilidades previstas. Sementes como nas tabelas principais. 50

B.1 Arquiteturas KAN exploratórias treinadas do zero (sem pré-treino no ImageNet) numa fase anterior deste trabalho. Usaram um único hold-out 80/20 por caso, entradas de 64 ou 128 px, lotes de 8 e receita própria, portanto *não* são comparáveis com nenhum número obtido no protocolo único. M = macro, m = micro, W = ponderada. 52

Capítulo 1

Introdução

1.1 Definição do Problema

As armas de fogo estão entre os instrumentos mais usados para cometer homicídios no mundo [2]. Por isso, ferimentos por arma de fogo são comuns no trabalho pericial, em locais de crime e em necropsias, e os peritos precisam determinar a sua natureza. Duas perguntas são centrais: se um ferimento é de entrada ou de saída e, nos de entrada, de que distância o disparo foi feito, a distância médico-legal do disparo (MLSD).

Em condições ideais, características como a forma e o tamanho do ferimento, a orla de escoriação e as bordas tornam relativamente fácil distinguir entrada de saída. Na prática, essas características podem estar parcialmente ausentes, sobrepostas ou alteradas pela putrefação, e o calibre, a munição, o ângulo, os anteparos intermediários e a região do corpo complicam a classificação mesmo para legistas experientes.

O aprendizado profundo transformou a análise de imagens médicas, mas o seu uso na prática forense ainda é limitado. Um dos principais obstáculos são os dados: as fotografias forenses são feitas com equipamentos diferentes, em condições variadas e na rotina dos locais de crime, o que torna a padronização impraticável e produz bases pequenas e desbalanceadas. Lira et al. [1] montaram a primeira grande base de fotografias reais de ferimentos por arma de fogo em locais de crime, a FDCPUnBGunshotDB, e avaliaram nela 59 arquiteturas de aprendizado profundo.

Este trabalho partiu de uma proposta específica: a TransferKAN, uma ResNet-152 pré-treinada no ImageNet cuja cabeça de classificação densa é trocada por uma Rede de Kolmogorov-Arnold (KAN) [3]. Uma versão anterior desta dissertação relatou que a TransferKAN superava os baselines de Lira et al. Ao reexaminar essa comparação, viu-se que ela misturava coisas diferentes. Os baselines publicados vieram de uma partição em que, segundo o código público do estudo, imagens do mesmo caso aparecem no treino e no teste, com a maioria das arquiteturas treinada do zero e a AUC calculada das

classes previstas. A TransferKAN, por sua vez, tinha sido avaliada com dobras agrupadas por caso, backbone pré-treinado, AUC das probabilidades e época escolhida no próprio conjunto de teste. Uma diferença entre números assim diz pouco sobre a cabeça KAN. Esta dissertação refaz a avaliação do zero, num protocolo único, e pergunta o que de fato se pode concluir.

1.2 Perguntas de Pesquisa

O trabalho se organiza em torno de cinco perguntas de pesquisa:

- **PP1:** O hold-out usado em 2024 infla os números relatados e, se sim, quanto, com todo o resto fixo?
- **PP2:** Num protocolo sem vazamento de casos, uma cabeça KAN melhora em relação a cabeças linear e MLP sobre o mesmo backbone pré-treinado?
- **PP3:** Como se comparam doze das arquiteturas avaliadas por Lira et al. no mesmo protocolo, e onde fica a TransferKAN entre elas?
- **PP4:** Uma KAN com outra base, wavelets em vez de splines, muda a resposta da PP2?
- **PP5:** Uma única rede com uma cabeça por tarefa pode substituir o par de redes usado hoje para entrada/saída e para a distância do disparo?

1.2.1 A Hipótese Original

A hipótese que motivou a TransferKAN era que trocar a cabeça MLP de uma ResNet-152 pré-treinada por uma KAN melhoraria a discriminação, medida pela AUC, nas duas tarefas, porque funções aprendíveis nas arestas modelariam melhor as fronteiras de decisão de classes forenses desbalanceadas. Essa hipótese não é descartada: ela vira a PP2 e é testada com uma ablação controlada e uma regra de decisão fixada antes dos experimentos (Seção 5.11). A resposta é negativa.

1.3 Contribuições

As contribuições desta dissertação são metodológicas e práticas:

- **Uma auditoria da partição de 2024.** O hold-out do código público de Lira et al. estratifica pelo caso em vez de agrupar por caso. Reproduzi-lo mostra que 98,7% (entrada/saída) e 98,4% (distância do disparo) das imagens de teste têm o seu caso

no treino e que, com a mesma rede e a mesma receita, essa partição infla a AUC em +0,034 em entrada/saída e de +0,155 a +0,158 na distância do disparo.

- **Um protocolo único sem vazamento.** Dobras agrupadas por caso, uma única receita de treino para todos os modelos, AUC das probabilidades, uma implementação congelada e com hash e regras de decisão escritas antes das rodadas. Nele foram treinadas e comparadas doze arquiteturas, cinco cabeças, cinco cabeças Wav-KAN e uma rede multitarefa.
- **Uma ablação controlada da cabeça, com KANs de splines e de wavelets.** A cabeça KAN da TransferKAN é equivalente às cabeças linear e MLP em entrada/saída e fica abaixo de uma MLP do mesmo tamanho na distância do disparo. As KANs com wavelets não mudam isso, e nenhuma das duas famílias é eficiente em parâmetros nem mais rápida neste cenário. A melhor arquitetura é a Swin-B, que supera a TransferKAN nas duas tarefas.
- **Uma rede para as duas tarefas, a meio custo.** Uma única ResNet-152 com duas cabeças tem cerca de metade dos parâmetros do par de redes e obtém as duas saídas duas vezes mais rápido. Ela é não inferior na distância do disparo e um pouco pior, de forma consistente, em entrada/saída, dentro da margem pré-registrada.

Os resultados também mostram onde está a dificuldade: os disparos encostados, com 42 imagens de 16 casos, quase nunca são reconhecidos quando o seu caso não está no treino.

1.4 Organização deste Documento

O Capítulo 2 apresenta as tarefas forenses, os componentes de aprendizado profundo, as KANs com bases de splines e de wavelets e os conceitos de avaliação usados ao longo do texto. O Capítulo 3 revisa os trabalhos relacionados, em particular o estudo de Lira et al. como descrito no artigo e como implementado no seu código público. O Capítulo 4 apresenta a TransferKAN, as hipóteses que ela representa e o desenho experimental. O Capítulo 5 descreve o protocolo único. O Capítulo 6 relata os resultados na ordem das perguntas de pesquisa, e o Capítulo 7 as responde e discute limitações e trabalhos futuros. O Apêndice A traz os resultados no formato de Lira et al., e o Apêndice B registra as arquiteturas KAN exploratórias treinadas do zero.

Capítulo 2

Fundamentação Teórica

Este capítulo traz a base necessária para o resto da dissertação: as tarefas forenses, os componentes de aprendizado profundo, as Redes de Kolmogorov-Arnold com bases de splines e de wavelets, e os conceitos de avaliação em que as conclusões se apoiam, a saber, a validação agrupada, as duas formas de calcular uma AUC, o aprendizado multitarefa e as comparações pareadas.

2.1 Patologia Forense dos Ferimentos por Arma de Fogo

Na medicina legal, a análise dos ferimentos por arma de fogo ajuda a reconstruir os fatos de um crime. Um projétil produz alterações morfológicas que dependem da arma, da munição e da distância do disparo [4, 5].

2.1.1 Ferimentos de Entrada e de Saída

Um ferimento de entrada costuma ter uma *orla de escoriação* (uma faixa de pele raspada), tecido invertido e forma regular, circular ou oval, conforme o ângulo de incidência. Um ferimento de saída costuma ter tecido evertido, forma irregular ou estrelada e nenhuma orla de escoriação nem resíduo do disparo, porque o projétil empurra o tecido de dentro para fora. Anteparos intermediários, desvios em ossos e alterações post mortem como a putrefação podem esconder esses sinais, de modo que a classificação visual depende muito da experiência do perito.

2.1.2 Distância Médico-Legal do Disparo (MLSD)

Nos ferimentos de entrada, a distância médico-legal do disparo é estimada pelos vestígios macroscópicos deixados pela combustão da pólvora e da espoleta [4]:

- **Encostado:** a boca do cano toca a pele. O ferimento costuma mostrar a marca da boca do cano e lacerações causadas pela expansão dos gases.
- **Curta distância:** o disparo é feito de perto (em geral a menos de cerca de 60 cm), e o ferimento mostra *tatuagem* (grãos de pólvora não queimados incrustados na pele) e fuligem.
- **Distância:** os resíduos da pólvora já não chegam à pele, e o ferimento mostra essencialmente a orla de escoriação.

Os ferimentos de saída não trazem informação de distância; por isso a tarefa de distância usa só as entradas.

2.2 Aprendizado Profundo em Visão Computacional

2.2.1 Redes Convolucionais, ResNet e Aprendizado por Transferência

As redes neurais convolucionais extraem características hierárquicas das imagens, de bordas nas primeiras camadas a formas complexas nas mais profundas. As redes residuais (ResNets) [6] acrescentam conexões de atalho que facilitam o treino de modelos muito profundos; a ResNet-152 tem 152 camadas e produz um vetor de 2.048 características antes da sua última camada. No aprendizado por transferência, uma rede pré-treinada numa base grande como o ImageNet [7] é reaproveitada como extratora de características e ajustada à tarefa de destino. Isso é útil sobretudo quando a base de destino é pequena, como nas imagens forenses. A última camada, que leva as características às classes, é chamada de *cabeça*; em geral é uma camada linear ou um pequeno perceptron de múltiplas camadas (MLP).

2.2.2 Transformers de Visão

Os transformers tratam uma imagem como uma sequência de blocos (*patches*) com autoatenção. Duas das arquiteturas avaliadas aqui são desse tipo: o Swin Transformer [8], que calcula a atenção dentro de janelas locais deslocadas e monta uma hierarquia de resoluções, e o MaxViT [9], que combina convoluções com atenção local e atenção global dilatada.

2.3 Redes de Kolmogorov-Arnold

2.3.1 Do Teorema da Representação às Camadas KAN

O teorema da representação de Kolmogorov-Arnold diz que qualquer função contínua de várias variáveis num domínio limitado pode ser escrita como uma composição finita de funções contínuas de uma variável e de somas. As Redes de Kolmogorov-Arnold (KANs) [3] transformam essa ideia numa camada treinável. Numa MLP, cada aresta tem um peso escalar e cada nó aplica uma não linearidade fixa. Numa camada KAN, cada aresta tem uma função de uma variável aprendível $\phi_{j,i}$, e o nó só soma:

$$x_j^{(l+1)} = \sum_{i=1}^{n_l} \phi_{j,i}^{(l)}\left(x_i^{(l)}\right). \tag{2.1}$$

Uma KAN $[n_0, n_1, n_2]$ tem duas dessas camadas; a cabeça da TransferKAN é $[2048, 128, K]$.

2.3.2 Arestas com B-Splines e Contagem de Parâmetros

Na KAN original e na implementação `efficient-kan` [10] usada aqui, cada função de aresta é a soma de um termo base e de uma spline:

$$\phi(x) = w_b \,\mathrm{SiLU}(x) + w_s \sum_{m=1}^{G+k} c_m B_m(x), \tag{2.2}$$

em que as B_m são B-splines de ordem k numa grade de G intervalos sobre $[-1, 1]$, estendida por k intervalos de cada lado. Com $G = 10$ e $k = 3$ há 13 coeficientes c_m por aresta, mais os pesos w_b e w_s: 15 parâmetros por aresta. Fora da grade estendida as B-splines se anulam, e a aresta se reduz ao seu termo base.

A contagem de parâmetros importa para as afirmações deste trabalho. O artigo da KAN defende que as KANs podem ser mais eficientes em parâmetros que as MLPs, sobretudo em tarefas científicas e simbólicas pequenas [3]. Como cabeça de classificação sobre 2.048 características, porém, uma KAN é grande: a cabeça $[2048, 128, 2]$ tem $15 \times (2048 \times 128 + 128 \times 2) = 3.936.000$ parâmetros, enquanto uma MLP com as mesmas larguras tem 262.530. Saber se uma cabeça KAN é mais eficiente é, portanto, uma questão empírica, testada neste trabalho contra MLPs do mesmo tamanho.

2.3.3 KANs com Wavelets

A Wav-KAN [11] troca a spline por uma wavelet com escala s e translação τ aprendíveis em cada aresta:

$$\phi(x) = w_\psi \, \psi\Big(\frac{x-\tau}{s}\Big) + w_b \, \mathrm{SiLU}(x), \tag{2.3}$$

seguida de normalização em lote da saída da camada. Isso usa quatro parâmetros por aresta em vez de quinze. Três wavelets-mãe são usadas aqui, escritas a menos de constantes de normalização: o chapéu mexicano $\psi(t) = (1 - t^2)\, e^{-t^2/2}$, a derivada de gaussiana $\psi(t) = -t\, e^{-t^2/2}$ e a Morlet $\psi(t) = \cos(\omega_0 t)\, e^{-t^2/2}$, com $\omega_0 = 5$. Em princípio, a escala e a translação aprendíveis poderiam adaptar cada aresta à faixa da sua entrada; se isso acontece é verificado na Seção 6.6.

2.4 Avaliação sem Vazamento

Há vazamento de dados quando informação que não estaria disponível no momento da predição chega ao treino de um modelo, de modo que o desempenho no teste superestima o desempenho em dados novos [12]. Uma forma comum aparece em dados agrupados: quando várias observações vêm da mesma unidade (um paciente, um local, um caso), as observações da mesma unidade se parecem mais entre si que com o resto. Se elas são divididas entre treino e teste, o modelo pode reconhecer a unidade em vez de aprender a tarefa [13]. O remédio é a validação agrupada: cada grupo fica inteiro no treino ou inteiro no teste.

Na base de ferimentos, um caso costuma ter várias fotografias do mesmo ferimento ou de ferimentos da mesma vítima. A unidade de avaliação é, portanto, o caso. A validação cruzada k-fold agrupada atribui casos inteiros às dobras; a k-fold estratificada e agrupada faz o mesmo mantendo proporções de classes parecidas entre as dobras. Estratificar *pelo* identificador do caso é diferente: a estratificação iterativa [14] sobre o número do caso tenta pôr em cada subconjunto uma parte proporcional das imagens de cada caso, e por isso espalha de propósito cada caso entre treino e teste. A diferença entre agrupar e estratificar pelo caso está no centro da Seção 6.1.

2.5 AUC das Probabilidades e das Classes

A curva ROC traça a taxa de verdadeiros positivos contra a taxa de falsos positivos à medida que o limiar de decisão sobre um escore contínuo varia, e a área sob ela (AUC) é igual à probabilidade de um exemplo positivo escolhido ao acaso receber um escore maior que um negativo escolhido ao acaso [15]. Ela mede quão bem o modelo ordena

os exemplos, independentemente do limiar. Com mais de duas classes, a AUC macro um-contra-o-resto é a média das AUC de cada classe contra as demais.

Se a AUC é calculada a partir dos rótulos previstos em vez dos escores, há um único limiar e a "curva" ROC tem um só ponto interior. A área passa a ser

$$\mathrm{AUC}_c = \frac{\mathrm{TPR} + \mathrm{TNR}}{2}, \tag{2.4}$$

a média entre sensibilidade e especificidade, que no caso binário é igual à acurácia balanceada e à revocação macro. A AUC_c depende do limiar e costuma ser bem menor que a AUC das probabilidades do mesmo modelo. Nesta dissertação, AUC significa sempre a AUC das probabilidades; a AUC_c é calculada só para comparar com as tabelas de Lira et al., que a relatam (Capítulo 3).

2.6 Aprendizado Multitarefa

O aprendizado multitarefa treina um único modelo em várias tarefas relacionadas, para que elas compartilhem uma representação [16, 17]. Na forma mais comum, o compartilhamento rígido de parâmetros, um único backbone alimenta uma cabeça por tarefa, e a perda é uma soma ponderada das perdas das tarefas. O compartilhamento pode ajudar quando as tarefas usam características parecidas e pode atrapalhar quando uma tarefa domina a representação comum. Quando um rótulo não existe para alguns exemplos, como a distância nos ferimentos de saída, esses exemplos ficam fora do termo correspondente da perda. Um backbone compartilhado também tem um efeito prático direto: as duas saídas vêm de um único passo para a frente em vez de dois.

2.7 Comparações Pareadas e Não Inferioridade

Quando dois modelos são avaliados nas mesmas imagens de teste, a diferença entre eles deve ser estimada de forma pareada, já que os dois são afetados pelas mesmas imagens difíceis e fáceis. Um bootstrap não paramétrico [18] reamostra as unidades de avaliação com reposição e recalcula a diferença em cada reamostra; os percentis das diferenças reamostradas dão um intervalo de confiança. Como as imagens de um mesmo caso são dependentes, as unidades reamostradas aqui são os casos, e não as imagens.

Uma pergunta de superioridade quer saber se o intervalo da diferença fica acima de zero. Uma pergunta de *não inferioridade* pede algo mais fraco: se um modelo não é pior que uma referência por mais de uma margem δ fixada de antemão, isto é, se o limite inferior do intervalo da diferença fica acima de $-\delta$. A não inferioridade é a pergunta

adequada quando o candidato tem outra vantagem, como menos parâmetros ou menor custo, e a margem precisa ser fixada antes de ver os resultados.

Capítulo 3

Trabalhos Relacionados

Este capítulo revisa os trabalhos de aprendizado profundo aplicados a ferimentos por arma de fogo, descreve em detalhe o estudo de Lira et al. [1], que fornece a base de dados e os baselines desta dissertação, e revisa o uso de KANs como cabeças de classificação. Ele termina com a lacuna que motiva este trabalho.

3.1 IA na Patologia Forense

A inteligência artificial entrou na ciência forense mais devagar que na medicina clínica. Os primeiros estudos de ferimentos por arma de fogo usaram carcaças de animais, como porcos, para simular a pele humana [19]. Esses cenários controlados permitiram acurácias altas, mas não têm a variabilidade, a contaminação e as alterações morfológicas dos casos reais. Cheng et al. [20] treinaram classificadores com fotografias de necropsia de ferimentos de entrada e saída, obtidas nas condições relativamente controladas da necropsia, e não trataram da distância do disparo.

3.2 O Estudo de Lira et al.

Lira et al. [1] montaram a FDCPUnBGunshotDB, com 2.551 fotografias (1.883 ferimentos de entrada e 668 de saída) de 489 casos da Polícia Civil do Distrito Federal, e avaliaram 59 arquiteturas de aprendizado profundo do TorchVision em duas tarefas: entrada contra saída e a distância médico-legal do disparo (encostado, curta distância, distância). As tabelas de hold-out deles (Tabelas 4 e 5 do artigo) põem a ResNet-152 em primeiro lugar nas duas tarefas. Em entrada/saída ela tem acurácia de 0,869 e AUC macro de 0,821, os "86,90%" e "82,09%" do resumo. Na tarefa de distância ela tem acurácia de 0,925, AUC macro de 0,733 e AUC micro de 0,944; a "AUC de até 94,36%" do resumo é a média micro. O artigo também relata uma análise k-fold da ResNet-152 em boxplots (a Figura 4 deles,

reproduzida na Figura 6.2); em entrada/saída, a mediana da acurácia entre as dobras é de cerca de 0,70.

3.2.1 O que o Artigo e o Código Público Dizem sobre a Partição

O artigo descreve as duas avaliações como separadas por caso: as imagens de um caso usado no treino não seriam usadas no teste, e o k-fold usaria dobras estratificadas e agrupadas com os casos como grupos [1]. O código público do estudo (`leguwoi` [21], commit `83d82f1`) concorda quanto ao k-fold, que usa `StratifiedGroupKFold` com o número do caso como grupo, mas não quanto ao hold-out. A função `iterative_split` aplica estratificação iterativa [14] às colunas *número do caso* e *rótulo*, ou seja, ela *estratifica* pelo caso em vez de agrupar por caso. Estratificar pelo número do caso espalha as imagens de cada caso entre treino e teste. Reproduzindo essa função com os dados distribuídos, 98,7% das imagens de teste de entrada/saída e 98,4% das imagens de teste de distância têm o seu caso no treino (Seção 6.1). Não é possível saber se as tabelas publicadas foram produzidas exatamente por essa versão do código; as afirmações desta dissertação sobre o hold-out se referem ao código público.

Três outros aspectos do código público importam para comparar números:

- **AUC das classes previstas.** A AUC é calculada com `roc_auc_score` sobre os rótulos previstos, e não sobre probabilidades. Com um único limiar, a AUC macro é igual à média entre revocação e especificidade, que no caso binário é a revocação macro. Isso aparece na Tabela 4 deles, em que a AUC macro de cada modelo é igual à sua revocação macro (0,821 e 0,821 na ResNet-152).
- **Inicialização.** Só as ResNets partem dos pesos do ImageNet, e a primeira convolução delas é trocada por uma camada iniciada ao acaso; as demais famílias são treinadas do zero.
- **Identidade do caso.** Os casos são identificados pelo número sem o ano, o que junta casos de anos diferentes (417 grupos em vez de 486).

Essas observações não diminuem o valor da base nem do estudo, que é o primeiro a classificar ferimentos por arma de fogo de locais de crime reais nessa escala. Elas significam, porém, que os números das Tabelas 4 e 5 medem uma grandeza diferente da avaliação agrupada por caso adotada aqui, e a versão anterior desta dissertação comparou as duas como se fossem a mesma.

3.3 KANs como Cabeças de Classificação

As Redes de Kolmogorov-Arnold [3] põem funções univariadas aprendíveis nas arestas da rede, em vez de ativações fixas nos nós (Seção 2.3). O artigo original defende ganhos de precisão e de eficiência de parâmetros sobretudo em tarefas científicas e simbólicas pequenas. Em visão, as KANs foram usadas tanto dentro das convoluções, como nas KANs convolucionais da `torch-conv-kan` [22], quanto como cabeças sobre extratores pré-treinados, como na TransferKAN. Várias bases foram propostas para as funções das arestas, entre elas as B-splines da KAN original, implementadas de forma eficiente na `efficient-kan` [10], e as wavelets da Wav-KAN [11]. Quando uma cabeça KAN é comparada com uma cabeça densa, a comparação muitas vezes muda ao mesmo tempo o backbone, a receita de treino ou o número de parâmetros, o que dificulta atribuir uma diferença à cabeça em si.

3.4 Lacuna de Pesquisa

Três lacunas motivam este trabalho. Primeiro, os números disponíveis para esta base vêm de um hold-out em que, segundo o código público, imagens do mesmo caso aparecem no treino e no teste, com a maioria das arquiteturas treinada do zero e a AUC calculada das classes. Nenhum estudo tinha avaliado as arquiteturas num protocolo comum sem vazamento de casos. Segundo, a afirmação de que uma cabeça KAN melhora em relação a uma cabeça densa sobre o mesmo backbone pré-treinado não tinha sido testada com uma ablação controlada, que mantivesse fixos o backbone, a receita e o orçamento de parâmetros. Terceiro, as duas tarefas forenses são aprendidas por redes separadas, embora usem as mesmas imagens. Esta dissertação trata das três lacunas com um protocolo único (Capítulo 5).

Capítulo 4

TransferKAN e o Desenho Experimental

Este capítulo apresenta a TransferKAN, o modelo que este trabalho se propôs a avaliar, as hipóteses que a motivaram e o desenho experimental usado para testá-las. O desenho isola a contribuição de cada componente: a cabeça, o backbone, a partição e o número de tarefas.

4.1 A Arquitetura TransferKAN

A TransferKAN[1] combina um extrator de características convolucional pré-treinado no ImageNet com uma Rede de Kolmogorov-Arnold (KAN) como cabeça de classificação. Ela tem três estágios (Figura 4.1):

1. **Extrator de características:** uma ResNet-152 [6] com os pesos do ImageNet [7] e sem a sua última camada totalmente conectada. Para uma imagem de 224×224, ela produz um vetor de 2.048 características.
2. **Regularização:** Dropout com $p = 0{,}5$ sobre esse vetor.
3. **Cabeça KAN:** uma KAN de duas camadas, $[2048, 128, K]$, com $K = 2$ saídas em entrada/saída e $K = 3$ na distância do disparo. Cada aresta tem uma função aprendível formada por um termo base SiLU e uma B-spline cúbica numa grade de tamanho 10 (Seção 2.3), implementada com a `efficient-kan` [10]. A cabeça tem 3.936.000 parâmetros em entrada/saída e 3.937.920 na distância.

[1] O artigo curto derivado deste trabalho para o SIBGRAPI 2026 chama o mesmo modelo de TransKAN.

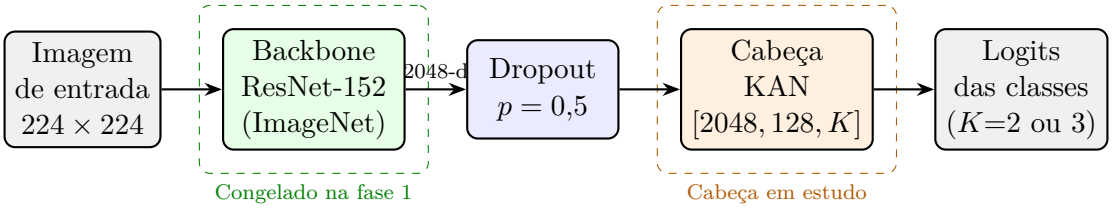


Figura 4.1: A TransferKAN. Uma ResNet-152 pré-treinada no ImageNet extrai um vetor de 2.048 características, que passa por Dropout ($p = 0{,}5$) e por uma cabeça KAN de duas camadas $[2048, 128, K]$ com grade de tamanho 10 e splines cúbicas ($K = 2$ em entrada/saída, $K = 3$ na distância do disparo). Na ablação da cabeça, só o bloco laranja muda.

4.2 Hipóteses em Teste

A TransferKAN foi motivada por duas afirmações sobre KANs usadas como cabeças de classificação. Na versão anterior deste trabalho, elas foram apresentadas como vantagens; aqui são tratadas como hipóteses, cada uma com o resultado que a sustentaria:

- **H1, melhor discriminação:** como as funções das arestas são aprendidas, uma cabeça KAN traçaria fronteiras de decisão mais finas que uma cabeça MLP sobre as mesmas características, sobretudo para as classes minoritárias. Isso seria sustentado por uma AUC maior que a da melhor cabeça MLP no mesmo backbone, pela regra pré-registrada da Seção 5.11 (desfecho A).
- **H2, eficiência de parâmetros:** uma cabeça KAN chegaria ao mesmo desempenho com menos parâmetros. Isso seria sustentado por uma cabeça KAN que vencesse uma cabeça MLP com o mesmo número de parâmetros. Note-se que a cabeça da TransferKAN não é pequena: com 15 parâmetros por aresta, ela tem 3,94 milhões de parâmetros, 15 vezes os de uma MLP com as mesmas larguras (262.530).

4.3 Desenho Experimental

Ablação da cabeça. Para testar H1 e H2, a ResNet-152, as dobras e a receita ficam fixas e só a cabeça muda (Tabela 4.1). A cabeça linear (a) é a referência mais simples. A MLP-128 (b) tem as mesmas larguras da KAN. A MLP isoparamétrica (c) tem praticamente o mesmo número de parâmetros da KAN, para que uma diferença entre (c) e (d) não possa ser atribuída ao tamanho. A KAN-8 (e) dá a uma KAN o orçamento de parâmetros de (b). Para verificar se a conclusão depende da base de splines, as cabeças Wav-KAN [11] W1–W5 trocam as B-splines por wavelets: a W1 mantém a topologia de (d), a W2 o orçamento de (b) e a W5 o orçamento de (d), e a W3 e a W4 mudam a wavelet.

Tabela 4.1: Cabeças de classificação comparadas sobre o mesmo backbone ResNet-152 (58.143.808 parâmetros) e a mesma receita. K = número de classes (2 em entrada/saída, 3 na MLSD). Parâmetros só da cabeça; sementes usadas em cada tarefa.

			Parâmetros da cabeça		Sementes		
Id	Cabeça	Estrutura	E/S	MLSD	E/S	MLSD	Papel
(a)	Linear	Linear$(2048, K)$	4.098	6.147	42–44	42–44	referência
(b)	MLP-128	$[2048, 128, K]$, ReLU	262.530	262.659	42–44	42–44	referência
(c)	MLP isoparamétrica	$[2048, 1919, K]$, ReLU	3.935.871	3.937.791	42–44	42–44	mesmo orçamento de (d)
(d)	KAN spline = TransferKAN	$[2048, 128, K]$, $G = 10$, $k = 3$	3.936.000	3.937.920	42–44	42–44	objeto de estudo
(e)	KAN-8	$[2048, 8, 2]$, $G = 10$, $k = 3$	246.000	—	42	—	sensibilidade
W1	Wav-KAN, chapéu mexicano	$[2048, 128, K]$	1.049.860	1.050.374	42–44	42–44	topologia de (d)
W2	Wav-KAN, chapéu mexicano	$[2048, 32, K]$	262.468	262.598	42–44	42–44	mesmo orçamento de (b)
W3	Wav-KAN, DoG	$[2048, 128, 2]$	1.049.860	—	42	—	sensibilidade
W4	Wav-KAN, Morlet	$[2048, 128, 2]$	1.049.860	—	42	—	sensibilidade
W5	Wav-KAN, chapéu mexicano	$[2048, 480, 2]$	3.936.964	—	42	—	mesmo orçamento de (d)

Backbones. Doze arquiteturas do estudo de Lira et al. [1], entre elas a ResNet-152 e dois transformers, são retreinadas com a mesma receita e cabeça linear. Isso mostra onde a TransferKAN fica entre arquiteturas treinadas da mesma forma. Como todos os backbones partem dos pesos do ImageNet, o efeito do pré-treino não é isolado (Seção 6.4).

Partição. O hold-out do código público de Lira et al. é reproduzido e comparado com as dobras agrupadas por caso, com todo o resto fixo, para medir quanto só a partição muda os números.

Uma rede para as duas tarefas. Por fim, uma única ResNet-152 com duas cabeças, uma por tarefa, é comparada com o par de redes de tarefa única (Figura 4.2). Essa variante muda o número de redes e mantém o tipo de cabeça; ela mede, portanto, o custo e o desempenho de compartilhar o backbone.

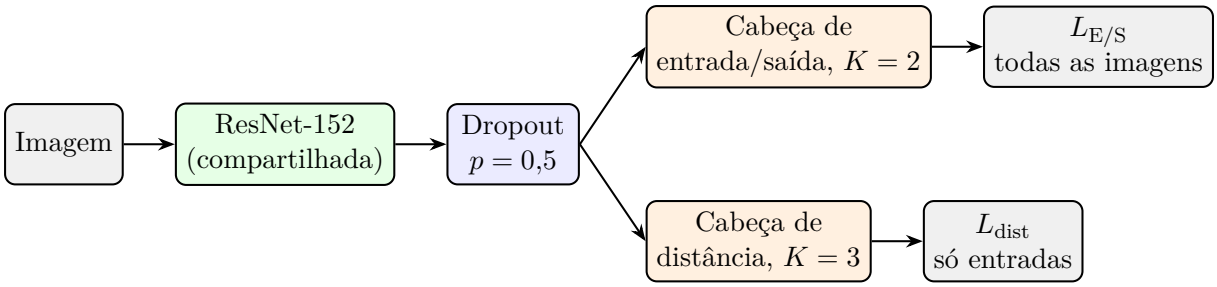


Figura 4.2: A variante multitarefa: uma ResNet-152 e um Dropout compartilhados por duas cabeças do mesmo tipo (KAN ou MLP-128). A perda é $L = L_{\mathrm{E/S}} + L_{\mathrm{dist}}$, com os ferimentos de saída fora do termo de distância.

Capítulo 5

Metodologia

Este capítulo descreve o protocolo único de avaliação sob o qual todos os modelos deste trabalho foram treinados e testados. Todos os modelos usam as mesmas imagens, as mesmas cinco dobras agrupadas por caso, a mesma receita de treino, as mesmas métricas e o mesmo procedimento estatístico; de um experimento para outro muda só o componente em estudo (a cabeça, o backbone, a partição ou o número de tarefas). O protocolo foi escrito como um único módulo Python (`protocolo_comum.py`, versão 1.0.0, SHA-256 `b7cd9bac...`) e congelado antes da primeira rodada de treino. Os experimentos posteriores (distância do disparo, reprodução da partição de Lira et al., cabeças Wav-KAN e rede multitarefa) entraram como plugins que registram novas cabeças, configurações ou perdas sem editar o módulo. Cada rodada grava os hashes do módulo, do plugin e do arquivo de dobras, o que permite conferir que todos os números vêm do mesmo código.

5.1 Base de Dados

As imagens vêm da FDCPUnBGunshotDB [1], uma coleção de fotografias de ferimentos por arma de fogo feitas em locais de crime e em necropsias pela Polícia Civil do Distrito Federal (PCDF). A base não tem licença de redistribuição e o seu README exige citar Lira et al. [1]; ela foi clonada num commit fixo (`f679389`) em cada sessão [23], e nenhuma imagem nem cache de imagens saiu das sessões de treino.

Os rótulos são lidos da estrutura de pastas. A versão usada tem 2.554 imagens de 486 casos: 1.883 ferimentos de entrada e 671 de saída. As 1.883 entradas têm também o rótulo da distância médico-legal do disparo (MLSD): 1.609 a distância, 232 a curta distância e 42 encostados; as 42 imagens de encostado vêm de apenas 16 casos. Lira et al. descrevem 2.551 imagens (1.883 entradas e 668 saídas) de 489 casos [1]. A diferença nas imagens vem de três imagens de saída que estão nas pastas, mas não no CSV distribuído com a base; o CSV traz 2.551 imagens de 485 casos. Os 489 casos do artigo não são reproduzidos pelos

dados distribuídos. Além disso, aqui o caso é identificado pelo ano e pelo número (os nove primeiros caracteres do nome do arquivo), enquanto o código de Lira et al. usa o número sem o ano, o que junta 56 números que aparecem em mais de um ano (417 grupos em vez de 486) [21]. Uma imagem de saída tem uma distância no CSV; vale o rótulo da pasta (saída). A distribuição de idade das vítimas aparece na Figura 5.1.

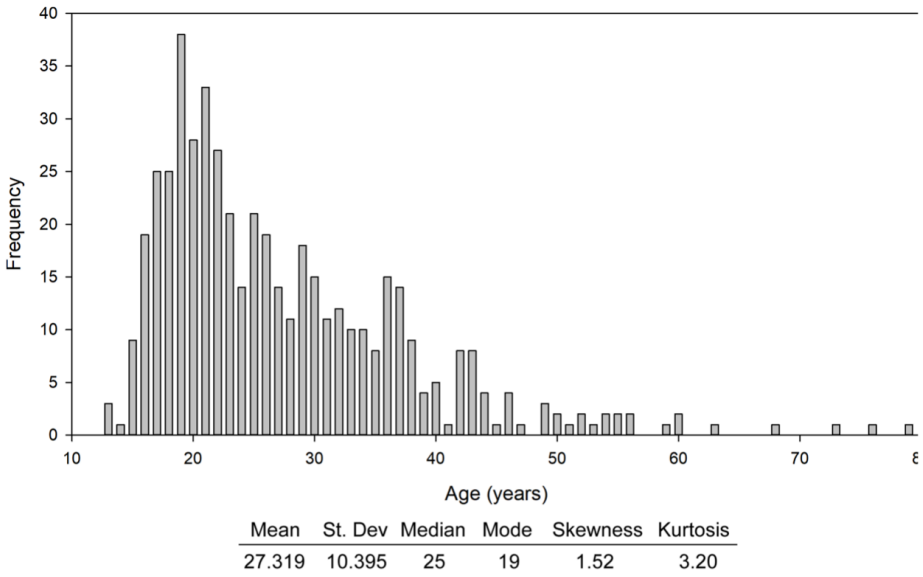
5.2 Dobras Agrupadas por Caso

As fotografias de um mesmo caso (muitas vezes vários ângulos do mesmo ferimento, ou ferimentos da mesma vítima) são muito correlacionadas. Se imagens de um caso caem no treino e no teste, o teste deixa de medir a generalização para casos novos (Seção 2.4). Por isso, todos os experimentos usam um único conjunto de cinco dobras em que cada caso pertence a exatamente uma dobra. As dobras foram geradas uma vez com o `StratifiedGroupKFold` do scikit-learn [24] (cinco dobras, embaralhadas, semente 42) sobre a lista de imagens ordenada pelo caminho, com grupos dados pelo caso e estratificação por um rótulo de quatro classes (saída, encostado, curta, distância), para equilibrar as duas tarefas ao mesmo tempo. Uma regra de composição foi fixada antes de gerar as dobras: cada dobra de teste precisa ter pelo menos dois casos de encostado e pelo menos uma imagem de cada classe; se a semente 42 falhasse, seria usada a primeira semente ≥ 43 que passasse. A semente 42 passou. A Tabela 5.1 mostra o resultado; a fração de saídas por dobra fica entre 24,5% e 28,9% (26,3% no total).

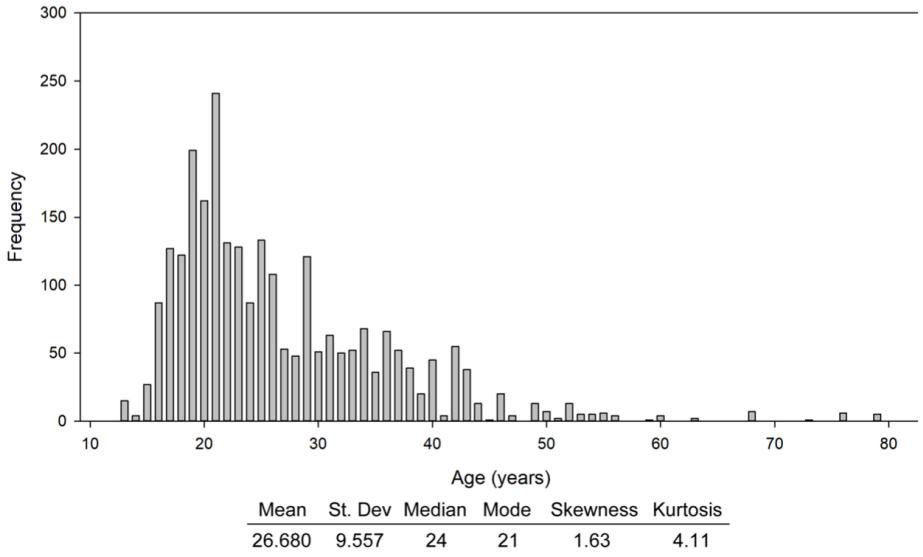
Tabela 5.1: Composição das cinco dobras de teste (`StratifiedGroupKFold`, semente 42, grupos = caso, estratificação pelo rótulo de quatro classes). Encostado: imagens (casos). Nenhum caso aparece em mais de uma dobra.

Dobra	Imagens	Casos	Saídas	Encostado	Curta	Distância
1	506	96	146	4 (2)	53	303
2	459	95	118	10 (4)	25	306
3	531	99	133	13 (5)	43	342
4	538	100	132	11 (3)	61	334
5	520	96	142	4 (2)	50	324
Total	2.554	486	671	42 (16)	232	1.609

A tarefa de distância usa as mesmas dobras restritas às entradas. Assim, nenhum caso atravessa dobras em nenhuma das tarefas, e as duas tarefas podem ser comparadas e combinadas imagem a imagem.



(a) Selected cases.



(b) Selected images.

t time of death

Figura 5.1: Frequência da idade no momento do óbito na base FDCPUnBGunshotDB, por casos selecionados (a) e por imagens selecionadas (b) (Fonte: [1]).

5.3 Receita de Treino

Todos os modelos (cabeças, backbones, cabeças Wav-KAN e rede multitarefa) são treinados com a receita do notebook original da TransferKAN, agora aplicada a todos eles:

- **Modelo:** um backbone do torchvision [25] com os pesos padrão do ImageNet [7], seguido de achatamento, Dropout ($p = 0{,}5$) e a cabeça.
- **Fase 1 (épocas 1–15):** backbone congelado (as estatísticas da normalização em lote continuam sendo atualizadas, como no código original); só os parâmetros novos são otimizados, com AdamW [26] (taxa de aprendizado 10^{-3}, decaimento de pesos 10^{-2}) e decaimento cosseno [27] em 15 épocas.
- **Fase 2 (épocas 16–60):** a rede inteira é treinada com AdamW (taxa 10^{-5}, decaimento 10^{-3}) e decaimento cosseno em 45 épocas.
- **Lotes e perda:** lotes de 32 imagens, descartando o último lote incompleto; entropia cruzada com pesos de classe $n/(K\,n_c)$ calculados na parte de treino de cada dobra (K classes, n_c imagens da classe c).
- **Sem validação interna e sem escolha de época:** toda a parte de treino da dobra é usada no treino, e o modelo avaliado é o da época 60. A dobra de teste é avaliada uma única vez.
- **Aumento de dados** (só no treino, Albumentations [28] 2.0.8, com os valores que de fato rodaram no notebook original): redimensionamento para 224×224; espelhamentos horizontal e vertical ($p = 0{,}5$ cada); deslocamento, escala e rotação (deslocamento 0,05, escala 0,1, rotação até 30°, $p = 0{,}5$); CLAHE (limite 2,0, blocos de 8×8, $p = 0{,}3$); transformação elástica ($\alpha = 1$, $\sigma = 50$, $p = 0{,}3$); ruído gaussiano (desvio-padrão entre 0,2 e 0,44 da faixa de intensidade, $p = 0{,}2$); variação de cor (brilho, contraste e saturação 0,2, matiz 0,05, $p = 0{,}5$); normalização do ImageNet. As imagens de teste são só redimensionadas e normalizadas.
- **Sementes:** as dobras são fixas; a semente de treino (42, 43 ou 44) controla a inicialização da cabeça, as máscaras do dropout, a ordem dos lotes e o aumento de dados.

O notebook original foi escrito para uma interface antiga da Albumentations; dois dos seus argumentos (`alpha_affine` e `var_limit`) são descartados sem erro pela versão 2. Por isso, a transformação elástica e o ruído gaussiano rodaram com os valores listados acima, e não com os escritos no notebook. O protocolo fixa explicitamente esses valores efetivos,

de modo que o aumento de dados é idêntico ao que produziu os resultados originais e é o mesmo para todos os modelos.

Precisão numérica e hardware. Todas as rodadas comparáveis usaram uma GPU NVIDIA L4 no Google Colab. O backbone roda em precisão mista automática (fp16) [29] e as cabeças sempre em fp32. A precisão mista só foi adotada depois de uma checagem definida antes de qualquer rodada: a TransferKAN foi treinada na dobra 1 com a semente 42 em fp32 e em precisão mista, e a precisão mista seria aceita se a acurácia mudasse no máximo 2 pontos percentuais e a AUC no máximo 0,015. A acurácia foi de 84,98% em fp32 e 84,39% em precisão mista, e a AUC de 0,9078 e 0,9076, enquanto o tempo por dobra caiu de 14,9 para 8,1 minutos; a precisão mista foi então usada em todos os modelos.

5.4 Cabeças Comparadas na ResNet-152

A ablação da cabeça mantém fixos o backbone ResNet-152 (58.143.808 parâmetros), as dobras e a receita, e muda só a camada que leva as 2.048 características às classes. As cinco cabeças, com as contagens de parâmetros, estão na Tabela 4.1 (Capítulo 4): (a) uma camada linear; (b) uma MLP com 128 unidades ocultas; (c) uma MLP cuja largura oculta (1.919) lhe dá praticamente o mesmo número de parâmetros da KAN (3,94 milhões); (d) a cabeça KAN da TransferKAN, $[2048, 128, K]$, com grade de tamanho 10 e splines cúbicas, implementada com a `efficient-kan` [10] (15 parâmetros por aresta: 13 coeficientes de B-spline, um peso da base e uma escala da spline); e (e) uma KAN pequena, $[2048, 8, 2]$, com aproximadamente o orçamento de (b). As cabeças (a)–(d) foram treinadas com as sementes 42, 43 e 44 nas duas tarefas; a cabeça (e), só com a semente 42 e só em entrada/saída.

5.5 Backbones no Mesmo Protocolo

Para situar a TransferKAN entre as arquiteturas avaliadas por Lira et al., doze das 59 arquiteturas da Tabela 4 deles foram retreinadas com a mesma receita. Elas cobrem redes convolucionais de 0,3 a 134 milhões de parâmetros e duas arquiteturas baseadas em transformers, e incluem o melhor modelo deles, a ResNet-152 [6] com cabeça linear, que é a cabeça (a). As outras onze são AlexNet [30], MobileNetV2 [31], MNASNet 1.3 [32], ShuffleNetV2 $\times 0.5$ [33], SqueezeNet 1.0 [34], DenseNet-169 [35], MaxViT-T [9], Swin-B [8], EfficientNetV2-L [36], VGG-16 [37] e RegNetY-16GF [38]. O catálogo segue o código de Lira et al. [21]: os mesmos construtores do torchvision e o mesmo ponto de troca da última camada. Há dois desvios declarados: todos os backbones partem dos pesos padrão

do ImageNet (no código público de Lira et al. só as ResNets são pré-treinadas, e a primeira convolução delas é trocada por uma camada iniciada ao acaso), e a primeira convolução é mantida. A nova última camada é um Dropout(0,5) seguido de uma camada linear (uma convolução 1×1 na SqueezeNet). A EfficientNetV2-L, pré-treinada a 480 px, roda a 224 px como as demais. A Swin-B e a MaxViT-T foram treinadas com as sementes 42, 43 e 44 em entrada/saída e com as sementes 42 e 43 na distância do disparo; os demais backbones, só com a semente 42.

5.6 Distância do Disparo

A tarefa de distância (encostado, curta distância, distância) usa só os ferimentos de entrada, porque as saídas não trazem informação de distância. Para a dobra de teste k, a rede é treinada com as entradas das outras quatro dobras e avaliada nas entradas da dobra k. As cabeças têm $K = 3$ saídas, e todo o resto (receita, sementes, grade 10 da KAN) é igual ao da tarefa de entrada/saída. O modelo de distância anterior deste trabalho, treinado numa fase só, com grade 5 e com a época escolhida no próprio teste, foi descartado e não é usado em nenhum ponto desta dissertação.

5.7 Reprodução da Partição de Lira et al.

Para medir quanto só a partição muda os resultados, o hold-out de Lira et al. foi reproduzido a partir do código público deles (`iterative_split` do `leguwoi`, commit `83d82f1`) [21]. Essa função separa as imagens em 80/20 com estratificação iterativa [14] (`IterativeStratification` do scikit-multilearn 0.2.0, ordem 2) sobre duas colunas, o número do caso e o rótulo. Estratificar pelo número do caso espalha as imagens de cada caso entre treino e teste, em vez de mantê-las juntas. A função não fixa semente, então três partições foram geradas com as sementes 42, 43 e 44 sobre as 2.551 imagens do CSV distribuído (entrada/saída: 2.074 imagens de treino e 477 de teste; distância: 1.520 e 363 entradas). A ResNet-152 com as cabeças (a) e (d) foi treinada em cada partição com a receita acima (semente 42) e comparada com os mesmos modelos nas dobras agrupadas por caso (semente 42). Isso reproduz o método do código público, e não necessariamente a partição exata usada nas tabelas publicadas, que não pode ser recuperada.

5.8 Cabeças Wav-KAN

Para testar se outra família de KAN muda a conclusão da ablação da cabeça, foram acrescentadas cabeças KAN com wavelets (Wav-KAN) [11]. Cada camada segue a

`WavKANLayer` da `torch-conv-kan` [22]: cada aresta tem uma escala e uma translação aprendíveis, um peso da wavelet e um peso para um ramo base SiLU, e a saída da camada passa por normalização em lote. A implementação usada aqui foi conferida contra a `torch-conv-kan` (commit `b412a3b`) e deu saídas e gradientes idênticos em CPU e em GPU. As cabeças têm duas camadas, $[2048, h, K]$, e $8202h + 4$ parâmetros para $K = 2$. Foram treinadas cinco configurações (Tabela 4.1): W1, chapéu mexicano com $h = 128$ (a topologia da cabeça (d), com 3,7 vezes menos parâmetros); W2, chapéu mexicano com $h = 32$ (o orçamento da MLP (b)); W3 e W4, wavelets derivada de gaussiana e Morlet com $h = 128$ (sensibilidade à wavelet); e W5, chapéu mexicano com $h = 480$ (o orçamento de (d)). O chapéu mexicano foi fixado de antemão para os orçamentos casados. W1 e W2 foram treinadas com as sementes 42–44 nas duas tarefas; W3–W5, só com a semente 42 e só em entrada/saída. Além do tempo por dobra, a cabeça sozinha foi medida em entradas aleatórias de 2048 dimensões (passo para a frente e para trás com lote de 32 e inferência por imagem; 20 aquecimentos e 200 medidas com eventos CUDA).

5.9 Uma Rede para as Duas Tarefas

Hoje as duas tarefas são resolvidas por duas redes separadas. O experimento multitarefa treina uma única ResNet-152, com backbone e Dropout compartilhados e duas cabeças, uma para entrada/saída ($K = 2$) e outra para distância ($K = 3$) [16, 17]. As duas cabeças são do mesmo tipo, a KAN (d) ou a MLP-128 (b). A perda é $L = L_{\mathrm{E/S}} + L_{\mathrm{dist}}$: cada termo é uma entropia cruzada com pesos de classe, e as saídas ficam fora do termo de distância (o rótulo de distância delas não existe). Assim, a cabeça de entrada/saída aprende com as 2.554 imagens e a de distância com as 1.883 entradas. Quando um lote não tem nenhuma entrada, o termo de distância vale zero. As referências de tarefa única são as redes da ablação da cabeça, (d) e (b), de cada tarefa, treinadas com as mesmas sementes (42–44); a comparação é, portanto, pareada nas mesmas imagens de teste.

Duas medidas adicionais são relatadas. Um pipeline de quatro classes (saída, encostado, curta, distância) combina as duas saídas: com o par de redes de tarefa única, a rede de entrada/saída decide e, para as entradas previstas, a rede de distância decide; com a rede multitarefa, as suas duas cabeças fazem o mesmo. Essa medida é secundária e descritiva. O custo é relatado em parâmetros, tempo de treino por dobra e tempo para obter as duas saídas (um passo para a frente da rede multitarefa contra dois do par), medido na L4 em precisão mista com lotes de 1 e de 32 (20 aquecimentos e 200 medidas). O tempo de inferência não depende dos pesos e foi medido em modelos recém-criados; nenhum peso treinado foi guardado.

5.10 Métricas

Para cada dobra e cada semente, calculam-se nas imagens de teste: acurácia, acurácia balanceada, precisão, revocação e F1 macro, e a área sob a curva ROC (AUC) [15] calculada das probabilidades previstas. Na tarefa binária, a AUC usa a probabilidade da classe saída; na tarefa de distância, é a média macro das três AUC um-contra-o-resto, calculada só nas entradas. Os resultados são dados como média ± desvio-padrão entre as cinco dobras, em que cada dobra é antes a média das sementes; também é dada a AUC fora da dobra ($\mathrm{AUC}_{\mathrm{OOF}}$), calculada depois de tirar a média das probabilidades de cada imagem entre as sementes. Na tarefa de distância a acurácia engana: prever sempre "distância" já dá 0,854. Por isso, as métricas principais são a AUC e o F1 macro.

Lira et al. calcularam a AUC a partir das classes previstas, e não das probabilidades [21]. Com um único limiar, a curva ROC tem um só ponto, e a AUC macro se reduz à média entre revocação e especificidade; essa grandeza, chamada aqui de AUC_c, é calculada só para comparar com as tabelas deles (Seção 2.5).

5.11 Estatística e Regras de Decisão Pré-Registradas

Dois modelos são sempre comparados nas mesmas imagens de teste. A diferença Δ (o primeiro menos o segundo) é calculada nas predições fora da dobra, e o seu intervalo de confiança de 95% vem de um bootstrap pareado sobre os casos [18]: os casos são reamostrados com reposição 2.000 vezes, o que respeita a dependência entre imagens do mesmo caso. Também são dados a diferença por dobra e o número de dobras em que cada modelo vence.

As regras de decisão foram escritas antes das rodadas correspondentes. As regras da ablação da cabeça, dos backbones e da distância foram fixadas nos planos dos experimentos e nos notebooks de análise registrados no repositório em 14 de outubro de 2026 (commits `9961146` e `367a7a6`, que permanecem no seu histórico), antes da primeira rodada de treino:

- **Comparação primária:** a cabeça KAN (d) contra a melhor das duas MLPs, (b) ou (c), em AUC.
- **Desfecho A (a KAN melhora):** $\Delta\mathrm{AUC} > 0$ em pelo menos quatro das cinco dobras *e* intervalo de confiança acima de zero.
- **Desfecho C (a KAN é pior):** a KAN vence no máximo uma dobra *e* o intervalo fica abaixo de zero.
- **Desfecho B (equivalente):** nos demais casos.

- **Afirmações proibidas sem o resultado correspondente:** “só trocar a cabeça melhora”, “novo estado da arte”, “supera os baselines transformer” e “eficiência de parâmetros”.

Os experimentos Wav-KAN e multitarefa foram planejados no mesmo commit dos planos (`9961146`), com margem de não inferioridade de $-0{,}02$: um modelo é *não inferior* quando o limite inferior do intervalo do ΔAUC (e, nas cabeças Wav-KAN, também o do ΔF1) fica acima de $-0{,}02$. Superior e inferior seguem a regra dos desfechos A e C. Nas cabeças Wav-KAN, a frase “mais eficiente em parâmetros que uma MLP” só seria permitida se a W2 fosse superior à MLP (b) do mesmo tamanho, e “mais rápida” só se o benchmark da cabeça e o tempo por dobra melhorassem além do ruído entre rodadas. Em 19 de outubro de 2026, depois do primeiro experimento e antes de qualquer rodada Wav-KAN ou multitarefa, três ajustes foram registrados (commit `3266a99`): as configurações principais usariam as sementes 42–44, como as referências; W1 e W2 rodariam também na distância; e a comparação multitarefa reaproveitaria as redes de tarefa única da ablação da cabeça. A margem foi mantida.

5.12 Ameaças à Validade

Sem partição de validação. Avaliar a última época evita escolher a época no conjunto de teste, o que inflou os resultados anteriores deste trabalho, mas também não é uma escolha otimizada: um modelo parado por uma validação interna poderia ser um pouco melhor. A regra é a mesma para todos os modelos e, portanto, não favorece nenhum deles.

Aumento de dados como rodou. O ruído gaussiano da receita original é forte (desvio-padrão de até 0,44 da faixa de intensidade) e pode apagar vestígios finos como a tatuagem, que importam para a classe curta distância. Ele vale igualmente para todos os modelos: é uma limitação da receita, não um viés das comparações.

Sementes. A ablação da cabeça, a Swin-B e a MaxViT-T (entrada/saída), W1, W2 e as redes multitarefa usam três sementes. Os demais backbones, a cabeça (e) e W3–W5 usam uma semente, e a Swin-B e a MaxViT-T usam duas sementes na distância; esses resultados são dados com essa ressalva.

A partição de Lira et al. O experimento de vazamento reproduz o método do código público com três sementes; a partição exata por trás das tabelas publicadas não pode ser recuperada, e o código pode diferir do usado no artigo.

Poder estatístico e a classe encostado. Cinco dobras dão pouco poder para detectar diferenças pequenas entre cabeças. A classe encostado tem 42 imagens de 16 casos (de 4 a 13 imagens de teste por dobra), então nada específico é afirmado sobre ela.

Uma única base. Todas as imagens vêm de uma única polícia e de uma única região; não houve validação externa.

Capítulo 6

Resultados

Este capítulo relata os experimentos do Capítulo 5 na ordem das perguntas de pesquisa: primeiro o efeito da partição usada em 2024 (Seção 6.1), depois a ablação da cabeça e os backbones nas duas tarefas (Seções 6.2 e 6.3), a comparação com os números publicados por Lira et al. (Seção 6.4) e com os transformers (Seção 6.5) e, por fim, as cabeças Wav-KAN (Seção 6.6) e a rede multitarefa (Seção 6.7). Salvo indicação em contrário, os números são médias ± desvios-padrão entre as cinco dobras agrupadas por caso, a AUC é calculada das probabilidades, e as diferenças vêm com intervalos de confiança de 95% do bootstrap pareado de casos.

6.1 O Hold-Out de 2024 Vaza Casos

Reproduzindo em três partições o hold-out do código público de Lira et al., 98,7% das imagens de teste de entrada/saída e 98,4% das imagens de teste de distância pertencem a um caso que também tem imagens no treino. A Tabela 6.1 e a Figura 6.1 comparam, com a mesma rede, a mesma receita e a mesma semente, os resultados nessas partições e nas dobras agrupadas por caso.

Em entrada/saída, a AUC sobe de 0,906 nas dobras agrupadas para 0,940 nas partições com vazamento, com as duas cabeças (+0,034). Na distância do disparo o efeito é cerca de cinco vezes maior: de 0,779 para 0,937 com a cabeça linear (+0,158) e de 0,788 para 0,942 com a cabeça KAN (+0,155); a acurácia balanceada vai de cerca de 0,51 para cerca de 0,78. As partições com vazamento também parecem muito mais estáveis (desvio-padrão de 0,003–0,004 na AUC, contra 0,011–0,013 em entrada/saída e 0,06–0,09 na distância entre as dobras agrupadas). Ou seja, uma partição que deixa a rede ver outras fotografias do mesmo caso faz a tarefa de distância parecer quase tão fácil quanto a de entrada/saída, enquanto as dobras agrupadas mostram que ela é bem mais difícil. Os números agrupados

Tabela 6.1: Efeito da partição com todo o resto fixo (ResNet-152, mesma receita, semente 42). *Lira et al.*: o hold-out por imagem do código público de Lira et al. (estratificação iterativa sobre o número do caso e o rótulo) reproduzido em três partições; média ± dp entre as partições. *Agrupada*: as cinco dobras agrupadas por caso deste trabalho; média ± dp entre dobras. Vaz.: fração das imagens de teste cujo caso também tem imagens no treino. Δ = Lira − agrupada.

Tarefa	Cabeça	Partição	Vaz.	Acc	$F1_M$	Acc bal.	AUC
Entrada/saída	Linear (a)	Lira et al.	98,7%	$0{,}876 \pm 0{,}005$	$0{,}838 \pm 0{,}007$	$0{,}852 \pm 0{,}010$	$0{,}940 \pm 0{,}003$
		Agrupada	0%	$0{,}848 \pm 0{,}010$	$0{,}809 \pm 0{,}013$	$0{,}820 \pm 0{,}011$	$0{,}906 \pm 0{,}013$
		Δ		+0,028	+0,029	+0,033	+0,034
Entrada/saída	KAN (d) = TransferKAN	Lira et al.	98,7%	$0{,}881 \pm 0{,}006$	$0{,}844 \pm 0{,}006$	$0{,}859 \pm 0{,}003$	$0{,}940 \pm 0{,}003$
		Agrupada	0%	$0{,}846 \pm 0{,}008$	$0{,}807 \pm 0{,}011$	$0{,}818 \pm 0{,}013$	$0{,}906 \pm 0{,}011$
		Δ		+0,035	+0,037	+0,040	+0,034
MLSD	Linear (a)	Lira et al.	98,4%	$0{,}857 \pm 0{,}006$	$0{,}697 \pm 0{,}014$	$0{,}783 \pm 0{,}008$	$0{,}937 \pm 0{,}004$
		Agrupada	0%	$0{,}817 \pm 0{,}014$	$0{,}486 \pm 0{,}059$	$0{,}521 \pm 0{,}079$	$0{,}779 \pm 0{,}088$
		Δ		+0,040	+0,211	+0,262	+0,158
MLSD	KAN (d) = TransferKAN	Lira et al.	98,4%	$0{,}863 \pm 0{,}002$	$0{,}691 \pm 0{,}003$	$0{,}788 \pm 0{,}006$	$0{,}942 \pm 0{,}003$
		Agrupada	0%	$0{,}810 \pm 0{,}018$	$0{,}466 \pm 0{,}035$	$0{,}500 \pm 0{,}062$	$0{,}788 \pm 0{,}063$
		Δ		+0,053	+0,225	+0,288	+0,155

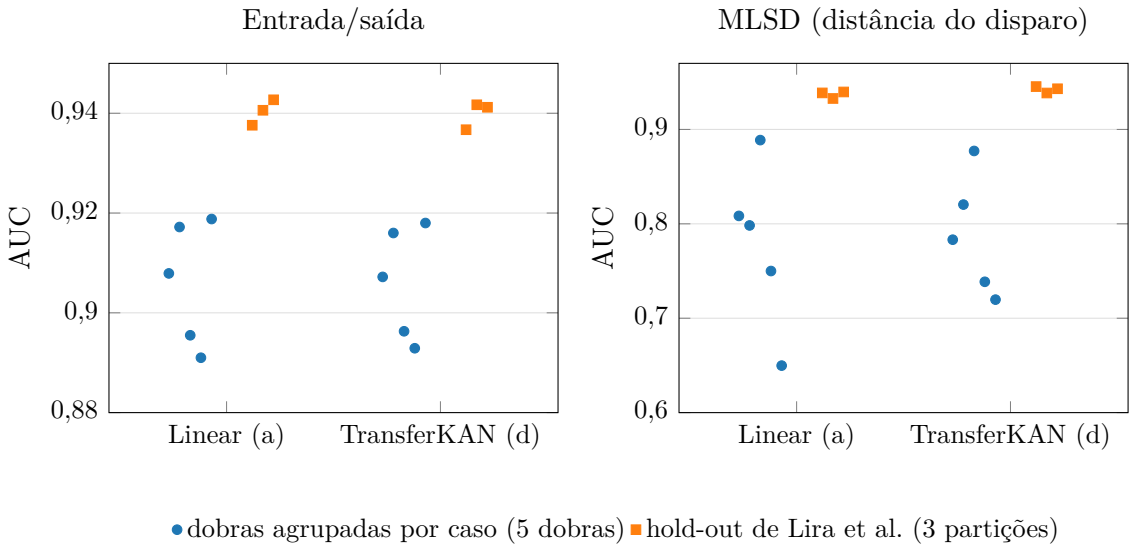


Figura 6.1: AUC da ResNet-152 com a cabeça linear (a) e com a cabeça KAN (d), semente 42, em cada dobra agrupada por caso (círculos) e em cada partição reproduzida de Lira et al. (quadrados). Mesma rede, receita e semente; só a partição muda.

desta tabela usam só a semente 42 e por isso diferem um pouco dos números com três sementes das seções seguintes (0,906 em vez de 0,904 para a cabeça linear).

A análise k-fold que Lira et al. relatam para a ResNet-152 deles aponta na mesma direção: com dobras agrupadas por caso, a mediana da acurácia do modelo deles em entrada/saída é de cerca de 0,70 (lida do boxplot, Figura 6.2), bem abaixo do 0,869 da tabela de hold-out.

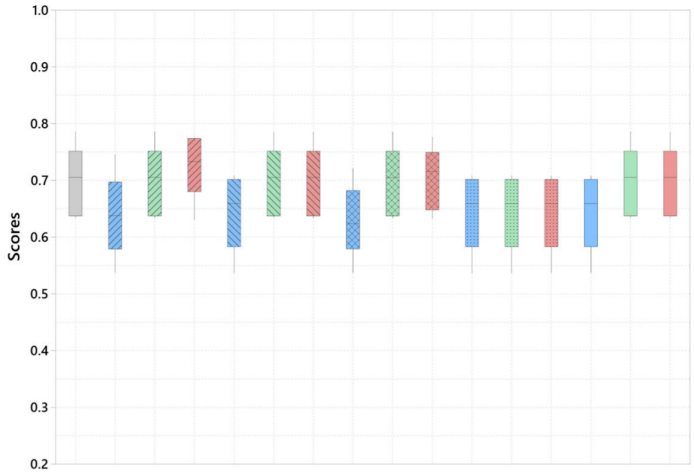
6.2 Entrada/Saída: Cabeças e Backbones

A Tabela 6.2 reúne todos os resultados de entrada/saída no protocolo único.

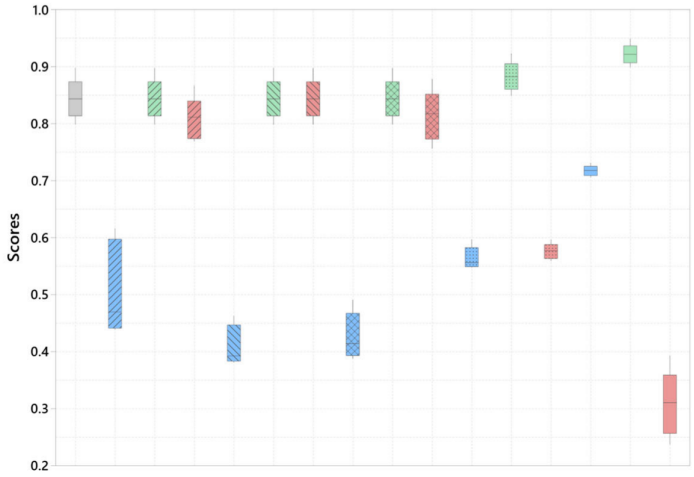
Tabela 6.2: Classificação entrada/saída no protocolo único (5 dobras estratificadas e agrupadas por caso, mesma receita de duas fases, última época). Média ± dp entre dobras; cada dobra é a média das sementes de treino (coluna S). F1 é a média macro (precisão e revocação macro estão no Apêndice A); a AUC é calculada das probabilidades previstas. Min: minutos de treino por dobra numa NVIDIA L4.

Modelo	Parâm. (M)	S	Acc	F1	AUC	Min
Ablação da cabeça (backbone ResNet-152)						
ResNet152 + Linear (a)	58,15	3	$0{,}846 \pm 0{,}008$	$0{,}805 \pm 0{,}012$	$0{,}904 \pm 0{,}013$	8,2
ResNet152 + MLP-128 (b)	58,41	3	$0{,}846 \pm 0{,}011$	$0{,}806 \pm 0{,}015$	$0{,}905 \pm 0{,}014$	8,3
ResNet152 + MLP-iso (c)	62,08	3	$0{,}846 \pm 0{,}009$	$0{,}807 \pm 0{,}013$	$0{,}906 \pm 0{,}014$	8,4
ResNet152 + KAN (d) = TransferKAN	62,08	3	$0{,}846 \pm 0{,}010$	$0{,}806 \pm 0{,}013$	$0{,}905 \pm 0{,}013$	8,5
ResNet152 + KAN-8 (e)	58,39	1	$0{,}846 \pm 0{,}012$	$0{,}808 \pm 0{,}014$	$0{,}903 \pm 0{,}014$	8,4
Backbones (cabeça linear)						
ResNet152	58,15	3	$0{,}846 \pm 0{,}008$	$0{,}805 \pm 0{,}012$	$0{,}904 \pm 0{,}013$	8,2
AlexNet	57,01	1	$0{,}803 \pm 0{,}036$	$0{,}761 \pm 0{,}047$	$0{,}859 \pm 0{,}040$	3,2
MobileNetV2	2,23	1	$0{,}812 \pm 0{,}024$	$0{,}776 \pm 0{,}029$	$0{,}877 \pm 0{,}025$	3,9
MNASNet1.3	5,00	1	$0{,}837 \pm 0{,}012$	$0{,}753 \pm 0{,}022$	$0{,}872 \pm 0{,}021$	3,9
ShuffleNetV2 x0.5	0,34	1	$0{,}746 \pm 0{,}018$	$0{,}713 \pm 0{,}018$	$0{,}839 \pm 0{,}021$	3,8
SqueezeNet1.0	0,74	1	$0{,}798 \pm 0{,}023$	$0{,}760 \pm 0{,}030$	$0{,}866 \pm 0{,}023$	3,2
DenseNet169	12,49	1	$0{,}858 \pm 0{,}005$	$0{,}821 \pm 0{,}008$	$0{,}904 \pm 0{,}018$	8,4
MaxViT-T	30,41	3	$0{,}864 \pm 0{,}015$	$0{,}831 \pm 0{,}021$	$0{,}917 \pm 0{,}009$	12,4
Swin-B	86,75	3	$0{,}884 \pm 0{,}011$	$0{,}850 \pm 0{,}015$	$0{,}929 \pm 0{,}011$	15,4
EfficientNetV2-L	117,24	1	$0{,}868 \pm 0{,}010$	$0{,}831 \pm 0{,}016$	$0{,}916 \pm 0{,}007$	15,2
VGG16	134,27	1	$0{,}841 \pm 0{,}013$	$0{,}794 \pm 0{,}025$	$0{,}891 \pm 0{,}025$	8,6
RegNetY-16GF	80,57	1	$0{,}852 \pm 0{,}015$	$0{,}815 \pm 0{,}020$	$0{,}906 \pm 0{,}011$	12,1
ResNet152 + KAN (d) = TransferKAN	62,08	3	$0{,}846 \pm 0{,}010$	$0{,}806 \pm 0{,}013$	$0{,}905 \pm 0{,}013$	8,5

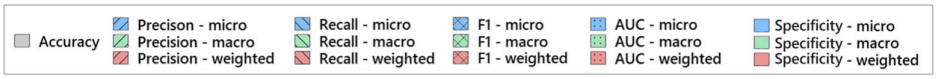
Cabeças. Com a ResNet-152 fixa, as cinco cabeças são indistinguíveis: AUC de 0,903 (KAN-8) a 0,906 (MLP isoparamétrica), e acurácia de 0,846 em todas. A regra pré-registrada dá o desfecho B. A melhor MLP é a isoparamétrica (c), e a cabeça KAN (d) difere dela em $\Delta\text{AUC} = -0{,}001$ (IC 95% $[-0{,}002; +0{,}0003]$), vencendo 2 das 5 dobras. Contra a MLP-128 (b) a diferença é de $-0{,}0001$ ($[-0{,}001; +0{,}001]$, 3 de 5 dobras), e contra a cabeça linear (a), de $+0{,}001$ ($[-0{,}001; +0{,}003]$, 3 de 5 dobras); todos os intervalos incluem o zero. As curvas ROC das quatro cabeças praticamente coincidem (Figura 6.3).



(a) Wound type



(b) Medical-legal shooting distance



ation performance for wound type (a) and shooting distance (b) using ResNet 152 over the k-folds

Figura 6.2: Análise de estabilidade da ResNet-152 de Lira et al. em k-folds agrupados, para o tipo de ferimento (a) e a distância do disparo (b); a caixa mais à esquerda (cinza) de cada painel é a acurácia (Fonte: [1]).

No mesmo protocolo, portanto, a cabeça KAN tem desempenho equivalente ao das cabeças linear e MLP; ela não é a fonte dos resultados da TransferKAN.

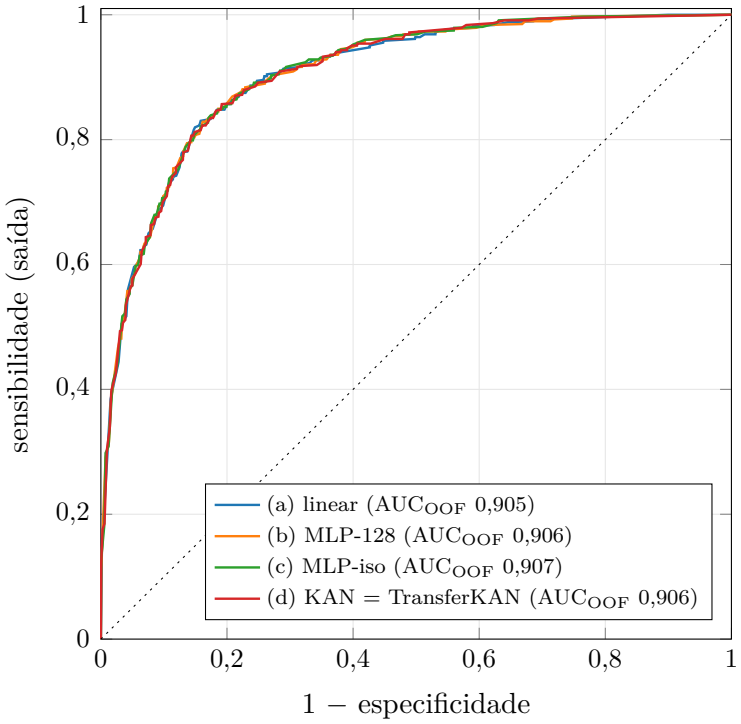


Figura 6.3: Curvas ROC fora da dobra das quatro cabeças na ResNet-152 (entrada/saída; probabilidades médias das sementes 42–44; saída é a classe positiva).

Um diagnóstico gravado na avaliação sugere por que a spline acrescenta pouco. A `efficient-kan` define as B-splines só numa grade sobre $[-1, 1]$ (um pouco estendida nas bordas); fora dela, cada aresta se reduz ao seu ramo base SiLU, que funciona como uma MLP. Nas imagens de teste, 97–98% das entradas da primeira camada KAN caem dentro da grade, mas só 46–64% das entradas da segunda camada (27–39% na KAN pequena (e)), de modo que boa parte da segunda camada trabalha sem as suas splines.

Backbones. Os backbones pré-treinados vão de 0,839 (ShuffleNetV2 $\times$0.5) a 0,929 (Swin-B). A Swin-B é o melhor modelo do estudo (AUC $0{,}929 \pm 0{,}011$, acurácia 0,884), seguida pela MaxViT-T (0,917) e pela EfficientNetV2-L (0,916). A TransferKAN (0,905) fica junto da RegNetY-16GF (0,906), da DenseNet-169 (0,904) e da ResNet-152 com cabeça linear (0,904), no meio da tabela. As demais redes (VGG-16, MobileNetV2, MNASNet, SqueezeNet, AlexNet e ShuffleNetV2) ficam em 0,891 ou abaixo. Fora as cabeças da ResNet-152, a Swin-B e a MaxViT-T, essas linhas usam uma única semente.

6.3 Distância do Disparo: Cabeças e Backbones

A Tabela 6.3 traz a mesma comparação para a tarefa de distância.

Tabela 6.3: Distância médico-legal do disparo (encostado, curta, distância; só entradas) no mesmo protocolo da Tabela 6.2. Média ± dp entre dobras; S = sementes de treino (Swin-B e MaxViT-T: só as sementes 42 e 43). AUC = AUC macro um-contra-o-resto, das probabilidades. Rev.: revocação por classe (média entre dobras); encostado tem de 4 a 13 imagens de teste por dobra e é só descritivo.

Modelo	Parâm. (M)	S	Acc	Acc bal.	$F1_M$	AUC	Rev. enc.	Rev. curta	Min
Ablação da cabeça (backbone ResNet-152)									
ResNet152 + Linear (a)	58,15	3	0,815 ± 0,014	0,524 ± 0,077	0,488 ± 0,056	0,785 ± 0,087	0,17	0,53	6,3
ResNet152 + MLP-128 (b)	58,41	3	0,813 ± 0,013	0,520 ± 0,072	0,482 ± 0,050	0,802 ± 0,062	0,16	0,53	6,3
ResNet152 + MLP-iso (c)	62,08	3	0,821 ± 0,017	0,510 ± 0,064	0,480 ± 0,050	0,807 ± 0,055	0,13	0,51	6,4
ResNet152 + KAN (d) = TransferKAN	62,08	3	0,813 ± 0,017	0,515 ± 0,069	0,477 ± 0,045	0,798 ± 0,058	0,15	0,52	6,5
Backbones (cabeça linear)									
ResNet152	58,15	3	0,815 ± 0,014	0,524 ± 0,077	0,488 ± 0,056	0,785 ± 0,087	0,17	0,53	6,3
AlexNet	57,02	1	0,780 ± 0,033	0,561 ± 0,105	0,498 ± 0,084	0,806 ± 0,079	0,26	0,59	2,5
MobileNetV2	2,23	1	0,778 ± 0,025	0,513 ± 0,074	0,464 ± 0,042	0,806 ± 0,056	0,20	0,50	3,1
MNASNet1.3	5,01	1	0,451 ± 0,078	0,455 ± 0,051	0,294 ± 0,047	0,710 ± 0,095	0,10	0,86	3,1
ShuffleNetV2 x0.5	0,34	1	0,854 ± 0,016	0,474 ± 0,079	0,474 ± 0,088	0,776 ± 0,046	0,10	0,38	3,1
SqueezeNet1.0	0,74	1	0,788 ± 0,023	0,525 ± 0,090	0,490 ± 0,074	0,805 ± 0,051	0,20	0,53	2,6
DenseNet169	12,49	1	0,820 ± 0,034	0,556 ± 0,136	0,519 ± 0,120	0,821 ± 0,070	0,24	0,55	6,6
MaxViT-T	30,41	2	0,810 ± 0,021	0,555 ± 0,086	0,511 ± 0,070	0,828 ± 0,047	0,23	0,58	9,4
Swin-B	86,75	2	0,825 ± 0,021	0,540 ± 0,087	0,505 ± 0,091	0,838 ± 0,054	0,18	0,55	11,4
EfficientNetV2-L	117,24	1	0,830 ± 0,026	0,529 ± 0,084	0,495 ± 0,076	0,744 ± 0,133	0,15	0,55	11,6
VGG16	134,27	1	0,844 ± 0,026	0,510 ± 0,067	0,481 ± 0,050	0,776 ± 0,079	0,10	0,51	6,6
RegNetY-16GF	80,57	1	0,826 ± 0,024	0,531 ± 0,080	0,496 ± 0,071	0,773 ± 0,088	0,13	0,58	9,1
ResNet152 + KAN (d) = TransferKAN	62,08	3	0,813 ± 0,017	0,515 ± 0,069	0,477 ± 0,045	0,798 ± 0,058	0,15	0,52	6,5

Cabeças. As AUC são 0,785 ± 0,087 (linear), 0,802 ± 0,062 (MLP-128), 0,807 ± 0,055 (MLP isoparamétrica) e 0,798 ± 0,058 (KAN). A regra pré-registrada dá o desfecho C: contra a melhor MLP, a isoparamétrica, a cabeça KAN tem $\Delta\text{AUC} = -0{,}011$ ($[-0{,}021; -0{,}003]$) e vence só 1 das 5 dobras. A KAN fica significativamente abaixo *só* dessa MLP: contra a MLP-128 a diferença é de $-0{,}005$ ($[-0{,}012; +0{,}003]$), e contra a cabeça linear, de $+0{,}008$ ($[-0{,}005; +0{,}023]$), os dois intervalos incluindo o zero. As curvas ROC por classe (Figura 6.4) se sobrepõem para curta distância e distância e só se separam para encostado, que tem 42 imagens.

Todas as cabeças têm acurácia balanceada em torno de 0,51–0,52 e F1 macro em torno de 0,48–0,49. A revocação é de cerca de 0,88 para distância e de 0,51–0,53 para curta distância, e de só 0,13–0,17 para encostado. O número do encostado é descritivo: há de 4 a 13 imagens de encostado por dobra de teste. Quando o caso de um ferimento encostado não está no treino, as redes quase nunca o reconhecem. Essa é a principal limitação dos modelos atuais.

Backbones. A Swin-B volta a ser a melhor (0,838 ± 0,054), seguida pela MaxViT-T (0,828) e pela DenseNet-169 (0,821); os dois transformers têm só as sementes 42 e 43 nesta tarefa. Redes mais antigas ou menores, como AlexNet, MobileNetV2 e SqueezeNet, chegam a 0,805–0,806, acima da ResNet-152, enquanto a EfficientNetV2-L (0,744) varia

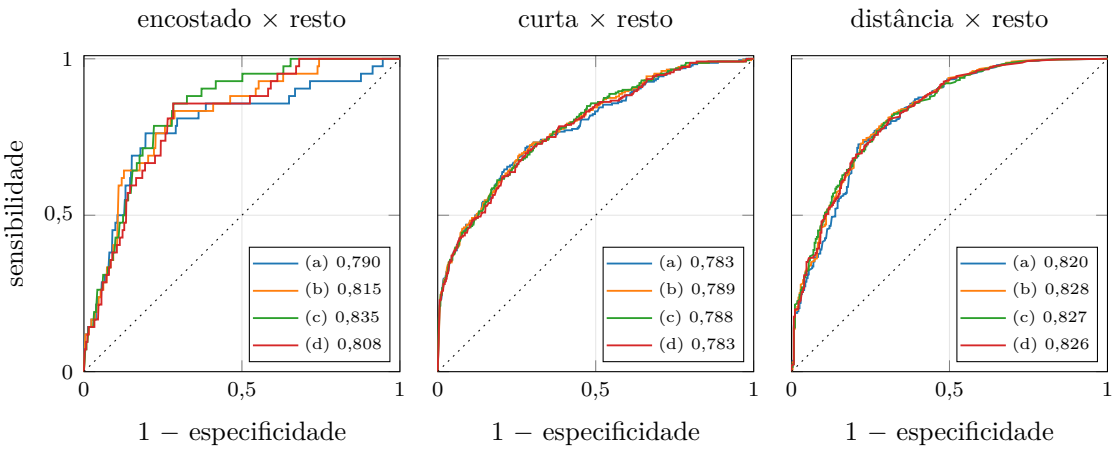


Figura 6.4: Curvas ROC um-contra-o-resto fora da dobra das quatro cabeças na ResNet-152 para a distância do disparo (só entradas; probabilidades médias das sementes 42–44). A legenda traz a AUC um-contra-o-resto de cada cabeça.

muito entre dobras (±0,133). A MNASNet colapsou nesta tarefa (acurácia 0,451, prevendo a maioria das entradas como curta distância), o que é uma instabilidade de otimização com esta receita, e não uma propriedade da arquitetura. Com desvios-padrão entre dobras de 0,05–0,13, a maioria das diferenças entre backbones nesta tarefa fica dentro do ruído.

6.4 Comparação com os Números Publicados de Lira et al.

As Tabelas 6.4 e 6.5 põem os números das Tabelas 4 e 5 de Lira et al. ao lado dos mesmos backbones no protocolo único. Os dois lados diferem em três pontos ao mesmo tempo (a partição, a inicialização e a definição da AUC), então as tabelas comparam pacotes de avaliação, e não modelos; só a AUC das classes, AUC_c, é calculada do mesmo jeito nos dois lados.

Em entrada/saída, a ResNet-152 de Lira et al. tem acurácia de 0,869, F1 macro de 0,824 e AUC_c de 0,821. O mesmo backbone com cabeça linear no protocolo único obtém 0,846, 0,805 e 0,814 (AUC das probabilidades 0,904). A TransferKAN, com 0,846, 0,806 e 0,816, fica acima de onze das doze linhas publicadas, mas *abaixo* da ResNet-152 deles nas três métricas. Para as outras onze arquiteturas, o protocolo único dá números maiores que os publicados nas três métricas, em geral bem maiores (Swin-B: acurácia de 0,728 para 0,884; AUC_c de 0,591 para 0,850), embora a sua partição seja a mais rigorosa. Isso é coerente com o fato de que, no código público, só as ResNets partem dos pesos do ImageNet; mas este trabalho não treinou do zero, então o efeito do pré-treino não é isolado aqui.

Tabela 6.4: Entrada/saída: números publicados por Lira et al. [1] (Tabela 4) ao lado dos mesmos backbones no protocolo único deste trabalho. Os dois lados diferem em três pontos ao mesmo tempo: a partição (hold-out por imagem no código público deles × 5 dobras agrupadas por caso), a inicialização (quase tudo treinado do zero no código público deles × pesos do ImageNet) e a AUC (das classes previstas, AUC_c × das probabilidades, AUC_p). Só a AUC_c é calculada do mesmo jeito nos dois lados; a tabela compara pacotes de avaliação, não modelos. M = macro; nossos: média ± dp entre dobras.

	Lira et al. (publicado)			Protocolo único (este trabalho)			
Modelo	Acc	$\mathrm{F1}_M$	$\mathrm{AUC}_{c,M}$	Acc	$\mathrm{F1}_M$	$\mathrm{AUC}_{c,M}$	$\mathrm{AUC}_{p,M}$
ResNet152	0,869	0,824	0,821	$0{,}846 \pm 0{,}008$	$0{,}805 \pm 0{,}012$	$0{,}814 \pm 0{,}012$	$0{,}904 \pm 0{,}013$
AlexNet	0,765	0,703	0,716	$0{,}803 \pm 0{,}036$	$0{,}761 \pm 0{,}047$	$0{,}782 \pm 0{,}045$	$0{,}859 \pm 0{,}040$
MobileNetV2	0,719	0,598	0,593	$0{,}812 \pm 0{,}024$	$0{,}776 \pm 0{,}029$	$0{,}802 \pm 0{,}027$	$0{,}877 \pm 0{,}025$
MNASNet1.3	0,746	0,657	0,656	$0{,}837 \pm 0{,}012$	$0{,}753 \pm 0{,}022$	$0{,}725 \pm 0{,}023$	$0{,}872 \pm 0{,}021$
ShuffleNetV2 x0.5	0,730	0,619	0,614	$0{,}746 \pm 0{,}018$	$0{,}713 \pm 0{,}018$	$0{,}755 \pm 0{,}017$	$0{,}839 \pm 0{,}021$
SqueezeNet1.0	0,750	0,429	0,500	$0{,}798 \pm 0{,}023$	$0{,}760 \pm 0{,}030$	$0{,}787 \pm 0{,}032$	$0{,}866 \pm 0{,}023$
DenseNet169	0,777	0,688	0,679	$0{,}858 \pm 0{,}005$	$0{,}821 \pm 0{,}008$	$0{,}830 \pm 0{,}012$	$0{,}904 \pm 0{,}018$
MaxViT-T	0,780	0,668	0,653	$0{,}864 \pm 0{,}015$	$0{,}831 \pm 0{,}021$	$0{,}846 \pm 0{,}020$	$0{,}917 \pm 0{,}009$
Swin-B	0,728	0,597	0,591	$0{,}884 \pm 0{,}011$	$0{,}850 \pm 0{,}015$	$0{,}850 \pm 0{,}016$	$0{,}929 \pm 0{,}011$
EfficientNetV2-L	0,782	0,654	0,638	$0{,}868 \pm 0{,}010$	$0{,}831 \pm 0{,}016$	$0{,}836 \pm 0{,}011$	$0{,}916 \pm 0{,}007$
VGG16	0,782	0,694	0,685	$0{,}841 \pm 0{,}013$	$0{,}794 \pm 0{,}025$	$0{,}796 \pm 0{,}034$	$0{,}891 \pm 0{,}025$
RegNetY-16GF	0,711	0,549	0,549	$0{,}852 \pm 0{,}015$	$0{,}815 \pm 0{,}020$	$0{,}824 \pm 0{,}021$	$0{,}906 \pm 0{,}011$
TransferKAN (ResNet152 + KAN)	—	—	—	$0{,}846 \pm 0{,}010$	$0{,}806 \pm 0{,}013$	$0{,}816 \pm 0{,}015$	$0{,}905 \pm 0{,}013$

Tabela 6.5: MLSD (só entradas): números publicados por Lira et al. [1] (Tabela 5) ao lado dos mesmos backbones no protocolo único deste trabalho. Os dois lados diferem em três pontos ao mesmo tempo: a partição (hold-out por imagem no código público deles × 5 dobras agrupadas por caso), a inicialização (quase tudo treinado do zero no código público deles × pesos do ImageNet) e a AUC (das classes previstas, AUC_c × das probabilidades, AUC_p). Só a AUC_c é calculada do mesmo jeito nos dois lados; a tabela compara pacotes de avaliação, não modelos. M = macro; nossos: média ± dp entre dobras. Nesta tarefa, prever sempre "distância" já dá acurácia de 0,854.

	Lira et al. (publicado)			Protocolo único (este trabalho)			
Modelo	Acc	$\mathrm{F1}_M$	$\mathrm{AUC}_{c,M}$	Acc	$\mathrm{F1}_M$	$\mathrm{AUC}_{c,M}$	$\mathrm{AUC}_{p,M}$
ResNet152	0,925	0,701	0,733	$0{,}815 \pm 0{,}014$	$0{,}488 \pm 0{,}056$	$0{,}670 \pm 0{,}047$	$0{,}785 \pm 0{,}087$
AlexNet	0,889	0,395	0,541	$0{,}780 \pm 0{,}033$	$0{,}498 \pm 0{,}084$	$0{,}694 \pm 0{,}064$	$0{,}806 \pm 0{,}079$
MobileNetV2	0,886	0,361	0,531	$0{,}778 \pm 0{,}025$	$0{,}464 \pm 0{,}042$	$0{,}660 \pm 0{,}043$	$0{,}806 \pm 0{,}056$
MNASNet1.3	0,869	0,378	0,533	$0{,}451 \pm 0{,}078$	$0{,}294 \pm 0{,}047$	$0{,}610 \pm 0{,}037$	$0{,}710 \pm 0{,}095$
ShuffleNetV2 x0.5	0,855	0,346	0,512	$0{,}854 \pm 0{,}016$	$0{,}474 \pm 0{,}088$	$0{,}627 \pm 0{,}044$	$0{,}776 \pm 0{,}046$
SqueezeNet1.0	0,095	0,058	0,500	$0{,}788 \pm 0{,}023$	$0{,}490 \pm 0{,}074$	$0{,}666 \pm 0{,}056$	$0{,}805 \pm 0{,}051$
DenseNet169	0,883	0,398	0,548	$0{,}820 \pm 0{,}034$	$0{,}519 \pm 0{,}120$	$0{,}691 \pm 0{,}092$	$0{,}821 \pm 0{,}070$
MaxViT-T	0,880	0,549	0,607	$0{,}810 \pm 0{,}021$	$0{,}511 \pm 0{,}070$	$0{,}691 \pm 0{,}053$	$0{,}828 \pm 0{,}047$
Swin-B	0,861	0,339	0,517	$0{,}825 \pm 0{,}021$	$0{,}505 \pm 0{,}091$	$0{,}684 \pm 0{,}053$	$0{,}838 \pm 0{,}054$
EfficientNetV2-L	0,880	0,488	0,588	$0{,}830 \pm 0{,}026$	$0{,}495 \pm 0{,}076$	$0{,}673 \pm 0{,}057$	$0{,}744 \pm 0{,}133$
VGG16	0,864	0,381	0,546	$0{,}844 \pm 0{,}026$	$0{,}481 \pm 0{,}050$	$0{,}656 \pm 0{,}041$	$0{,}776 \pm 0{,}079$
RegNetY-16GF	0,875	0,357	0,523	$0{,}826 \pm 0{,}024$	$0{,}496 \pm 0{,}071$	$0{,}678 \pm 0{,}048$	$0{,}773 \pm 0{,}088$
TransferKAN (ResNet152 + KAN)	—	—	—	$0{,}813 \pm 0{,}017$	$0{,}477 \pm 0{,}045$	$0{,}664 \pm 0{,}041$	$0{,}798 \pm 0{,}058$

Na tarefa de distância, as acurácias publicadas (0,855–0,925 em todas as linhas exceto a SqueezeNet) são maiores que qualquer acurácia do protocolo único, e a TransferKAN (0,813) fica abaixo de onze das doze linhas publicadas. Em AUC_c, a TransferKAN (0,664) fica acima de onze das doze linhas e abaixo da ResNet-152 deles (0,733). Vários modelos publicados têm AUC_c perto de 0,5 (SqueezeNet 0,500, ShuffleNetV2 0,512), ou seja, quase não separam as classes, mesmo com acurácia alta, que nesta tarefa é dominada pela classe distância.

Essas comparações sustentam uma afirmação mais estreita que a da versão anterior deste trabalho. No protocolo único, a TransferKAN é equivalente à mesma ResNet-152 com cabeça linear e fica abaixo dos melhores backbones pré-treinados (Seção 6.5). As diferenças em relação aos números de Lira et al. vêm da partição, do pré-treino e da receita, e não da cabeça KAN. Só o efeito da partição foi isolado com a mesma receita (Seção 6.1).

6.5 A TransferKAN e os Transformers

Como os dois transformers foram os melhores backbones, a TransferKAN foi comparada diretamente com eles, nas mesmas imagens (Tabela 6.6).

Tabela 6.6: TransferKAN (ResNet-152 + KAN spline, sementes 42–44) contra os dois backbones transformer com cabeça linear, no protocolo único. ΔAUC nas predições fora da dobra (probabilidades médias das sementes); IC 95% por bootstrap pareado de casos (2.000 reamostragens); vence = dobras em que a TransferKAN tem a AUC maior.

Tarefa	Contraste	ΔAUC	IC 95%	Vence	Sementes do transformer
Entrada/saída	TransferKAN − Swin-B	−0,023	[−0,035; −0,011]	0/5	42–44
Entrada/saída	TransferKAN − MaxViT-T	−0,010	[−0,020; −0,001]	0/5	42–44
MLSD	TransferKAN − Swin-B	−0,033	[−0,064; −0,0004]	1/5	42, 43
MLSD	TransferKAN − MaxViT-T	−0,030	[−0,059; +0,001]	1/5	42, 43

Em entrada/saída, a TransferKAN fica abaixo da Swin-B (ΔAUC = −0,023, [−0,035; −0,011]) e da MaxViT-T (−0,010, [−0,020; −0,001]), e perde nas cinco dobras contra as duas. Na distância, fica abaixo da Swin-B (−0,033, [−0,064; −0,0004], 1 de 5 dobras). Contra a MaxViT-T a diferença é parecida (−0,030), mas o intervalo inclui o zero. A afirmação de que a TransferKAN supera os baselines transformer, portanto, não se sustenta; o contrário vale para a Swin-B nas duas tarefas.

6.6 Cabeças Wav-KAN

As Tabelas 6.7 e 6.8 mostram as cabeças Wav-KAN ao lado das cabeças (a)–(d), a Tabela 6.9 traz os contrastes pré-registrados e a Figura 6.5, a AUC em função do número de parâmetros da cabeça.

Tabela 6.7: Entrada/saída: cabeças Wav-KAN contra as cabeças (a)–(d), na mesma ResNet-152 e com a mesma receita. Média ± dp entre dobras (cada dobra é a média das S sementes); F1 macro; a $\mathrm{AUC}_{\mathrm{OOF}}$ junta as predições fora da dobra. Min: minutos de treino por dobra (NVIDIA L4). Cabeça ms: forward + backward só da cabeça, num lote de 32 entradas aleatórias de 2048 dimensões.

Id	Cabeça	Parâm.	S	Acc	F1	AUC	$\mathrm{AUC}_{\mathrm{OOF}}$	Min	Cabeça ms
(a)	Linear	4.098	3	$0{,}846 \pm 0{,}008$	$0{,}805 \pm 0{,}012$	$0{,}904 \pm 0{,}013$	0,905	8,2	0,48
(b)	MLP-128	262.530	3	$0{,}846 \pm 0{,}011$	$0{,}806 \pm 0{,}015$	$0{,}905 \pm 0{,}014$	0,906	8,3	0,73
(c)	MLP-iso	3.935.871	3	$0{,}846 \pm 0{,}009$	$0{,}807 \pm 0{,}013$	$0{,}906 \pm 0{,}014$	0,907	8,4	0,73
(d)	KAN spline = TransferKAN	3.936.000	3	$0{,}846 \pm 0{,}010$	$0{,}806 \pm 0{,}013$	$0{,}905 \pm 0{,}013$	0,906	8,5	3,30
W1	Wav-KAN, chapéu mexicano, $h = 128$	1.049.860	3	$0{,}835 \pm 0{,}015$	$0{,}800 \pm 0{,}019$	$0{,}902 \pm 0{,}014$	0,905	8,8	8,84
W2	Wav-KAN, chapéu mexicano, $h = 32$	262.468	3	$0{,}834 \pm 0{,}017$	$0{,}799 \pm 0{,}022$	$0{,}902 \pm 0{,}013$	0,905	8,5	2,95
W3	Wav-KAN, DoG, $h = 128$	1.049.860	1	$0{,}823 \pm 0{,}020$	$0{,}793 \pm 0{,}026$	$0{,}908 \pm 0{,}015$	0,907	8,7	7,60
W4	Wav-KAN, Morlet, $h = 128$	1.049.860	1	$0{,}807 \pm 0{,}023$	$0{,}779 \pm 0{,}028$	$0{,}901 \pm 0{,}015$	0,900	8,7	8,55
W5	Wav-KAN, chapéu mexicano, $h = 480$	3.936.964	1	$0{,}834 \pm 0{,}017$	$0{,}799 \pm 0{,}022$	$0{,}903 \pm 0{,}013$	0,902	10,6	38,36

Entrada/saída. Todas as cabeças, spline ou wavelet, ficam na mesma faixa de AUC (0,901–0,908). O primeiro contraste primário, W2 contra a MLP do mesmo tamanho (b), é *inconclusivo*: a diferença de AUC é pequena e cabe na margem ($-0{,}001$, $[-0{,}004; +0{,}002]$), mas a diferença de F1 ($-0{,}012$, $[-0{,}023; -0{,}003]$) tem o limite inferior além de $-0{,}02$, então a não inferioridade não é demonstrada; a inferioridade também não, e a W2 não vence nenhuma dobra. W1 e W5 são não inferiores à MLP isoparamétrica (c) e à KAN spline (d) (a W5, com uma única semente), e a W2 não chega à não inferioridade contra (d) pelo mesmo motivo do F1. As cabeças com wavelets ordenam as imagens tão bem quanto as MLPs (mesma AUC), mas, no limiar padrão de 0,5, têm cerca de um ponto a menos de acurácia (0,834–0,835 contra 0,846) e um pouco menos de F1 (0,799–0,800 contra 0,805–0,807), com revocação macro um pouco maior. Isso indica um deslocamento do limiar de decisão ou da calibração, e não uma perda de separação. Entre as rodadas de sensibilidade, com uma semente, a cabeça derivada de gaussiana (W3) tem a maior AUC da tabela (0,908), mas F1 e acurácia menores, e a cabeça Morlet (W4) tem o menor F1 (ΔF1 contra a W1 = $-0{,}023$, $[-0{,}035; -0{,}012]$).

Distância do disparo. Aqui as cabeças com wavelets perdem com clareza: AUC de $0{,}711 \pm 0{,}116$ (W1) e $0{,}715 \pm 0{,}113$ (W2), contra 0,785–0,807 das outras cabeças. Todos os contrastes dão inferior: a W2 contra a MLP (b) tem $\Delta\mathrm{AUC} = -0{,}071$ ($[-0{,}098; -0{,}043]$) e perde nas cinco dobras, e os demais contrastes vão de $-0{,}066$ a $-0{,}086$. A variação entre dobras dobra (dp de 0,11–0,12 contra cerca de 0,06) e a acurácia cai para 0,65–0,67.

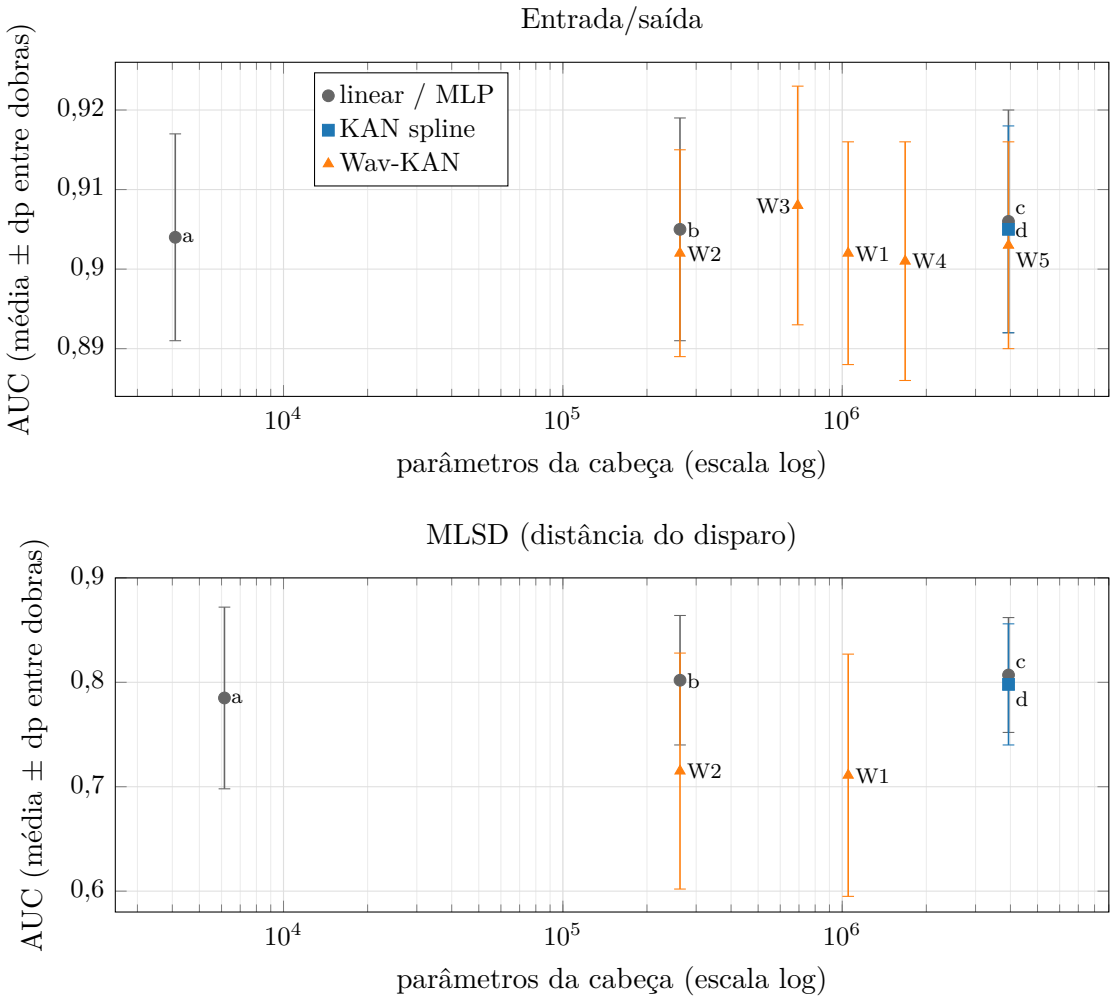


Figura 6.5: AUC (média ± dp entre dobras) em função do número de parâmetros da cabeça (escala log) para as cabeças linear e MLP, a KAN spline e as cabeças Wav-KAN. W3 e W4 têm o número de parâmetros da W1 e aparecem deslocadas na horizontal só para não se sobreporem; W3–W5 usam uma única semente.

Tabela 6.8: MLSD (só entradas; AUC = macro um-contra-o-resto): cabeças Wav-KAN contra as cabeças (a)–(d), na mesma ResNet-152 e com a mesma receita. Média ± dp entre dobras (cada dobra é a média das S sementes); F1 macro; a AUC_{OOF} junta as predições fora da dobra. Min: minutos de treino por dobra (NVIDIA L4). Cabeça ms: forward + backward só da cabeça, num lote de 32 entradas aleatórias de 2048 dimensões.

Id	Cabeça	Parâm.	S	Acc	F1	AUC	AUC_{OOF}	Min	Cabeça ms
(a)	Linear	6.147	3	$0{,}815 \pm 0{,}014$	$0{,}488 \pm 0{,}056$	$0{,}785 \pm 0{,}087$	0,797	6,3	0,48
(b)	MLP-128	262.659	3	$0{,}813 \pm 0{,}013$	$0{,}482 \pm 0{,}050$	$0{,}802 \pm 0{,}062$	0,811	6,3	0,73
(c)	MLP-iso	3.937.791	3	$0{,}821 \pm 0{,}017$	$0{,}480 \pm 0{,}050$	$0{,}807 \pm 0{,}055$	0,817	6,4	0,73
(d)	KAN spline = TransferKAN	3.937.920	3	$0{,}813 \pm 0{,}017$	$0{,}477 \pm 0{,}045$	$0{,}798 \pm 0{,}058$	0,805	6,5	3,30
W1	Wav-KAN, chapéu mexicano, $h = 128$	1.050.374	3	$0{,}671 \pm 0{,}043$	$0{,}418 \pm 0{,}034$	$0{,}711 \pm 0{,}116$	0,730	6,7	8,84
W2	Wav-KAN, chapéu mexicano, $h = 32$	262.598	3	$0{,}649 \pm 0{,}039$	$0{,}410 \pm 0{,}030$	$0{,}715 \pm 0{,}113$	0,740	6,4	2,95

Tabela 6.9: Contrastes pré-registrados das cabeças Wav-KAN (Δ = W − referência) nas predições fora da dobra (probabilidades médias das sementes em comum); IC 95% por bootstrap pareado de casos (2.000 reamostragens). Margem de não inferioridade: −0,02 no limite inferior do IC do ΔAUC e do ΔF1. Superior: AUC maior em pelo menos 4/5 dobras e IC do ΔAUC acima de zero. Inferior: AUC maior em no máximo 1/5 dobras e IC do ΔAUC abaixo de zero. Inconclusivo: nenhum dos três. Vence: dobras em que W tem a AUC maior.

Tarefa	Contraste	Papel	Sementes	ΔAUC [IC 95%]	ΔF1 [IC 95%]	Vence	Desfecho
E/S	W2 − (b)	primário 1	42–44	−0,001 [−0,004; +0,002]	−0,012 [−0,023; −0,003]	0/5	inconclusivo
E/S	W1 − (c)	primário 2	42–44	−0,002 [−0,005; +0,002]	−0,003 [−0,014; +0,008]	0/5	não inferior
E/S	W5 − (c)	primário 2	42	−0,003 [−0,008; +0,002]	−0,009 [−0,019; +0,003]	2/5	não inferior
E/S	W1 − (d)	secundário	42–44	−0,001 [−0,004; +0,003]	−0,005 [−0,016; +0,005]	1/5	não inferior
E/S	W2 − (d)	secundário	42–44	−0,001 [−0,003; +0,002]	−0,011 [−0,021; −0,002]	0/5	inconclusivo
E/S	W5 − (d)	secundário	42	−0,002 [−0,007; +0,003]	−0,008 [−0,019; +0,002]	2/5	não inferior
E/S	W1 − (b)	descritivo	42–44	−0,001 [−0,004; +0,003]	−0,007 [−0,019; +0,004]	1/5	não inferior
E/S	W3 − W1	sensibilidade	42	+0,002 [−0,002; +0,006]	−0,008 [−0,018; +0,001]	4/5	não inferior
E/S	W4 − W1	sensibilidade	42	−0,004 [−0,010; +0,001]	−0,023 [−0,035; −0,012]	1/5	inconclusivo
E/S	W3 − (d)	sensibilidade	42	+0,003 [−0,001; +0,007]	−0,014 [−0,027; −0,001]	4/5	inconclusivo
E/S	W4 − (d)	sensibilidade	42	−0,004 [−0,009; +0,001]	−0,028 [−0,044; −0,014]	1/5	inconclusivo
MLSD	W2 − (b)	primário 1	42–44	−0,071 [−0,098; −0,043]	−0,069 [−0,117; −0,021]	0/5	inferior
MLSD	W1 − (c)	primário 2	42–44	−0,086 [−0,120; −0,052]	−0,070 [−0,121; −0,024]	0/5	inferior
MLSD	W1 − (d)	secundário	42–44	−0,075 [−0,105; −0,044]	−0,067 [−0,113; −0,024]	0/5	inferior
MLSD	W2 − (d)	secundário	42–44	−0,066 [−0,096; −0,038]	−0,070 [−0,119; −0,022]	0/5	inferior
MLSD	W1 − (b)	descritivo	42–44	−0,080 [−0,109; −0,050]	−0,066 [−0,112; −0,024]	0/5	inferior

Custo e forma aprendida. As cabeças com wavelets não são mais rápidas. A W2 leva quase o mesmo tempo por dobra que a MLP-128 (8,5 contra 8,3 minutos) e o mesmo que a KAN spline (8,46 contra 8,49 minutos, uma diferença de 0,35%, dentro do ruído entre rodadas, de cerca de 0,1 minuto). A W1 é 3,6% mais lenta por dobra que a KAN spline e 5,3% mais lenta que a MLP isoparamétrica, e a W5 é 25–27% mais lenta. Sozinha, a cabeça W1 leva 8,8 ms para o passo para a frente e para trás de 32 entradas e usa 223 MB de memória, contra 0,73 ms e 0,2 MB da MLP isoparamétrica: cada camada monta um tensor de tamanho lote × saídas × entradas. As wavelets também quase não mudaram de forma. No fim das duas fases e nas duas tarefas, a escala média fica entre 0,99 e 1,003 (dp 0,013–0,020) e a translação média fica perto de 0 (dp 0,013–0,025), a partir dos valores iniciais 1 e 0. Na prática, as cabeças aprenderam os pesos de wavelets de forma fixa, e nenhum resultado pode ser atribuído ao ajuste da forma da wavelet.

Em resumo, uma KAN com wavelets não muda o quadro. Em entrada/saída ela empata com as MLPs em AUC e é um pouco pior no limiar padrão; na distância é claramente pior; e não é, na prática, nem menor que uma MLP de mesmo desempenho nem mais rápida.

6.7 Uma Rede para as Duas Tarefas

A Tabela 6.10 compara uma única ResNet-152 multitarefa com o par de redes de tarefa única, a Tabela 6.11 traz os contrastes e a Tabela 6.12, o custo.

Tabela 6.10: Uma ResNet-152 multitarefa (backbone compartilhado, uma cabeça por tarefa, $L = L_{\mathrm{E/S}} + L_{\mathrm{dist}}$, com as saídas fora de L_{dist}) contra o par de redes de tarefa única da ablação da cabeça, com as mesmas dobras e a mesma receita e sementes 42–44 nos dois lados. Média ± dp entre dobras; AUC das probabilidades (distância: macro um-contra-o-resto, só entradas); F1 macro; F1 de 4 classes: pipeline saída/encostado/curta/distância (secundário, descritivo).

Sistema	Redes	Parâm. (M)	AUC E/S	F1 E/S	AUC dist.	F1 dist.	F1 4 classes
Duas redes de tarefa única, cabeças KAN (d)	2	124,16	$0{,}905 \pm 0{,}013$	$0{,}806 \pm 0{,}013$	$0{,}798 \pm 0{,}058$	$0{,}477 \pm 0{,}045$	$0{,}500 \pm 0{,}035$
Uma rede multitarefa, cabeças KAN	1	66,02	$0{,}894 \pm 0{,}014$	$0{,}784 \pm 0{,}022$	$0{,}805 \pm 0{,}065$	$0{,}482 \pm 0{,}058$	$0{,}491 \pm 0{,}045$
Duas redes de tarefa única, cabeças MLP-128 (b)	2	116,81	$0{,}905 \pm 0{,}014$	$0{,}806 \pm 0{,}015$	$0{,}802 \pm 0{,}062$	$0{,}482 \pm 0{,}050$	$0{,}506 \pm 0{,}037$
Uma rede multitarefa, cabeças MLP-128	1	58,67	$0{,}895 \pm 0{,}014$	$0{,}787 \pm 0{,}017$	$0{,}806 \pm 0{,}071$	$0{,}492 \pm 0{,}063$	$0{,}499 \pm 0{,}045$

Entrada/saída. A rede multitarefa é pior, mas dentro da margem pré-registrada. Com cabeças KAN, a AUC vai de $0{,}905 \pm 0{,}013$ para $0{,}894 \pm 0{,}014$ ($\Delta\mathrm{AUC} = -0{,}011$, $[-0{,}015; -0{,}006]$), e com cabeças MLP, de 0,905 para 0,895 ($-0{,}010$, $[-0{,}014; -0{,}005]$). A rede multitarefa perde nas cinco dobras, então a regra classifica o resultado como pior, enquanto o limite inferior do intervalo fica acima da margem de $-0{,}02$. As duas coisas valem: a perda é pequena e consistente. No limiar padrão a queda é maior: $\Delta\mathrm{F1} = -0{,}023$ ($[-0{,}034; -0{,}011]$) com cabeças KAN e $-0{,}022$ ($[-0{,}034; -0{,}010]$) com cabeças MLP, além da margem, e a acurácia cai de 0,846 para 0,820 e 0,823. Em 5 das 30 rodadas multitarefa a acurácia de entrada/saída de uma dobra ficou um pouco abaixo de 0,80 (0,792–0,797), o que reflete essa queda; as perdas continuaram finitas e a AUC dessas dobras foi normal (0,873–0,885).

Distância do disparo. A rede multitarefa é não inferior. Com cabeças KAN a AUC é de $0{,}805 \pm 0{,}065$ contra $0{,}798 \pm 0{,}058$ ($+0{,}007$, $[-0{,}003; +0{,}018]$, 3 de 5 dobras), e com cabeças MLP, de 0,806 contra 0,802 ($+0{,}004$, $[-0{,}006; +0{,}014]$). O F1 macro também não muda. A acurácia da rede multitarefa é maior (0,824 contra 0,813), mas a acurácia balanceada é igual ou menor (0,511 contra 0,515 com cabeças KAN; 0,520 nas duas com cabeças MLP), então a acurácia não deve ser lida como ganho.

KAN contra MLP dentro da rede multitarefa. Os dois tipos de cabeça voltam a empatar: $\Delta\mathrm{AUC} = -0{,}001$ ($[-0{,}003; +0{,}0004]$) em entrada/saída e $-0{,}002$ ($[-0{,}009; +0{,}003]$) na distância. Isso compara tipos de cabeça, não eficiência: as duas cabeças KAN têm 7,87 milhões de parâmetros, contra 0,53 milhão das duas cabeças MLP.

Pipeline de quatro classes (secundário, descritivo). Combinando as duas saídas em saída, encostado, curta e distância, o F1 macro fora da dobra é de 0,485 para a rede

Tabela 6.11: Contrastes pré-registrados do estudo multitarefa (Δ = primeiro − segundo; MT = multitarefa, ST = par de redes de tarefa única), nas predições fora da dobra (probabilidades médias das sementes 42–44); IC 95% por bootstrap pareado de casos (2.000 reamostragens). Margem de não inferioridade: −0,02 no limite inferior do IC do ΔAUC. Pior: AUC maior em no máximo 1/5 dobras e IC do ΔAUC abaixo de zero; "dentro da margem": esse IC ainda fica acima de −0,02. Vence: dobras em que o primeiro sistema tem a AUC maior (o F1, nas linhas de 4 classes).

Tarefa	Contraste	Papel	ΔAUC [IC 95%]	ΔF1 [IC 95%]	Vence	Desfecho
E/S	MT-KAN − ST-KAN	primário	−0,011 [−0,015; −0,006]	−0,023 [−0,034; −0,011]	0/5	pior, dentro da margem
E/S	MT-MLP − ST-MLP	primário	−0,010 [−0,014; −0,005]	−0,022 [−0,034; −0,010]	0/5	pior, dentro da margem
E/S	MT-KAN − MT-MLP	secundário	−0,001 [−0,003; +0,0004]	−0,002 [−0,008; +0,003]	2/5	não inferior
E/S	ST-KAN − ST-MLP	descritivo	−0,0001 [−0,001; +0,001]	−0,001 [−0,006; +0,003]	3/5	descritivo
Dist.	MT-KAN − ST-KAN	primário	+0,007 [−0,003; +0,018]	−0,002 [−0,029; +0,027]	3/5	não inferior
Dist.	MT-MLP − ST-MLP	primário	+0,004 [−0,006; +0,014]	+0,007 [−0,021; +0,035]	3/5	não inferior
Dist.	MT-KAN − MT-MLP	secundário	−0,002 [−0,009; +0,003]	−0,008 [−0,014; −0,001]	2/5	não inferior
Dist.	ST-KAN − ST-MLP	descritivo	−0,005 [−0,012; +0,003]	+0,001 [−0,007; +0,010]	2/5	descritivo
4 classes	MT-KAN − ST-KAN	descritivo	—	−0,030 [−0,061; −0,004]	1/5	descritivo
4 classes	MT-MLP − ST-MLP	descritivo	—	−0,022 [−0,052; +0,004]	2/5	descritivo
4 classes	MT-KAN − MT-MLP	descritivo	—	−0,007 [−0,013; −0,002]	0/5	descritivo

multitarefa contra 0,515 para o par com cabeças KAN (ΔF1 = −0,030, [−0,061; −0,004]), e de 0,492 contra 0,514 com cabeças MLP (−0,022, [−0,052; +0,004]). A queda vem sobretudo da cabeça de entrada/saída: a rede multitarefa manda mais entradas para "saída" (283 entradas a distância previstas como saída, contra 204 no par), o que também aumenta a revocação de saída (0,788 contra 0,756). A revocação de encostado no pipeline vai de 5 para 2 das 42 imagens, poucas demais para qualquer conclusão sobre disparos encostados.

Tabela 6.12: Custo para obter as duas saídas numa NVIDIA L4 (AMP fp16). Treino: minutos por dobra (tarefa única = soma das duas redes; média ± dp nas 15 unidades) e pico de memória do treino. Inferência: ms por imagem para obter as duas saídas (um forward na rede multitarefa, dois no par; 20 aquecimentos e 200 medidas por eventos CUDA, média ± dp) e pico de memória da inferência com lote 32. O tempo não depende dos pesos e foi medido em modelos recém-criados.

		Treino		Inferência (as duas saídas)		
Sistema	Parâm. (M)	min/dobra	pico GB	ms/img, lote 1	ms/img, lote 32	pico MB
Duas redes de tarefa única, cabeças KAN (d)	124,16	14,9 ± 0,2	3,6	51,0 ± 2,1	2,22 ± 0,01	282
Uma rede multitarefa, cabeças KAN	66,02	8,6 ± 0,1	3,7	27,3 ± 0,9	1,12 ± 0,01	163
Duas redes de tarefa única, cabeças MLP-128 (b)	116,81	14,6 ± 0,1	3,5	48,5 ± 1,0	2,22 ± 0,02	287
Uma rede multitarefa, cabeças MLP-128	58,67	8,1 ± 0,1	3,5	24,3 ± 1,3	1,11 ± 0,01	163

Custo. Uma rede substitui duas. Com cabeças KAN, os parâmetros caem de 124,16 para 66,02 milhões (−46,8%), e com cabeças MLP, de 116,81 para 58,67 milhões (−49,8%). O treino leva 8,6 em vez de 14,9 minutos por dobra (KAN) e 8,1 em vez de 14,6 (MLP), com desvio-padrão de 0,1–0,2 minuto. Obter as duas saídas leva 1,12 em vez de 2,22 ms por imagem com lote 32 (2,0 vezes mais rápido) e 27,3 em vez de 51,0 ms com lote

1. O pico de memória da inferência com lote 32 cai de 282 para 163 MB, enquanto o pico de memória do treino fica quase igual (3,7 contra 3,6 GB). Essas economias vêm diretamente de fazer um passo para a frente em vez de dois; são uma vantagem de custo de compartilhar o backbone, e não um mérito de uma cabeça específica.

6.8 Resumo

Num protocolo sem vazamento de casos, os resultados sustentam as seguintes afirmações, todas ligadas a uma regra pré-registrada:

- o hold-out do código público de Lira et al. infla a AUC em +0,034 (entrada/saída) e de +0,155 a +0,158 (distância), com todo o resto fixo;
- a cabeça KAN da TransferKAN é equivalente às cabeças linear e MLP em entrada/saída (desfecho B) e, na distância, fica abaixo da MLP isoparamétrica, sendo equivalente à MLP-128 e à cabeça linear (desfecho C);
- a melhor arquitetura é a Swin-B, que supera a TransferKAN nas duas tarefas;
- as cabeças Wav-KAN não mudam esse quadro: AUC igual em entrada/saída, claramente pior na distância, e não são mais rápidas;
- uma rede multitarefa custa cerca de metade do par de redes, é não inferior na distância e um pouco pior, de forma consistente, em entrada/saída, dentro da margem.

As afirmações proibidas pelas regras pré-registradas continuam sem sustentação: que só trocar a cabeça melhora os resultados, que a TransferKAN é um novo estado da arte, que ela supera os baselines transformer e que a cabeça KAN é eficiente em parâmetros.

Capítulo 7

Conclusões

Esta dissertação se propôs a avaliar a TransferKAN, uma ResNet-152 pré-treinada com uma cabeça de classificação KAN, em duas tarefas forenses sobre fotografias reais de locais de crime: ferimentos de entrada contra saída e a distância médico-legal do disparo. Ao reexaminar uma comparação anterior, viu-se que os seus números não podiam ser atribuídos à cabeça KAN. O trabalho foi então refeito em torno de um protocolo único de avaliação sem vazamento de casos, com regras de decisão fixadas antes dos experimentos.

7.1 Respostas às Perguntas de Pesquisa

PP1: o hold-out de 2024 infla os números? Sim. O hold-out do código público de Lira et al. estratifica pelo caso em vez de agrupar por caso, de modo que 98,7% (entrada/saída) e 98,4% (distância) das imagens de teste pertencem a casos vistos no treino. Com a mesma rede, receita e semente, ele eleva a AUC de 0,906 para 0,940 em entrada/saída (+0,034) e de 0,779–0,788 para 0,937–0,942 na distância do disparo (+0,155 a +0,158). O efeito é grande onde a tarefa é difícil e as classes são raras, e ele também esconde a variabilidade entre casos. Números obtidos com essa partição não são comparáveis com resultados agrupados por caso.

PP2: a cabeça KAN melhora em relação às cabeças linear e MLP? Não. Na mesma ResNet-152 e com a mesma receita, a cabeça KAN é equivalente às cabeças linear e MLP em entrada/saída (AUC de 0,905 contra 0,904–0,906; diferença para a melhor MLP de −0,001, IC 95% [−0,002; +0,0003]; desfecho B). Na distância do disparo, ela fica abaixo da MLP com o mesmo número de parâmetros (−0,011, [−0,021; −0,003]; desfecho C) e é equivalente à MLP-128 e à cabeça linear. A cabeça KAN da TransferKAN não é a fonte dos seus resultados e, com 3,94 milhões de parâmetros, não é eficiente em parâmetros.

PP3: como se comparam os backbones? Com pré-treino no ImageNet e a mesma receita, a Swin-B é a melhor arquitetura nas duas tarefas (AUC de 0,929 em entrada/saída

e 0,838 na distância) e supera a TransferKAN nas duas. A TransferKAN fica no meio das doze arquiteturas, junto com a ResNet-152 de cabeça linear. Em relação à tabela publicada por Lira et al., os outros onze backbones têm números maiores que os publicados em entrada/saída, enquanto a TransferKAN continua abaixo da ResNet-152 deles em acurácia, F1 e AUC_c, nas duas tarefas. Essas diferenças vêm da partição, do pré-treino e da receita juntos, e não da cabeça KAN.

PP4: uma KAN com wavelets muda o quadro? Não. Em entrada/saída, as cabeças Wav-KAN ordenam as imagens tão bem quanto as MLPs (mesma AUC), mas perdem cerca de um ponto de acurácia e um pouco de F1 no limiar padrão. O contraste com uma MLP do mesmo tamanho é inconclusivo. Na distância do disparo elas são claramente piores (AUC de cerca de 0,71 contra 0,80). Elas não são mais rápidas, e as escalas e translações aprendidas quase não saíram da inicialização.

PP5: uma rede pode substituir o par? Em parte. Uma ResNet-152 com duas cabeças tem 47–50% menos parâmetros que o par, treina em 8,1–8,6 em vez de 14,6–14,9 minutos por dobra e obtém as duas saídas duas vezes mais rápido. Ela é não inferior na distância do disparo e pior em entrada/saída por cerca de 0,01 de AUC em todas as dobras, o que fica dentro da margem pré-registrada de 0,02, mas é consistente, com uma queda maior no F1. Quando o custo importa mais que um centésimo de AUC em entrada/saída, ela é uma substituta razoável.

Em conjunto, a hipótese que motivou este trabalho, de que trocar a cabeça MLP por uma KAN melhora a classificação, tem resposta negativa, e com duas famílias de KAN. As contribuições positivas são metodológicas, uma partição auditada e um protocolo em que as arquiteturas podem ser comparadas, e práticas, uma única rede para as duas tarefas a cerca de metade do custo.

7.2 Limitações

As respostas acima valem dentro de limites impostos pelos dados, pelo desenho experimental e pela comparação com o trabalho anterior. O primeiro e mais importante limite vem dos dados. Todas as imagens vêm de uma única polícia de uma única região, e não foi possível fazer uma validação externa; não se sabe, portanto, como os modelos se comportariam com fotografias feitas por outras equipes, com outros equipamentos e em outras condições. Dentro desta base, a classe encostado é o caso mais restritivo: ela tem só 42 imagens de 16 casos, e só 13–17% dessas imagens são reconhecidas quando o seu caso não está no treino (Seção 6.3). Com tão poucos casos, nada específico pode ser afirmado sobre essa classe.

O desenho experimental impõe outras restrições. Todos os modelos são avaliados na última época, sem uma partição interna de validação. Como a regra é a mesma para todos os modelos, ela é justa entre eles, mas não é otimizada para nenhum. Da mesma forma, a receita do notebook original da TransferKAN foi mantida para todos os modelos, inclusive um ruído gaussiano forte que pode apagar vestígios finos como a tatuagem; ela não favorece nenhum modelo, mas outras receitas podem mudar os números absolutos. O número de sementes também varia entre os experimentos: a Swin-B e a MaxViT-T têm duas sementes na tarefa de distância, e a maioria dos outros backbones, a KAN pequena (e) e as cabeças Wav-KAN W3–W5 têm uma única semente. Os resultados desses modelos carregam, portanto, mais incerteza que os da ablação da cabeça, que usa três sementes (Seção 5.12).

Por fim, duas limitações dizem respeito à comparação com Lira et al. O experimento de vazamento reproduz o método do código público deles, e não a partição exata por trás das tabelas publicadas, que não pode ser recuperada; ele mede o efeito desse método de partição, e o código usado no artigo pode ter sido diferente. Além disso, a comparação com a tabela publicada sugere um efeito grande do pré-treino no ImageNet, mas nenhum modelo foi treinado do zero no protocolo único; esse efeito é, portanto, sugerido por este trabalho, mas não medido nele (Seção 6.4). A maior parte dessas limitações vale igualmente para todos os modelos e, por isso, não enviesa as comparações feitas no protocolo único; o que elas restringem é o alcance dos números absolutos e das conclusões para além desta base.

7.3 Trabalhos Futuros

Os resultados e as limitações acima sugerem cinco direções para trabalhos futuros. A primeira decorre diretamente da ablação da cabeça. Como a cabeça KAN não melhorou a ResNet-152, resta saber se esse resultado se mantém com um extrator de características mais forte, o que pode ser testado treinando uma cabeça KAN sobre a Swin-B, o melhor backbone no protocolo único.

A segunda direção trata da principal limitação dos dados. Reunir mais casos de encostado, assim como imagens de outras instituições, permitiria que a classe minoritária fosse aprendida e que os modelos fossem validados fora da base original, de modo que as conclusões deixassem de depender de uma única polícia e de uma única região.

A terceira e a quarta direções dizem respeito às alternativas avaliadas neste trabalho. As cabeças Wav-KAN e a rede multitarefa perdem sobretudo no limiar padrão (Seções 6.6 e 6.7), o que motiva calibrar as probabilidades e escolher o limiar de decisão numa partição interna de validação. No caso da rede multitarefa, ponderar as perdas das tarefas, por

exemplo pela sua incerteza, poderia recuperar a sua pequena perda em entrada/saída e reforçar o seu uso como substituta do par de redes.

A última direção diz respeito ao fator que este trabalho não conseguiu isolar. As diferenças em relação aos números publicados por Lira et al. foram atribuídas à partição, ao pré-treino e à receita, mas só o efeito da partição foi medido. Treinar alguns backbones do zero no protocolo único mediria também o efeito do pré-treino e tornaria mais completa a comparação com os resultados anteriores.

Referências

[1] Queiroz Nogueira Lira, Renato, Luana Geovana Motta de Sousa, Maisa Luana Memoria Pinho, Renan Cesar Pinto da Silva Andrade de Lima, Pedro Garcia Freitas, Bruno Scholles Soares Dias, Andreia Cristina Breda de Souza e André Ferreira Leite: *Deep learning-based human gunshot wounds classification*. International Journal of Legal Medicine, 139(2):651–666, 2025. xii, xiii, xiv, 1, 10, 11, 15, 16, 18, 29, 33, 49, 50

[2] United Nations Office on Drugs and Crime (UNODC): *Global study on homicide 2023*. `https://www.unodc.org/unodc/en/data-and-analysis/global-study-on-homicide.html`, 2023. Accessed: 2024-03-08. 1

[3] Liu, Ziming, Yixuan Wang, Sachin Vaidya, Fabian Ruehle, James Halverson, Marin Soljačić, Thomas Y Hou e Max Tegmark: *KAN: Kolmogorov-Arnold networks*. arXiv preprint arXiv:2404.19756, 2024. 1, 6, 12

[4] Di Maio, Vincent J M: *Gunshot Wounds: Practical Aspects of Firearms, Ballistics, and Forensic Techniques*. CRC Press, Boca Raton, FL, USA, 3ª edição, 2015. 4, 5

[5] Saukko, Pekka J e Bernard Knight: *Knight's Forensic Pathology*. CRC Press, Boca Raton, FL, USA, 4ª edição, 2016. 4

[6] He, Kaiming, Xiangyu Zhang, Shaoqing Ren e Jian Sun: *Deep residual learning for image recognition*. Em *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 770–778, 2016. 5, 13, 20

[7] Deng, Jia, Wei Dong, Richard Socher, Li Jia Li, Kai Li e Li Fei-Fei: *ImageNet: A large-scale hierarchical image database*. Em *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 248–255, 2009. 5, 13, 19

[8] Liu, Ze, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin e Baining Guo: *Swin transformer: Hierarchical vision transformer using shifted windows*. Em *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, páginas 10012–10022, 2021. 5, 20

[9] Tu, Zhengzhong, Hossein Talebi, Han Zhang, Feng Yang, Peyman Milanfar, Alan Bovik e Yinxiao Li: *MaxViT: Multi-axis vision transformer*. Em *Computer Vision – ECCV 2022*, volume 13684 de *Lecture Notes in Computer Science*, páginas 459–479. Springer, 2022. 5, 20

[10] Blealtan: *efficient-kan: An efficient implementation of Kolmogorov-Arnold network*. `https://github.com/Blealtan/efficient-kan`, 2024. Commit 7b6ce1c. 6, 12, 13, 20

[11] Bozorgasl, Zavareh e Hao Chen: *Wav-KAN: Wavelet Kolmogorov-Arnold networks*. arXiv preprint arXiv:2405.12832, 2024. 7, 12, 14, 21

[12] Kapoor, Sayash e Arvind Narayanan: *Leakage and the reproducibility crisis in machine-learning-based science*. Patterns, 4(9):100804, 2023. 7

[13] Roberts, David R., Volker Bahn, Simone Ciuti, Mark S. Boyce, Jane Elith, Gurutzeta Guillera-Arroita, Severin Hauenstein, José J. Lahoz-Monfort, Boris Schröder, Wilfried Thuiller, David I. Warton, Brendan A. Wintle, Florian Hartig e Carsten F. Dormann: *Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure*. Ecography, 40(8):913–929, 2017. 7

[14] Sechidis, Konstantinos, Grigorios Tsoumakas e Ioannis Vlahavas: *On the stratification of multi-label data*. Em *Machine Learning and Knowledge Discovery in Databases (ECML PKDD 2011)*, volume 6913 de *Lecture Notes in Computer Science*, páginas 145–158. Springer, 2011. 7, 11, 21

[15] Fawcett, Tom: *An introduction to ROC analysis*. Pattern Recognition Letters, 27(8):861–874, 2006. 7, 23

[16] Caruana, Rich: *Multitask learning*. Machine Learning, 28(1):41–75, 1997. 8, 22

[17] Ruder, Sebastian: *An overview of multi-task learning in deep neural networks*. arXiv preprint arXiv:1706.05098, 2017. 8, 22

[18] Efron, Bradley e Robert J. Tibshirani: *An Introduction to the Bootstrap*. Chapman & Hall, New York, 1993. 8, 23

[19] Oura, Petteri, Anneli Junno e Juho Antti Junno: *Deep learning in forensic gunshot wound interpretation—a proof-of-concept study*. International Journal of Legal Medicine, 135:2101–2106, 2021. 10

[20] Cheng, Jerome, Carl Schmidt, Allecia Wilson, Zhaohui Wang, Wei Hao, Joshua Pantanowitz, Christopher Morris, Robert Tashjian e Liron Pantanowitz: *Artificial intelligence for human gunshot wound classification*. Journal of Pathology Informatics, 15:100361, 2024. 10

[21] LISA/UnB: *LeGuWoI: Learned gunshot wound identification (source code)*. `https://gitlab.com/lisa-unb/leguwoi`, 2025. Commit 83d82f1 (2025-04-03). 11, 17, 20, 21, 23

[22] Drokin, Ivan: *torch-conv-kan: Kolmogorov-Arnold convolutional networks in PyTorch*. `https://github.com/IvanDrokin/torch-conv-kan`, 2024. Commit b412a3b. 12, 22, 51

[23] Garcia Freitas, Pedro: *FDCPUnBGunshotDB: gunshot wound image database*. `https://github.com/pedrogarciafreitas/FDCPUnBGunshotDB`, 2025. Commit f679389. 16

[24] Pedregosa, Fabian, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot e Édouard Duchesnay: *Scikit-learn: Machine learning in Python*. Journal of Machine Learning Research, 12:2825–2830, 2011. 17

[25] Paszke, Adam, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga *et al.*: *PyTorch: An imperative style, high-performance deep learning library*. Em *Advances in Neural Information Processing Systems (NeurIPS)*, volume 32, páginas 8024–8035, 2019. 19

[26] Loshchilov, Ilya e Frank Hutter: *Decoupled weight decay regularization*. Em *International Conference on Learning Representations (ICLR)*, 2019. 19

[27] Loshchilov, Ilya e Frank Hutter: *SGDR: Stochastic gradient descent with warm restarts*. Em *International Conference on Learning Representations (ICLR)*, 2017. 19

[28] Buslaev, Alexander, Vladimir I Iglovikov, Eugene Khvedchenya, Alex Parinov, Mikhail Druzhinin e Alexandr A Kalinin: *Albumentations: Fast and flexible image augmentations*. Information, 11(2):125, 2020. 19

[29] Micikevicius, Paulius, Sharan Narang, Jonah Alben, Gregory Diamos, Erich Elsen, David Garcia, Boris Ginsburg, Michael Houston, Oleksii Kuchaiev, Ganesh Venkatesh e Hao Wu: *Mixed precision training*. Em *International Conference on Learning Representations (ICLR)*, 2018. 20

[30] Krizhevsky, Alex, Ilya Sutskever e Geoffrey E. Hinton: *ImageNet classification with deep convolutional neural networks*. Em *Advances in Neural Information Processing Systems 25 (NIPS 2012)*, páginas 1097–1105, 2012. 20

[31] Sandler, Mark, Andrew Howard, Menglong Zhu, Andrey Zhmoginov e Liang Chieh Chen: *MobileNetV2: Inverted residuals and linear bottlenecks*. Em *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 4510–4520, 2018. 20

[32] Tan, Mingxing, Bo Chen, Ruoming Pang, Vijay Vasudevan, Mark Sandler, Andrew Howard e Quoc V. Le: *MnasNet: Platform-aware neural architecture search for mobile*. Em *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 2820–2828, 2019. 20

[33] Ma, Ningning, Xiangyu Zhang, Hai Tao Zheng e Jian Sun: *ShuffleNet V2: Practical guidelines for efficient CNN architecture design*. Em *Computer Vision – ECCV 2018*, volume 11218 de *Lecture Notes in Computer Science*, páginas 116–131. Springer, 2018. 20

[34] Iandola, Forrest N., Song Han, Matthew W. Moskewicz, Khalid Ashraf, William J. Dally e Kurt Keutzer: *SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size*. arXiv preprint arXiv:1602.07360, 2016. 20

[35] Huang, Gao, Zhuang Liu, Laurens van der Maaten e Kilian Q. Weinberger: *Densely connected convolutional networks*. Em *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 4700–4708, 2017. 20

[36] Tan, Mingxing e Quoc V. Le: *EfficientNetV2: Smaller models and faster training*. Em *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 de *Proceedings of Machine Learning Research*, páginas 10096–10106, 2021. 20

[37] Simonyan, Karen e Andrew Zisserman: *Very deep convolutional networks for large-scale image recognition*. Em *International Conference on Learning Representations (ICLR)*, 2015. 20

[38] Radosavovic, Ilija, Raj Prateek Kosaraju, Ross Girshick, Kaiming He e Piotr Dollár: *Designing network design spaces*. Em *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 10428–10436, 2020. 20

Apêndice A

Resultados no Formato de Lira et al.

Lira et al. [1] relatam cada métrica com médias macro (M), micro (m) e ponderada (W). Para quem quiser comparar formatos, as Tabelas A.1 e A.2 trazem os resultados do protocolo único nesse formato. Na tarefa binária, a precisão, a revocação e o F1 micro são iguais à acurácia e a especificidade macro é igual à revocação macro, por isso as tabelas principais os omitem. Aqui a AUC é calculada das probabilidades; a AUC das classes previstas, usada por Lira et al., está nas Tabelas 6.4 e 6.5. A comparação com os números deles está sujeita às ressalvas da Seção 6.4.

Tabela A.1: Entrada/saída no protocolo único, no formato de Lira et al. [1]: M = macro, m = micro, W = ponderada. Média entre dobras (os desvios-padrão estão nos arquivos de resultados do repositório); AUC das probabilidades previstas. Sementes como nas tabelas principais.

	Acc	Precisão			Revocação			F1			AUC			Especificidade		
Modelo		M	m	W	M	m	W	M	m	W	M	m	W	M	m	W
ResNet152 + Linear (a)	0,846	0,800	0,846	0,852	0,814	0,846	0,846	0,805	0,846	0,847	0,904	0,925	0,904	0,814	0,846	0,783
ResNet152 + MLP-128 (b)	0,846	0,800	0,846	0,852	0,815	0,846	0,846	0,806	0,846	0,848	0,905	0,926	0,905	0,815	0,846	0,784
ResNet152 + MLP-iso (c)	0,846	0,801	0,846	0,853	0,817	0,846	0,846	0,807	0,846	0,848	0,906	0,926	0,906	0,817	0,846	0,789
ResNet152 + KAN (d) = TransferKAN	0,846	0,800	0,846	0,852	0,816	0,846	0,846	0,806	0,846	0,848	0,905	0,925	0,905	0,816	0,846	0,786
ResNet152 + KAN-8 (e)	0,846	0,800	0,846	0,854	0,819	0,846	0,846	0,808	0,846	0,848	0,903	0,921	0,903	0,819	0,846	0,793
AlexNet	0,803	0,750	0,803	0,822	0,782	0,803	0,803	0,761	0,803	0,809	0,859	0,881	0,859	0,782	0,803	0,761
MobileNetV2	0,812	0,763	0,812	0,835	0,802	0,812	0,812	0,776	0,812	0,819	0,877	0,890	0,877	0,802	0,812	0,792
MNASNet1.3	0,837	0,829	0,837	0,835	0,725	0,837	0,837	0,753	0,837	0,822	0,872	0,911	0,872	0,725	0,837	0,613
ShuffleNetV2 x0.5	0,746	0,706	0,746	0,799	0,755	0,746	0,746	0,713	0,746	0,759	0,839	0,826	0,839	0,755	0,746	0,764
SqueezeNet1.0	0,798	0,749	0,798	0,824	0,787	0,798	0,798	0,760	0,798	0,805	0,866	0,875	0,866	0,787	0,798	0,776
DenseNet169	0,858	0,814	0,858	0,863	0,830	0,858	0,858	0,821	0,858	0,860	0,904	0,924	0,904	0,830	0,858	0,801
MaxViT-T	0,864	0,821	0,864	0,873	0,846	0,864	0,864	0,831	0,864	0,867	0,917	0,930	0,917	0,846	0,864	0,827
Swin-B	0,884	0,850	0,884	0,884	0,850	0,884	0,884	0,850	0,884	0,884	0,929	0,948	0,929	0,850	0,884	0,816
EfficientNetV2-L	0,868	0,828	0,868	0,870	0,836	0,868	0,868	0,831	0,868	0,869	0,916	0,934	0,916	0,836	0,868	0,804
VGG16	0,841	0,794	0,841	0,842	0,796	0,841	0,841	0,794	0,841	0,841	0,891	0,920	0,891	0,796	0,841	0,752
RegNetY-16GF	0,852	0,807	0,852	0,858	0,824	0,852	0,852	0,815	0,852	0,854	0,906	0,925	0,906	0,824	0,852	0,796

Tabela A.2: MLSD (só entradas) no protocolo único, no formato de Lira et al. [1]: M = macro, m = micro, W = ponderada. Média entre dobras (os desvios-padrão estão nos arquivos de resultados do repositório); AUC das probabilidades previstas. Sementes como nas tabelas principais.

	Acc	Precisão			Revocação			F1			AUC			Especificidade		
Modelo		M	m	W	M	m	W	M	m	W	M	m	W	M	m	W
ResNet152 + Linear (a)	0,815	0,487	0,815	0,843	0,524	0,815	0,815	0,488	0,815	0,825	0,785	0,937	0,820	0,816	0,908	0,632
ResNet152 + MLP-128 (b)	0,813	0,477	0,813	0,842	0,520	0,813	0,813	0,482	0,813	0,823	0,802	0,938	0,827	0,817	0,906	0,639
ResNet152 + MLP-iso (c)	0,821	0,482	0,821	0,842	0,510	0,821	0,821	0,480	0,821	0,828	0,807	0,941	0,824	0,814	0,910	0,622
ResNet152 + KAN (d) = TransferKAN	0,813	0,477	0,813	0,840	0,515	0,813	0,813	0,477	0,813	0,822	0,798	0,937	0,822	0,813	0,906	0,628
AlexNet	0,780	0,485	0,780	0,844	0,561	0,780	0,780	0,498	0,780	0,804	0,806	0,923	0,823	0,827	0,890	0,700
MobileNetV2	0,778	0,457	0,778	0,834	0,513	0,778	0,778	0,464	0,778	0,800	0,806	0,923	0,806	0,807	0,889	0,643
MNASNet1.3	0,451	0,383	0,451	0,841	0,455	0,451	0,451	0,294	0,451	0,518	0,710	0,678	0,768	0,765	0,725	0,843
ShuffleNetV2 x0.5	0,854	0,483	0,854	0,832	0,474	0,854	0,854	0,474	0,854	0,840	0,776	0,939	0,770	0,780	0,927	0,487
SqueezeNet1.0	0,788	0,487	0,788	0,837	0,525	0,788	0,788	0,490	0,788	0,807	0,805	0,924	0,803	0,807	0,894	0,632
DenseNet169	0,820	0,505	0,820	0,848	0,556	0,820	0,820	0,519	0,820	0,831	0,821	0,942	0,839	0,826	0,910	0,658
MaxViT-T	0,810	0,498	0,810	0,851	0,555	0,810	0,810	0,511	0,810	0,826	0,828	0,940	0,833	0,828	0,905	0,673
Swin-B	0,825	0,504	0,825	0,850	0,540	0,825	0,825	0,505	0,825	0,834	0,838	0,944	0,843	0,829	0,913	0,661
EfficientNetV2-L	0,830	0,499	0,830	0,847	0,529	0,830	0,830	0,495	0,830	0,835	0,744	0,936	0,800	0,817	0,915	0,621
VGG16	0,844	0,469	0,844	0,839	0,510	0,844	0,844	0,481	0,844	0,840	0,776	0,944	0,782	0,802	0,922	0,563
RegNetY-16GF	0,826	0,494	0,826	0,849	0,531	0,826	0,826	0,496	0,826	0,834	0,773	0,941	0,826	0,826	0,913	0,652

Apêndice B

Experimentos Exploratórios

Antes do protocolo único, foram exploradas três arquiteturas KAN treinadas do zero, para ver até onde uma KAN chegaria sem um extrator de características pré-treinado. Elas ficam registradas aqui por completude. Os números vêm de outro cenário e *não* são comparáveis com nenhum resultado do Capítulo 6.

- **ResKANet-18:** uma rede residual cujas próprias convoluções são parametrizadas por splines (`reskanet_18x32p` da `torch-conv-kan` [22]), treinada do zero com entradas de 128×128.
- **PureConvKAN:** três blocos convolucionais KAN (16, 32 e 64 canais), cada um seguido de max-pooling e normalização em lote, depois pooling médio global, Dropout(0,5) e uma camada linear de saída; treinada do zero com entradas de 128×128.
- **PureKAN:** a imagem achatada num vetor de pixels e passada diretamente a uma KAN, sem convolução; entradas de 64×64 ($3 \times 64 \times 64 = 12.288$ entradas).

A ResKANet-18 foi treinada só em entrada/saída, e a PureConvKAN e a PureKAN, nas duas tarefas. Todas foram treinadas por 60 épocas, de ponta a ponta, com AdamW e lotes de 8 imagens. Foram avaliadas num único hold-out 80/20 separado por caso, que evita o vazamento de casos, mas é uma única partição, com resolução menor e uma receita diferente da do protocolo único. A Tabela B.1 traz os resultados.

A única leitura que esses números sustentam é qualitativa: sem um extrator pré-treinado, as arquiteturas KAN chegam a 0,69–0,82 de acurácia em entrada/saída, e na tarefa de distância a AUC macro das duas fica perto do acaso ou abaixo dele (0,46–0,54), ou seja, aprendem pouco sobre as classes minoritárias. Isso é coerente com o achado principal de que é o backbone pré-treinado, e não a KAN, que faz a discriminação.

Tabela B.1: Arquiteturas KAN exploratórias treinadas do zero (sem pré-treino no ImageNet) numa fase anterior deste trabalho. Usaram um único hold-out 80/20 por caso, entradas de 64 ou 128 px, lotes de 8 e receita própria, portanto *não* são comparáveis com nenhum número obtido no protocolo único. M = macro, m = micro, W = ponderada.

		Acc	Precisão			Revocação			F1			AUC			Especificidade		
Modelo	Entrada		M	m	W	M	m	W	M	m	W	M	m	W	M	m	W
Entrada/saída																	
ResKANet-18	128 px	0,822	0,767	0,822	0,820	0,762	0,822	0,822	0,765	0,822	0,821	0,839	0,885	0,839	0,762	0,822	0,703
PureConvKAN	128 px	0,707	0,614	0,707	0,704	0,611	0,707	0,707	0,613	0,707	0,706	0,682	0,768	0,682	0,611	0,707	0,516
PureKAN	64 px	0,692	0,614	0,692	0,692	0,614	0,692	0,692	0,614	0,692	0,692	0,684	0,733	0,684	0,614	0,692	0,536
MLSD																	
PureConvKAN	128 px	0,803	0,268	0,803	0,645	0,333	0,803	0,803	0,297	0,803	0,716	0,536	0,888	0,509	0,667	0,902	0,197
PureKAN	64 px	0,712	0,355	0,712	0,689	0,324	0,712	0,712	0,328	0,712	0,693	0,463	0,841	0,496	0,679	0,856	0,326

Anexo I

Artigos Produzidos

TransKAN: Transfer Learning and Kolmogorov Arnold Networks for Gunshot Wound Classification

Arthur Silva Carneiro[1], **Pedro Garcia Freitas**[1]

[1]Department of Computer Science
University of Brasília, Brasília, Brazil

arthur.carneiro@aluno.unb.br, pedro.freitas@unb.br

Abstract. *Determining wound orientation (entry or exit) and estimating medico-legal shooting distance (MLSD) remain highly complex forensic challenges. These tasks rely on specialized forensics experts and remain highly sensitive to crime scene illumination and imaging conditions. Despite the recent advancements in machine learning (ML) techniques, particularly deep learning (DL) and its applications in computer vision (CV), its applications in these forensics tasks remain under-explored. Recent progress in DL has led to the development of automated classifiers that achieve high performance by processing raw gunshot wound imagery. However, despite these efforts, techniques reported in the literature for gunshot wound classification (GSWC) perform below expectations when compared to other CV tasks, such as diabetic retinopathy screening, medical image classification, biometric identification [Freitas et al. 2023b, Fioravanti et al. 2024], and many others. To overcome these challenges, we introduce TransKAN, a novel hybrid architecture that leverages transfer learning and Kolmogorov-Arnold networks (KANs). Specifically, TransKAN leverages a pre-trained ResNet152 network to extract high-level spatial features, substituting the conventional dense classifier with a KAN to capture intricate non-linear relationships more efficiently. In order to validate TransKAN, we present Gunshot Wound Image Database (GuWID), a comprehensive database created using real photographic records of homicide and suicide cases and examined by crime scene forensic experts from incidents attended by Federal District Civil Police (PCDF). Images within the GuWID dataset were collected between January 2012 and March 2022, comprising a total of 2,551 images (1,883 entry and 668 exit wounds). Categorized by MLSD, the dataset includes 1,609 distant, 232 close-range, and 42 contact shots. Experimental results show that TransKAN demonstrate achieves state-of-the-art (SOTA) performance on the GuWID dataset.*

1. Introduction

Handguns are a primary instrument of global homicide, accounting for three-quarters of lethal acts in the Americas in 2021 [UNODC 2023], with Brazil alone exceeding 47,000 annual firearm deaths [Wisevoter 2024]. Forensic experts must therefore differentiate entry from exit wounds and classify the range at which they were inflicted [Kleypas and Badiye 2024, Shrestha et al. 2024], based on shape, dimensions, and border characteristics [Denton et al. 2006] that can be obscured, missing, or mixed. Projectile velocity,

TransKAN: Transfer Learning and Kolmogorov–Arnold Networks for Gunshot Wound Classification

Arthur Silva Carneiro and **Pedro Garcia Freitas**

Department of Computer Science, University of Brasília (UnB), Brasília, Brazil

arthur.carneiro@aluno.unb.br pedro.freitas@unb.br Silva015

SIBGRAPI 2026 — Conference on Graphics, Patterns and Images



Telling an **entry** from an **exit** gunshot wound, and estimating the **shooting distance**, are core forensic tasks. They still rely on expert judgement and depend on lighting and imaging conditions at the scene. Deep CNNs have been tried, but conventional fully connected (MLP) heads struggle with the *irregular, noisy and imbalanced* decision boundaries of real forensic photographs. **TransKAN** keeps a pre-trained **ResNet-152** backbone and replaces its dense classifier with a **Kolmogorov–Arnold Network (KAN)** head, which has *learnable spline activations on every edge*. It is validated on **GuWID**, a new database of **2,551 real wound images** from Federal District Civil Police (PCDF) casework.

Real Forensic Evidence

⚠ *Contains real forensic imagery.*

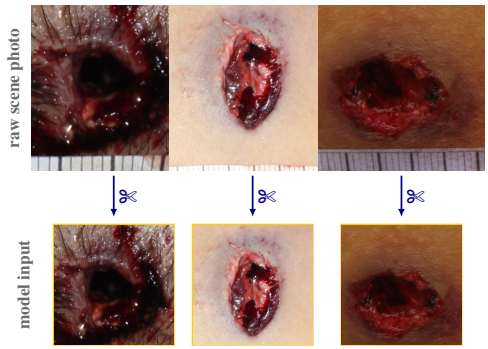


Figure 1: From crime-scene photograph to model input. Raw PCDF photographs (top; note the forensic ruler) are cropped in GIMP to a square region centred on the wound (bottom), then resized to 224×224. All three samples are entry wounds.

GuWID: Gunshot Wound Image Database

Built from records of **real homicide and suicide cases** examined by PCDF forensic experts (UnB Research Ethics Committee, protocol 4418221.9.0000.0030). Labels (wound type, anatomical location, shooting distance) were transcribed *verbatim* from the forensic pathologist's autopsy reports.

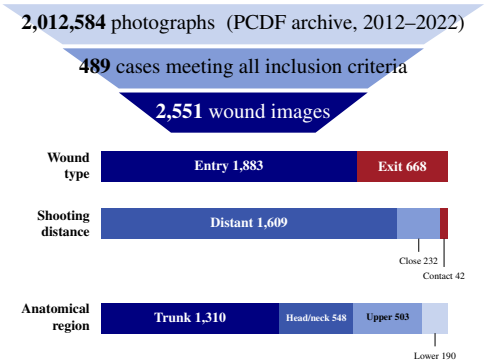


Figure 2: GuWID is heavily imbalanced, reflecting the real rarity of some injuries: exit wounds are 26% of the data and contact shots only 2.2% of entry wounds. 95.5% of images come from male victims, which matches the regional profile of firearm deaths.

TransKAN Architecture

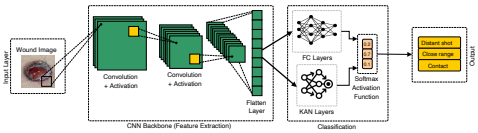
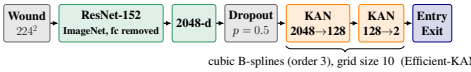


Figure 3: Pipeline. A CNN backbone extracts features that are flattened and passed to *either* a conventional FC head (baseline) *or* our KAN head. The two heads are separate configurations, trained and evaluated independently. They are drawn side by side only for comparison.



Why a KAN head? MLP vs. KAN

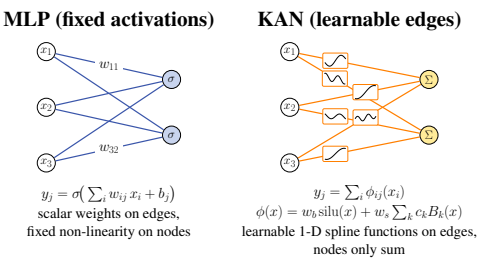


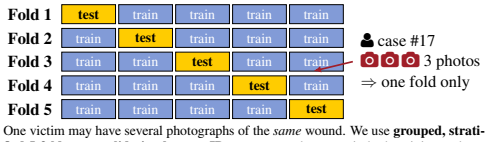
Figure 4: Edges learn their own activation. Each KAN edge is a B-spline ϕ_{ij} whose shape is learned. This gives the classifier the flexibility to fit irregular boundaries between morphologically similar wounds *without* extra depth, and only in the head, so the trainable parameter count stays modest on a few thousand images. The design is motivated by the Kolmogorov–Arnold representation theorem.

Imbalance Handling & Augmentation



All steps are **re-fit inside each training fold only**, so validation and test data are never touched.

Leakage-Free Evaluation

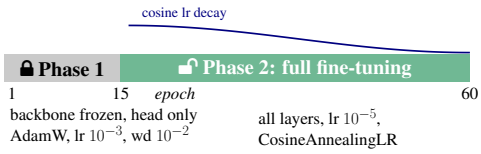


One victim may have several photographs of the *same* wound. We use **grouped, stratified 5-fold cross-validation by case ID**, so no wound appears in both training and test data. **All 12 baseline families were re-trained under exactly the same protocol**, and out-of-fold predictions are aggregated into the final metrics.

Take-home Messages

- Replacing only the **classifier head** (MLP→KAN) on a ResNet-152 improves precision, F1 and class separation (AUC) on real forensic images.
- **GuWID**: 2,551 authentic wound images, labelled from autopsy reports.
- **Case-grouped** cross-validation removes the photo-level leakage that inflates results.

Two-Phase Training



Results: Entry vs. Exit

macro F1	macro Precision	Accuracy	macro AUC
0.832	**0.847**	**0.871**	**0.893**
ResNet-152: 0.824	ResNet-152: 0.827	ResNet-152: 0.869	ResNet-152: 0.821

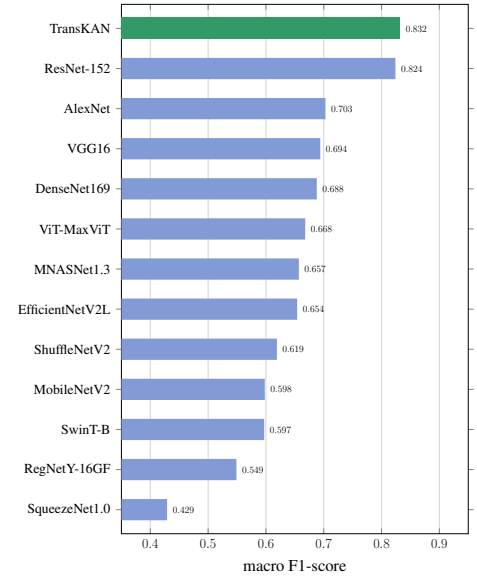


Figure 5: Wound-type classification, grouped 5-fold CV. Best variant of each architecture family. Lightweight models (MobileNet, ShuffleNet, SqueezeNet) form the lower bound. Isotropic ViTs are inconsistent at this data scale. Deep residual backbones are strongest, and **TransKAN matches or exceeds ResNet-152 on every primary metric**.

	Precision	Recall	F1	AUC	Specificity
	macro / micro	macro / micro	macro / micro	macro / micro	macro / micro
ResNet-152	.827 / .869	.821 / .869	.824 / .869	.821 / .821	.821 / .869
TransKAN	**.847 / .871**	.821 / **.871**	**.832 / .871**	**.893 / .924**	.821 / **.871**

Table 1: Head-to-head with the strongest baseline (out-of-fold, grouped 5-fold CV). In this binary task, the micro averages equal accuracy.

Future Work

Joint multi-task entry/exit and MLSD (contact / close-range / distant) estimation. Wavelet-based KANs to cut cost. External validation on international forensic databases. Code and data will be released after acceptance.

References. [1] Z. Liu *et al.*, "KAN: Kolmogorov–Arnold Networks," ICLR 2025. [2] R. Queiroz Nogueira Lira *et al.*, "Deep learning-based human gunshot wounds classification," *Int. J. Legal Med.*, 139(2), 2025. [3] K. He *et al.*, "Deep residual learning for image recognition," CVPR 2016. [4] Efficient-KAN, github.com/Blealtan/efficient-kan. [5] A. Buslaev *et al.*, "Albumentations," *Information*, 11(2), 2020.

Acknowledgements. We thank the forensic experts of the Federal District Civil Police (PCDF) for the case records and annotations.

Gunshot Wound Classification via Transfer Learning and Kolmogorov-Arnold Networks

Arthur Silva Carneiro
Department of Computer Science
University of Brasília
Brasília, Brazil
arthur.carneiro@aluno.unb.br

Pedro Garcia Freitas
Department of Computer Science
University of Brasília
Brasília, Brazil
pedro.freitas@unb.br

***Abstract*—Classifying the directionality of a wound (entrance versus exit) and inferring medico-legal shooting distance (MLSD) constitute intricate forensic challenges that hinge on the judgment of trained specialists, and their outcomes are strongly influenced by lighting at the crime scene and the conditions under which photographs are captured. Even though machine learning (ML) has driven substantial progress in computer vision (CV), its use for these forensic problems has received comparatively little attention. Contemporary classifiers based on deep learning (DL) can already deliver strong results straight from unprocessed gunshot wound photographs. Nevertheless, published gunshot wound classification (GSWC) methods continue to fall short of the benchmarks reached in other CV application areas, including diabetic retinopathy detection, medical image diagnosis, and biometric recognition. To close this gap, we propose TransKAN, a hybrid framework that unites transfer learning with Kolmogorov-Arnold networks (KANs). TransKAN derives high-level spatial representations through a pre-trained ResNet152 backbone, and substitutes the standard fully connected classification head with a KAN, allowing it to capture complex non-linear relationships with greater efficiency. In order to evaluate TransKAN, we introduce the Gunshot Wound Image Database (GuWID), a collection of authentic photographic evidence drawn from homicide and suicide cases assessed by forensic specialists in incidents handled by the Federal District Civil Police (PCDF). Gathered from January 2012 through March 2022, GuWID contains 2,551 images (1,883 depicting entry wounds and 668 depicting exit wounds), classified by MLSD into 1,609 distant-range, 232 close-range, and 42 contact-range shots. Empirical findings demonstrate that TransKAN attains state-of-the-art (SOTA) results. GuWID dataset and source code can be accessed at https://github.com/Silva015/tcc-2026/tree/main/notebooks and https://github.com/pedrogarciafreitas/GuWID-UnB.**

***Index Terms*—Forensic image analysis, gunshot wound classification, transfer learning, Kolmogorov-Arnold networks, deep learning, medico-legal shooting distance**

I. Introduction

Handguns are the leading cause of homicides worldwide, causing three-quarters of killings in the Americas in 2021 [1]. Brazil records the most such deaths, surpassing 47,000 yearly [2]. Forensic professionals thus routinely examine gunshot wounds during crime scene work and autopsies. A key task involves distinguishing entry from exit wounds and classifying entry injuries by firing distance [3], [4].

Telling these wounds apart depends on assessing their shape, size, and edge features [5]. Yet these traits may be unclear, absent, or blended, making identification difficult. Bullet speed, angle of travel, ammunition kind, caliber, obstacles in the path, and the body area struck also change how a wound looks [6], [7]. These same factors also affect the legal classification of firing range, which uses visible tissue damage to sort wounds into contact, close-range, or distant groups [8]. Since this system relies solely on physical evidence on the body, it acts as a guide for reconstructing events [7]

To help courts remain impartial, forensic findings must be based on objective, scientifically proven standards [9]. ML and artificial intelligence (AI) have lately grown within forensic medicine to improve and speed up criminal probes [10], [11]. Computer vision has been applied to study ballistic injuries, but early studies were limited by small sample sizes, dependence on animal models [12], or failure to assess the MLSD when working with autopsy data [13].

Meanwhile, transformer-based classifiers have already reached competitive accuracy in other biometric domains, such as photoplethysmography-based health monitoring [14]–[17], underscoring how much room remains for similar gains in gunshot wound classification. Data-driven quality-descriptor advances have likewise extended to other imaging modalities, including geometry- and texture-aware quality assessment for 3D point clouds [18]–[20], further illustrating how broadly such descriptors are replacing traditional reference-based metrics. Recent studies show forensic practitioners increasingly adopting AI across their work, from digital forensics to forensic pathology [21]. Many see AI as a way to boost efficiency, accuracy, and automation in tasks like evidence analysis and case triage. For example, applying DL to forensic wound analysis could enable automated, precise, and repeatable testing [22], [23]. These studies mostly depend on traditional convolutional neural networks (CNNs), which use standard multilayer perceptrons (MLPs) in their final classification stages. Though these architectures work well under general conditions, they struggle to capture the highly non-linear, complex feature boundaries found in noisy, imbalanced, and unstandardized forensic wound images. Thus, more advanced classifiers are needed, ones able to extract and separate non-linear patterns without requiring vastly larger datasets or huge parameter counts.

To meet this need for classifiers that capture non-linear patterns without massive datasets or parameter counts, we

International Conference on Artificial Intelligence, Computer, Data Sciences and Applications (ACDSA 2027)

September 25, 2026

ACCEPTANCE LETTER

Dear Silva Carneiro, Arthur; Garcia Freitas, Pedro*

Thank you for your submission to the International Conference on Artificial Intelligence, Computer, Data Sciences and Applications (ACDSA 2027). We are pleased to inform you that your paper entitled "282: Transfer Learning and Kolmogorov-Arnold Networks for Gunshot Wound Classification" has been accepted as a full paper for oral/poster/online presentation by the conference committee of ACDSA 2027. The event will take place Rio de Janeiro, Brazil on 2-4 February 2027 online and physically.

We strictly follow "no podium, no paper" policy and only the papers that are presented at the conference will be submitted to IEEE Xplore for publication. At least one author of an accepted paper must register (as a full participant) and participate in ACDSA 2027 online or physically for the paper to be included in the proceedings.

You can make your registration and payment using this link:
https://www.ecer.org/register/register.php?conf=acdsa-2027

According to the conference regulations, only those papers which have been duly registered and presented on the conference days are considered for submission to IEEE Xplore. The conference program will be communicated in due course.

We look forward to seeing you for a fruitful research and innovation event and for a great time in the wonderful environment of Rio de Janeiro.

Yours sincerely,



Dr. Gabriel Gomes de Oliveira
ACDSA 2027 Conference Chair